

Maestría en Explotación de Datos y Descubrimiento del Conocimiento

Unidad I, Clase 2

Aprendizaje Automático

Tarea, Experiencia, Performance

*"Un programa de computadora se dice que aprende de una **experiencia E** con respecto a una clase de **tareas T** y una medida de **performance P**, si su performance en las tareas T, medidas por P, mejoran con la experiencia E"* (Mitchell 1998)

Laura de la Fuente, Hernán Bocaccio

Diego Onna, Stephanie Müller, Felipe Cignoli, Ezequiel Rodríguez

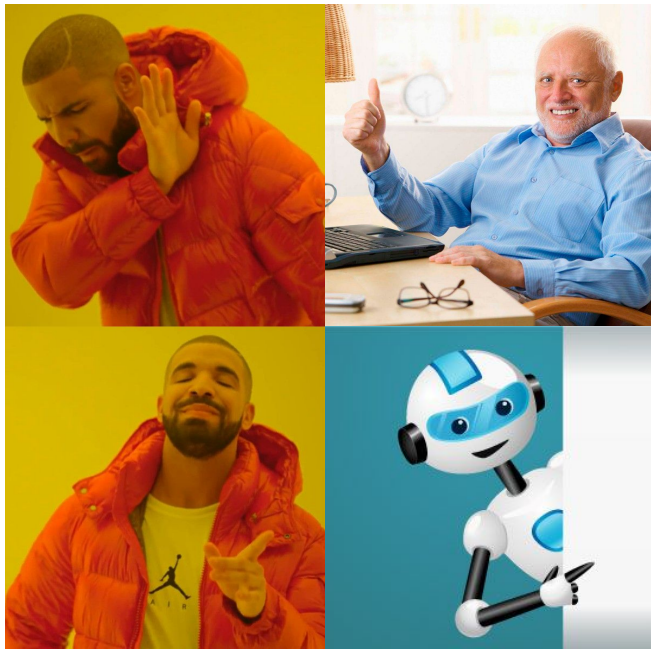
Dirección de e-mail de la materia:

datawillconfess@gmail.com

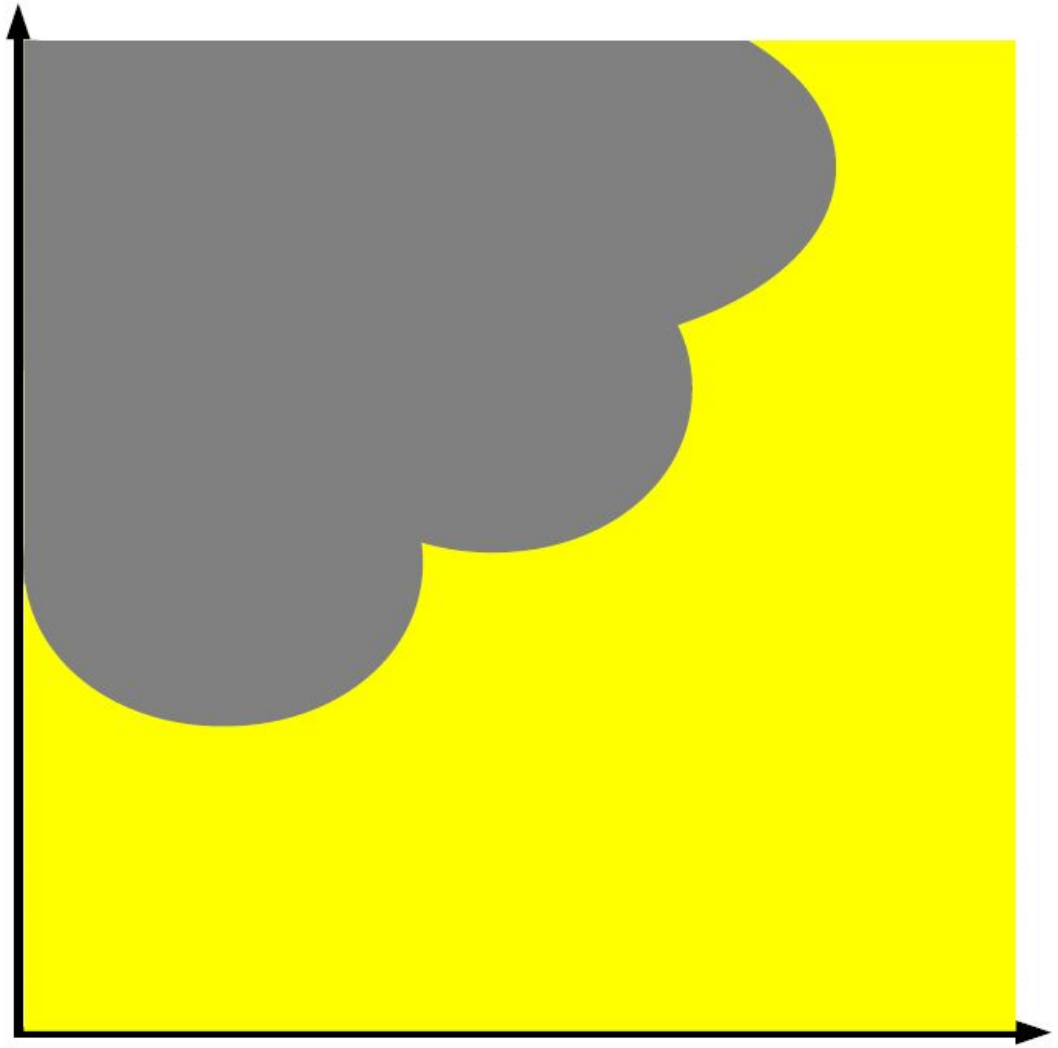
Aprendizaje de conceptos

Concepto: Representación mental asociada a un significante lingüístico.





Aprendizaje de conceptos



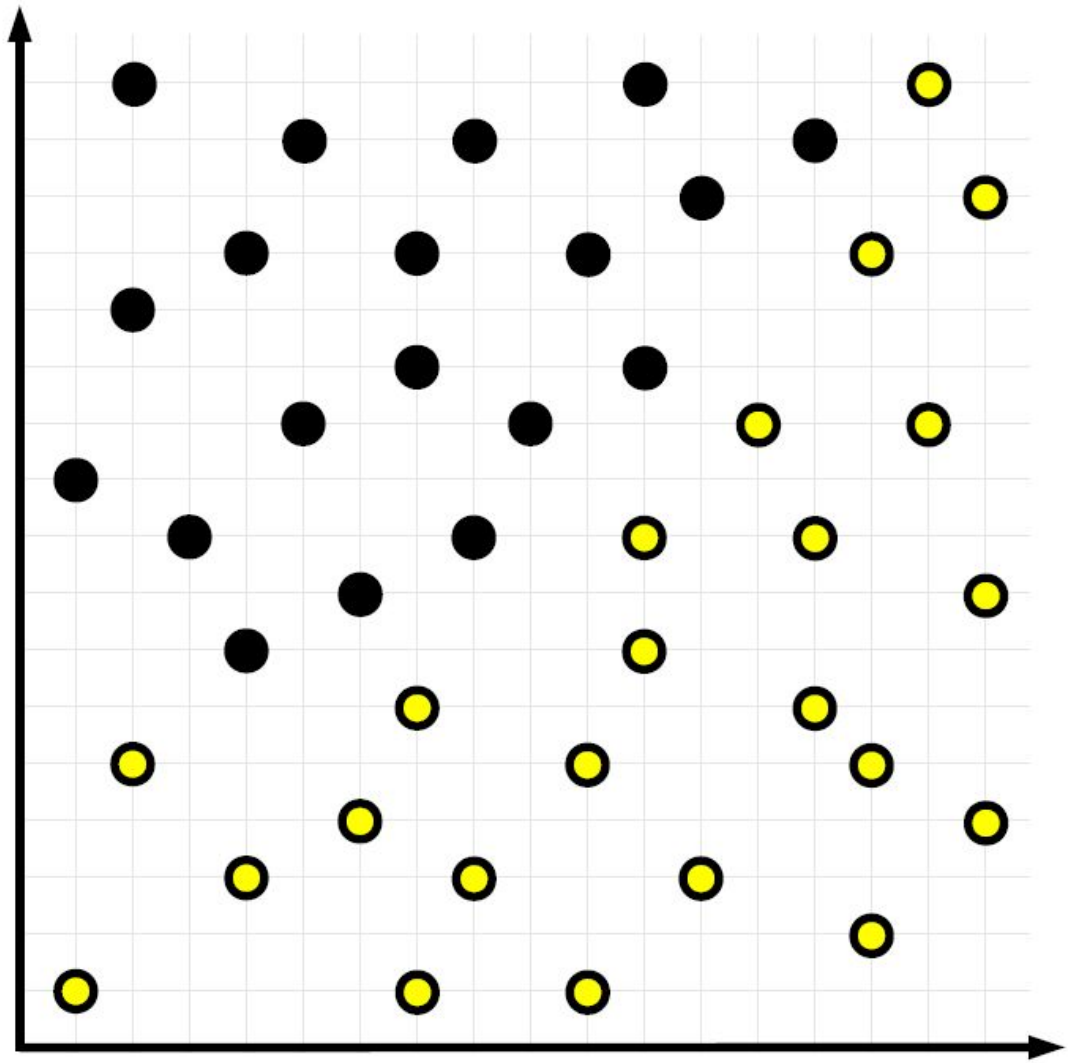
Este es el concepto [función objetivo] que queremos aprender:

$f(x, y) \rightarrow$ color

¡Es desconocida!

Sólo podemos conocerlo a través de muestras, inspeccionando datos.

Aprendizaje de conceptos



Tenemos N muestras [instancias].

Cada punto tiene 2 coordenadas: (x, y) [atributos].

Cada punto tiene un color: negro o amarillo [clases].

Buscamos una función

h(x, y) → color [hipótesis o modelo] que aproxime a la función objetivo.

Aprendizaje Inductivo

Consiste en construir un modelo general a partir de información específica.

Premisa del Aprendizaje Inductivo

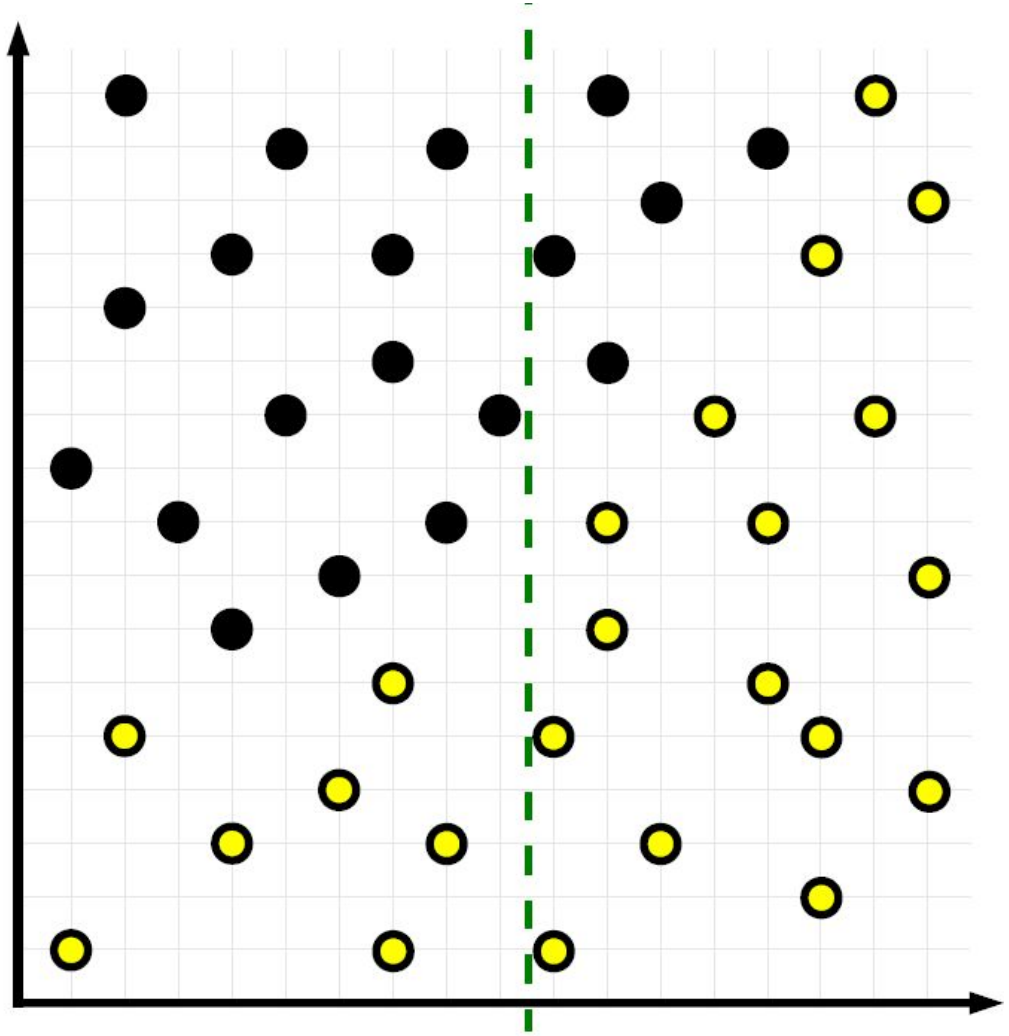
Cualquier **hipótesis h (modelo)**, perteneciente a un **espacio de hipótesis H** que determina la forma que pueda tener, que aproxime bien a una **función objetivo f** sobre un **conjunto suficientemente grande de datos** también aproximará bien a la función objetivo sobre datos no observados **(generaliza)**.

La **forma de las hipótesis** (número y tipo de parámetros); y las características de funcionamiento del algoritmo (**cómo recorre el espacio de hipótesis** hasta elegir un único modelo), son parte de las elecciones que uno hace al modelar y contribuyen al **sesgo inductivo**.

Aprendizaje Inductivo

Buscamos:

Función f(x, y) → color



Primera idea:

h(x, y) = colorizq si x < k

el otro color, si no

H = posibles valores de < k, colorizq >

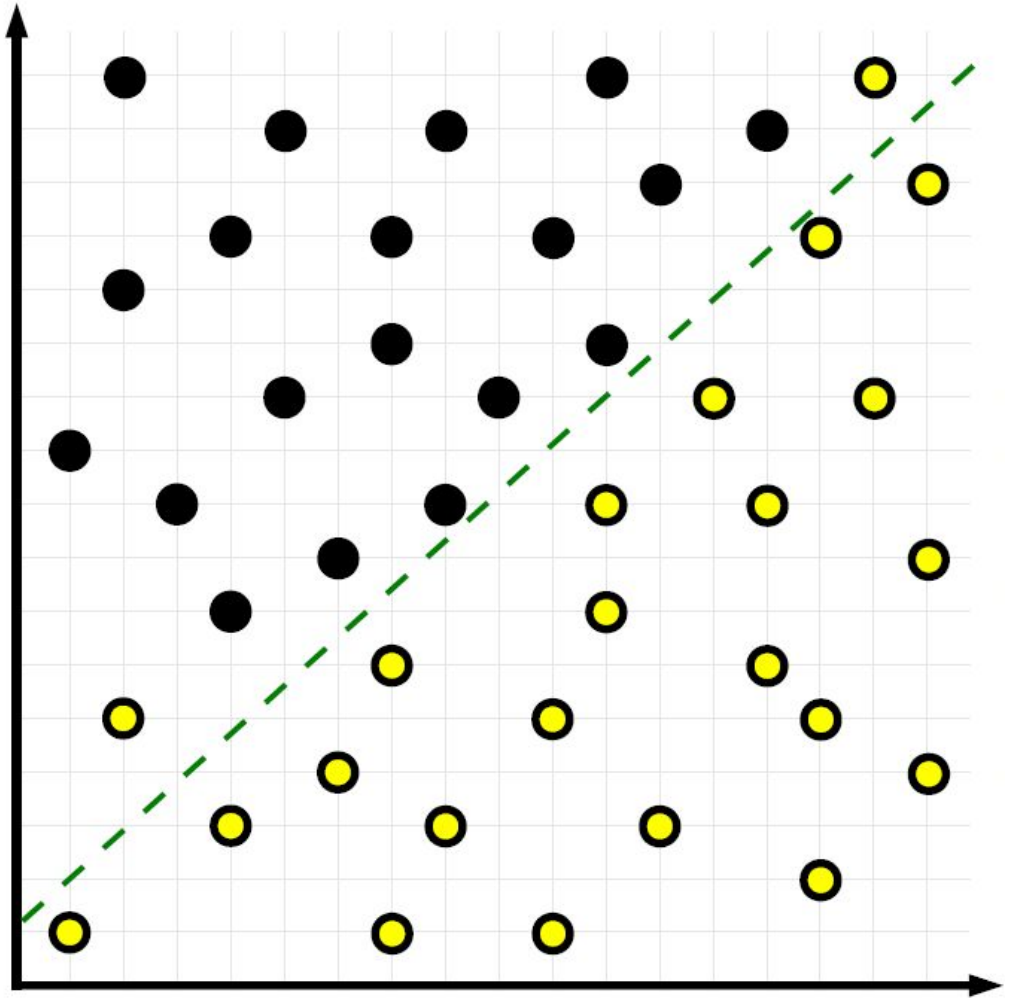
Algoritmo: buscar < k, colorizq > que mejor separe las 2 clases.

Obs: El concepto objetivo no tiene esta forma.

Aprendizaje Inductivo

Buscamos:

Función f(x, y) ⟶ color



Segunda idea:

h(x, y) = colorsup si y > m x + b

el otro color, si no

H = < m, b, colorsup >

Algoritmo: buscar < m, b, colorsup > que mejor separe las 2 clases.

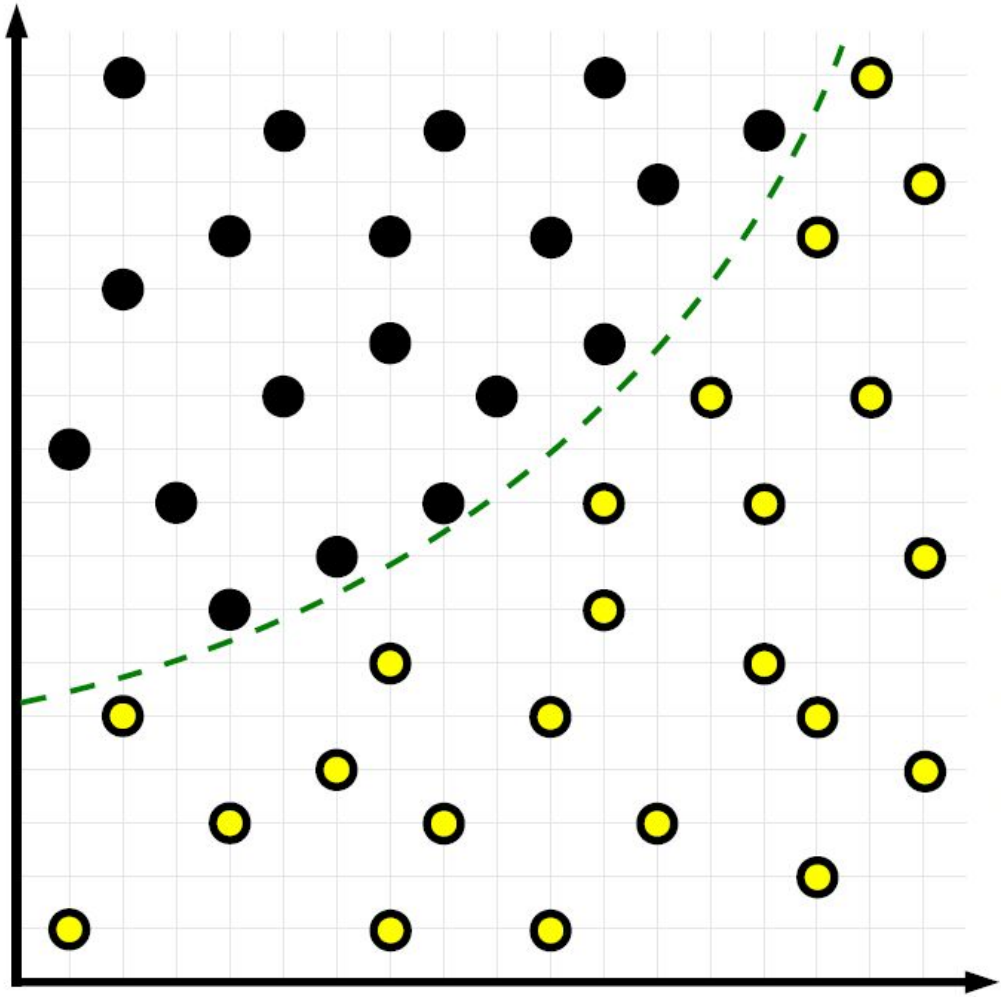
El concepto objetivo tampoco tiene esta forma, pero la aproximación parece mejor que la anterior.

Encontrar los valores m, b, colorsup es más costoso.

Aprendizaje Inductivo

Buscamos:

Función f(x, y) → color



Tercera idea:

h(x, y) = colorsup si y > a x^2 + b x + c

el otro color, si no

H = < a, b, c, colorsup >

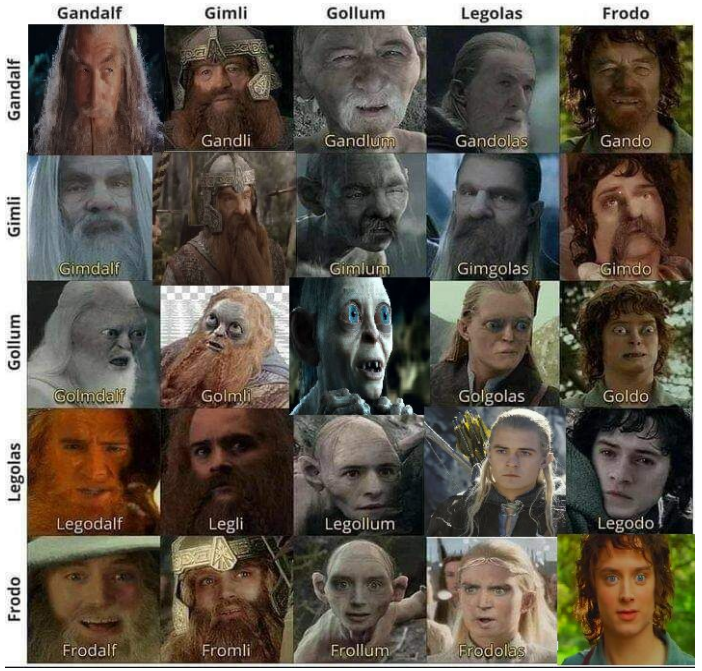
Algoritmo: buscar < a, b, c, colorsup > que mejor separe las 2 clases.

El concepto objetivo tampoco tiene esta forma.

La aproximación parece mejor que las otras dos.

Encontrar los valores a, b, c, colorsup es aún más costoso.

Tipos de modelos según la **Tarea**

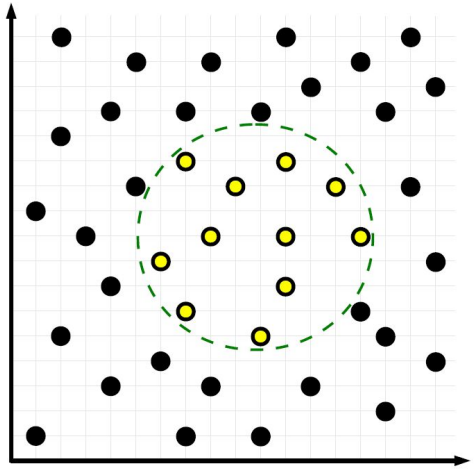


Modelos Predictivos: Es lo que vamos a ver

Entrenados para realizar la tarea de predecir características en datos nuevos (no vistos en el entrenamiento).

Modelos Generativos: ⟶

Entrenados para realizar la tarea de generar datos.



A veces un tipo de modelo podría usarse para las 2 cosas, pero según la tarea puede cambiar cómo lo construyo.

Puedo pedirle al modelo que haga la predicción de color en algún punto nuevo según su posición, o puedo pedirle que me genere la posición de un posible punto amarillo.

Tipos de modelos según la **Experiencia**

La **experiencia** estará dada por **datos** descritos como **variables**.

Variable: representación de una característica observable en los individuos de una población. Se obtiene mediante diferentes procedimientos de medición.

Cualitativa: sus valores designan una categoría (*sexo / monotributista*)

Cuantitativas: sus valores son cantidades numéricas:

- Discreta: sus valores son enteros, no tienen un valor consecutivo (*#de hijos*)
- Continua: pueden tomar cualquier valor en un intervalo numérico (*peso / altura*)

Tipos de modelos según la **Experiencia**

Aprendizaje supervisado:

Los **datos están anotados** con la respuesta correcta que quiero predecir.

- Clasificación: Predecir una clase (variable categórica)
- Regresión: Predecir un valor numérico (variable numérica)

Aprendizaje no supervisado:

Los **datos** de entrenamiento **no están anotados**.

- Encontrar patrones, clustering.
- Transformar datos, reducción de dimensionalidad.

Aprendizaje por refuerzos:

Los datos surgen de la **interacción con el entorno**, y el aprendizaje es gradual en base a una **recompensa**.

Aprendizaje supervisado

Los **datos están anotados** con la respuesta correcta que quiero predecir.

atributos

clase

instancias

Cielo	Temperatura	Humedad	Viento	¿Camina?
Sol	Calor	Alta	Débil	No
Sol	Calor	Alta	Fuerte	No
Nublado	Calor	Alta	Débil	Sí
Lluvia	Templado	Alta	Débil	Sí
Lluvia	Frío	Normal	Débil	Sí
Lluvia	Frío	Normal	Fuerte	No
Nublado	Frío	Normal	Fuerte	Sí
Sol	Templado	Alta	Débil	No
Sol	Frío	Normal	Débil	Sí
Lluvia	Templado	Normal	Débil	Sí
Sol	Templado	Normal	Fuerte	Sí
Nublado	Templado	Alta	Fuerte	Sí
Nublado	Calor	Normal	Débil	Sí
Lluvia	Templado	Alta	Fuerte	No

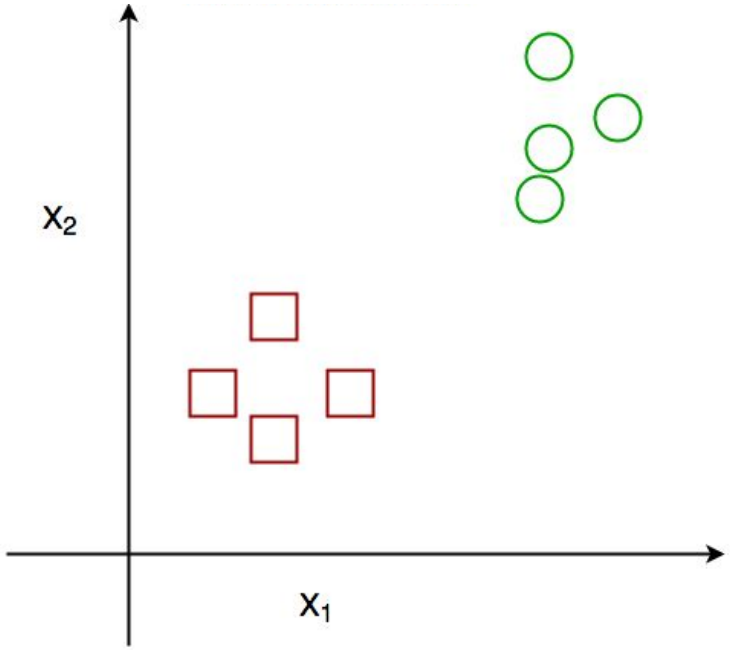
En este ejemplo, la **respuesta** correcta que quiero predecir es una variable categórica (clase). Pero también podría ser una variable numérica (metros que camina).

Conseguir datos anotados puede ser **costoso** (tiempo, recursos, dinero), o en el caso de datos minados o de usuarios puede tener problemas de **calidad y sesgos**. También puede haber problemas de disponibilidad o **sensibilidad de la información**.

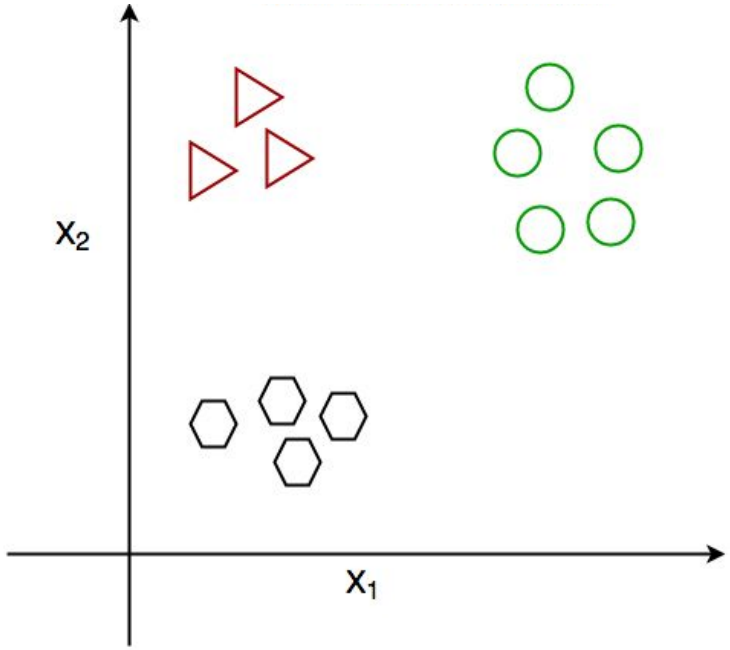
Clasificación

Cuando la **variable** anotada que quiero predecir es **categórica** (clase).

Clasificación binaria



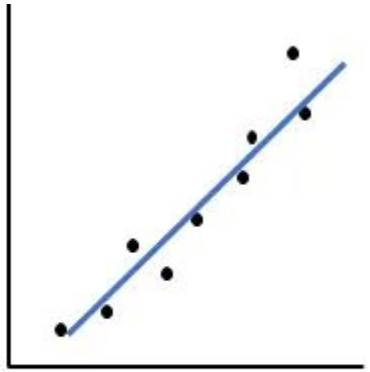
Clasificación multi-clase

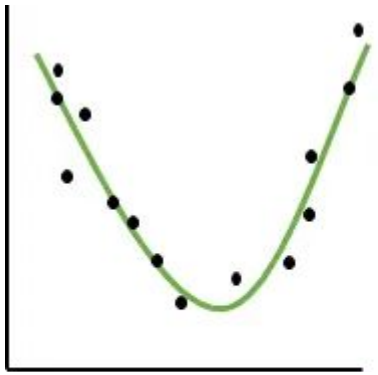


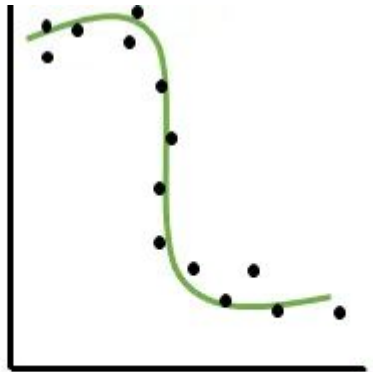
La **predicción** sobre un dato nuevo puede ser la **clase** a la que pertenece o la **probabilidad** de pertenecer a esa clase según el modelo y el algoritmo.

Regresión

Cuando la **variable** anotada que quiero predecir es **numérica** (cantidad).







Regresión lineal **Regresión no lineal** (polinomio, etc)

Respuesta Parámetros Atributos

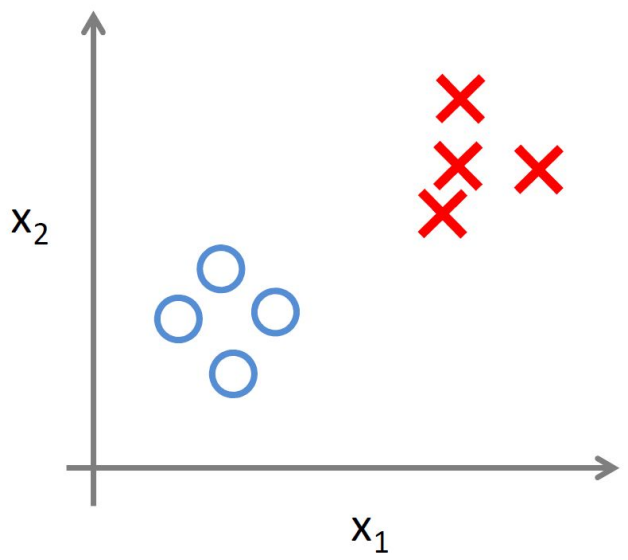
$$Y_i = \beta_0 + \beta_1 X_i$$

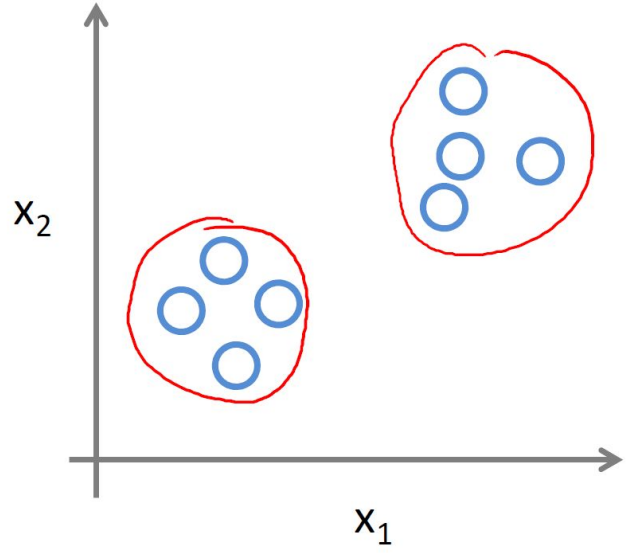
Postulo que la **función objetivo** responde a una **relación lineal**.
Exploro el **espacio de hipótesis** definido por rectas genéricas (**parámetros desconocidos**).
Estimo los **parámetros** que aproximan a la función objetivo, y definirán mi **hipótesis**.

Aprendizaje no supervisado

Los **datos** de entrenamiento **no están anotados**.

Supervisado vs. No supervisado





Se busca encontrar patrones ocultos en los datos o transformarlos para entenderlos mejor.

Clustering, reducción dimensionalidad.
Ejemplos: segmentación de mercado, análisis redes sociales, …



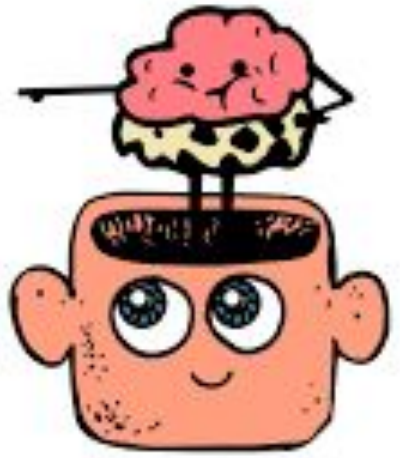


Aprendizaje por refuerzo

- Aprendizaje de un agente autónomo (con sensores) para elegir acciones óptimas que le permitan lograr sus objetivos.
- Premio y castigos, en función de la satisfacción del objetivo, con efecto atrasado.
- Agente tiene que aprender qué secuencias de acciones realizar para obtener el mejor premio posible.
- Ej: juegos de mesa, robots autónomos, cerebro (secuencia de acciones).







CLASSICAL MACHINE LEARNING

Data is pre-categorized or numerical

SUPERVISED

Predict a category

CLASSIFICATION

«Divide the socks by color»



Predict a number

REGRESSION

«Divide the ties by length»



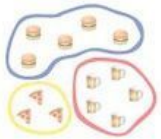
Data is not labeled in any way

UNSUPERVISED

Divide by similarity

CLUSTERING

«Split up similar clothing into stacks»



Find hidden dependencies

DIMENSION REDUCTION (generalization)

«Make the best outfits from the given clothes»



Identify sequences

ASSOCIATION

«Find what clothes I often wear together»



Es lo que vamos a ver

Medidas de performance

¿Qué medidas usamos?

Accuracy: proporción de aciertos totales

Ventaja, intuitiva. Desventaja, mala en datos desbalanceados (ej: meteorito)



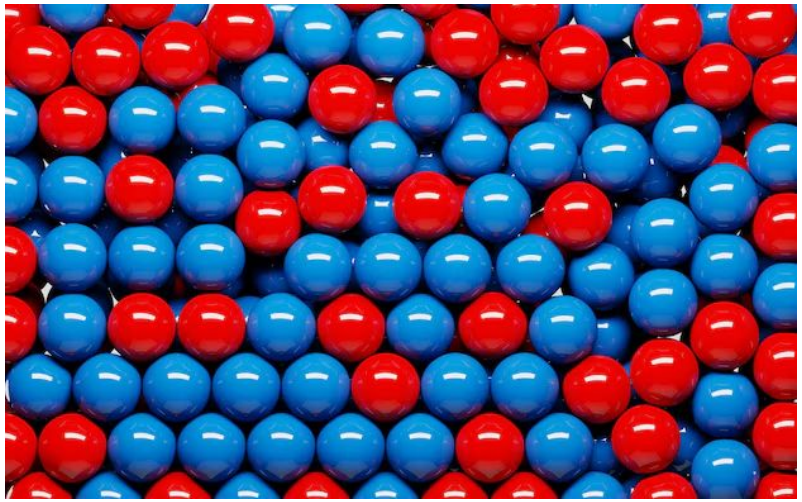
No cae hasta que es tarde...

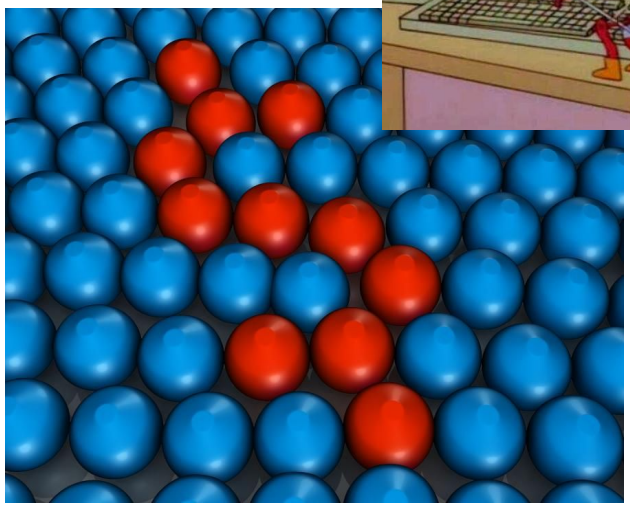


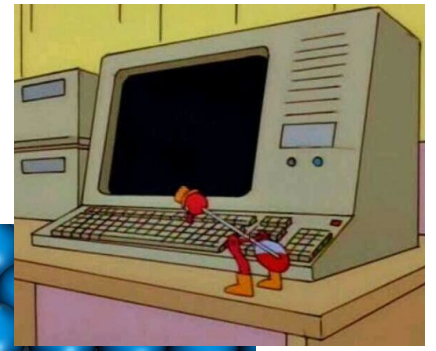
Medidas de performance

Cómo sabemos qué tan buena es la performance?









Tenemos que comparar con performances obtenidas por chance, haciendo una permutación aleatoria de etiquetas (**chance/random/modelo nulo**) que rompe la estructura de los datos pero no el balance, para ver si el modelo aprendió algo

Medidas de performance

¿Qué medidas usamos?

<u>Sensibilidad/recall/TVP:</u>

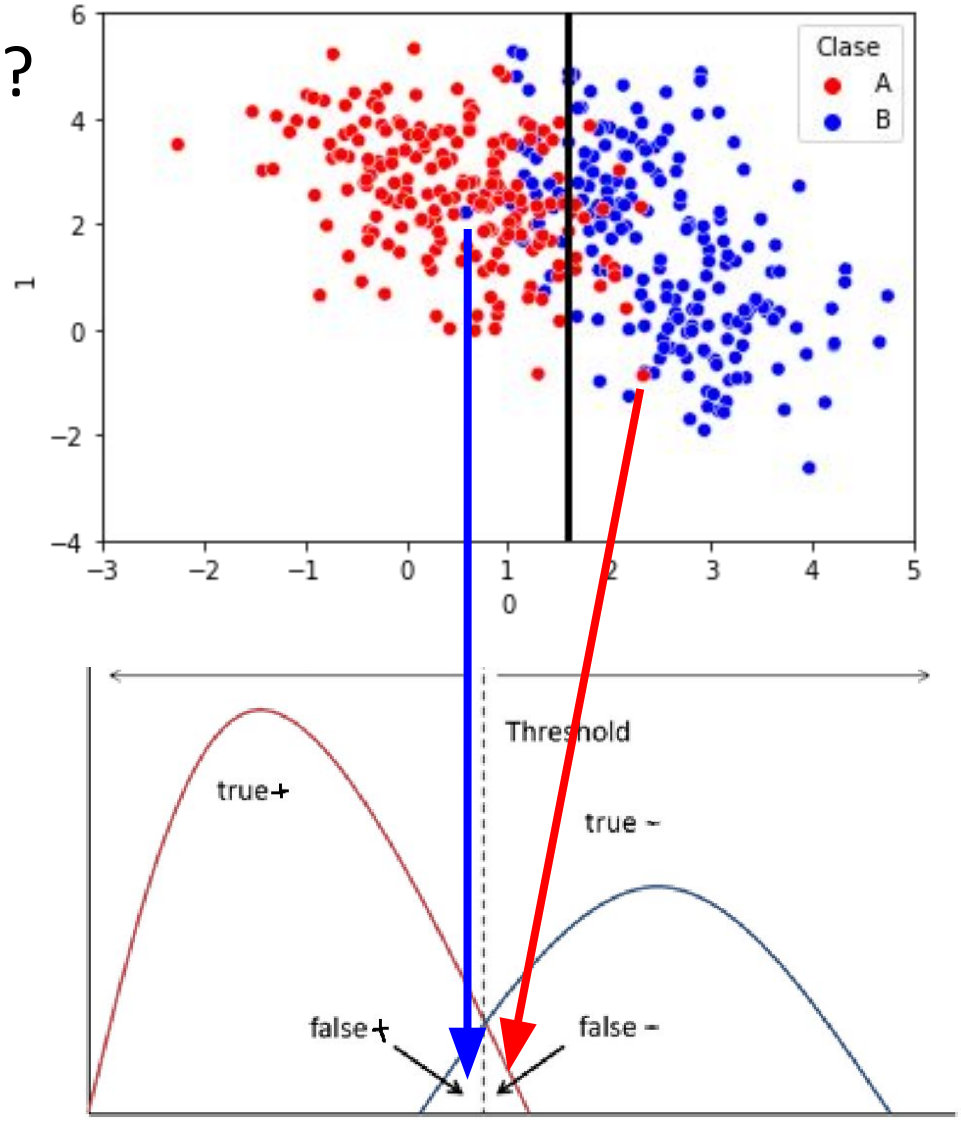
Proporción de positivos que recuperé

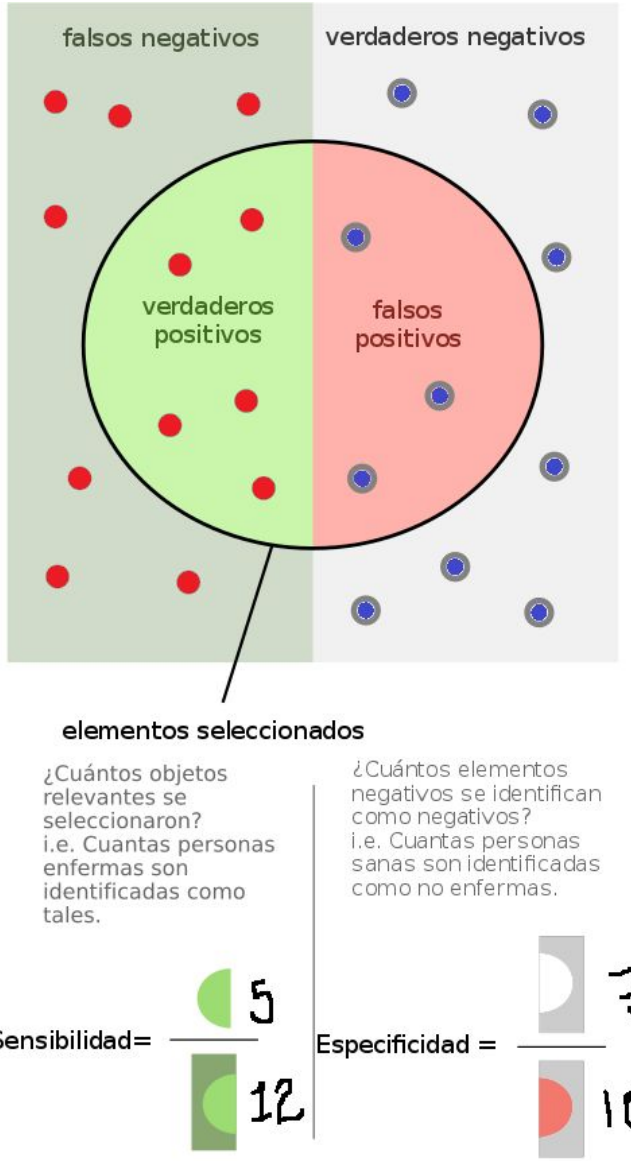
$$Sensibilidad = \frac{VP}{VP + FN}$$

<u>Especificidad/TVN:</u>

Proporción de negativos que recuperé

$$Especificidad = \frac{VN}{VN + FP}$$

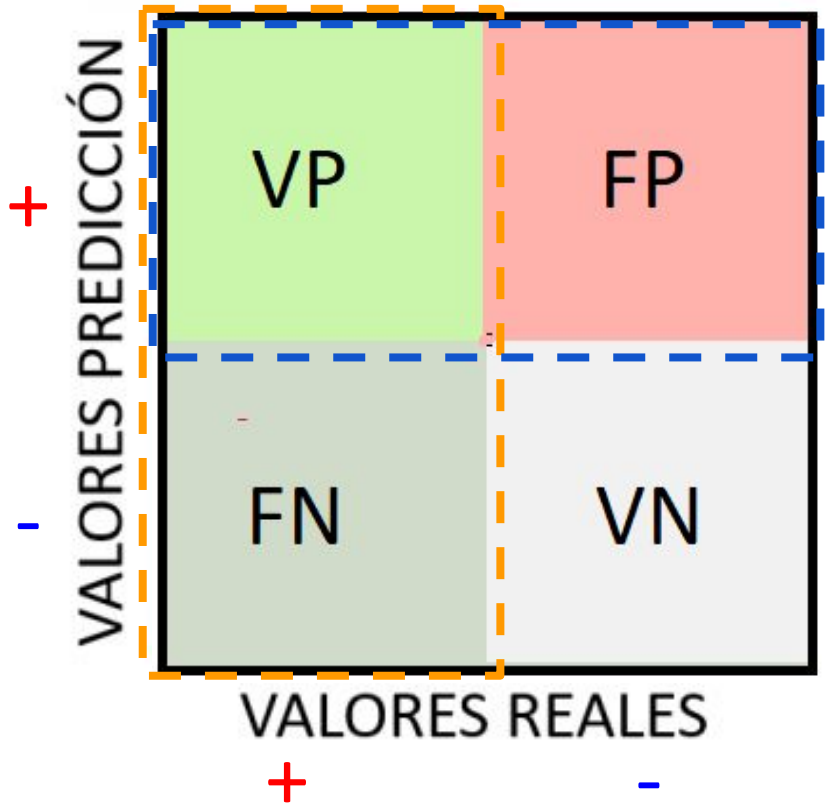




Medidas de performance

¿Qué medidas usamos?

Matriz de confusión





$$precision = \frac{TP}{TP + FP}$$

Precision alto: los positivos predichos, lo son (menos error de tipo I)



$$recall = \frac{TP}{TP + FN}$$

Recall alto: no se me pasan positivos sin predecir (menos error de tipo II)

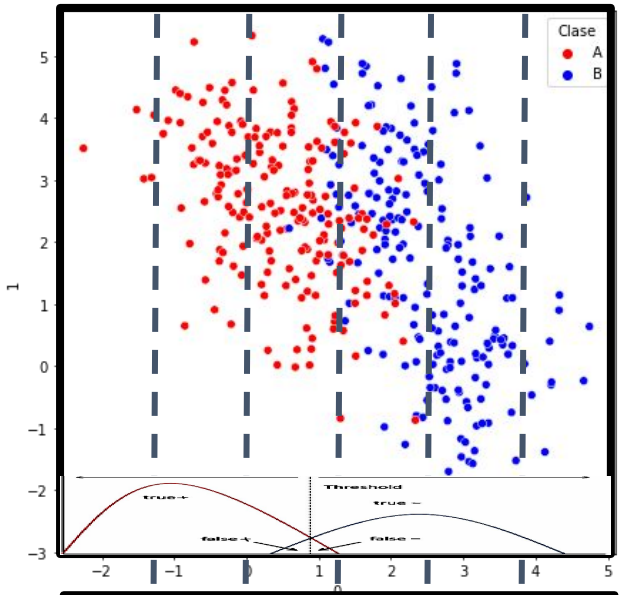


$$F1 = \frac{2 \times precision \times recall}{precision + recall}$$

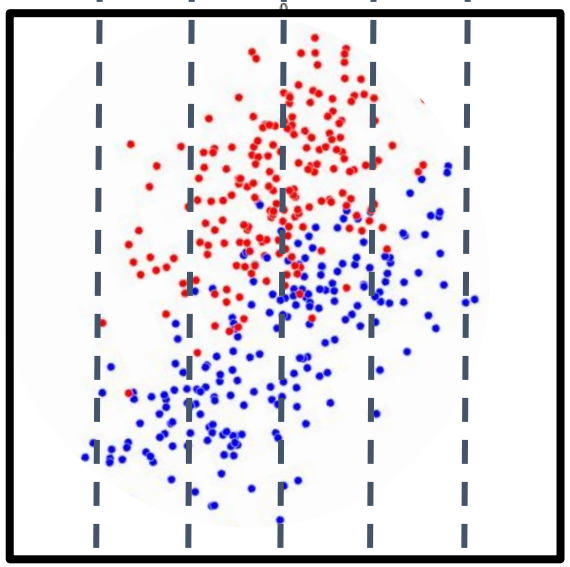
$$accuracy = \frac{TP + TN}{TP + FN + TN + FP}$$

Medidas de performance

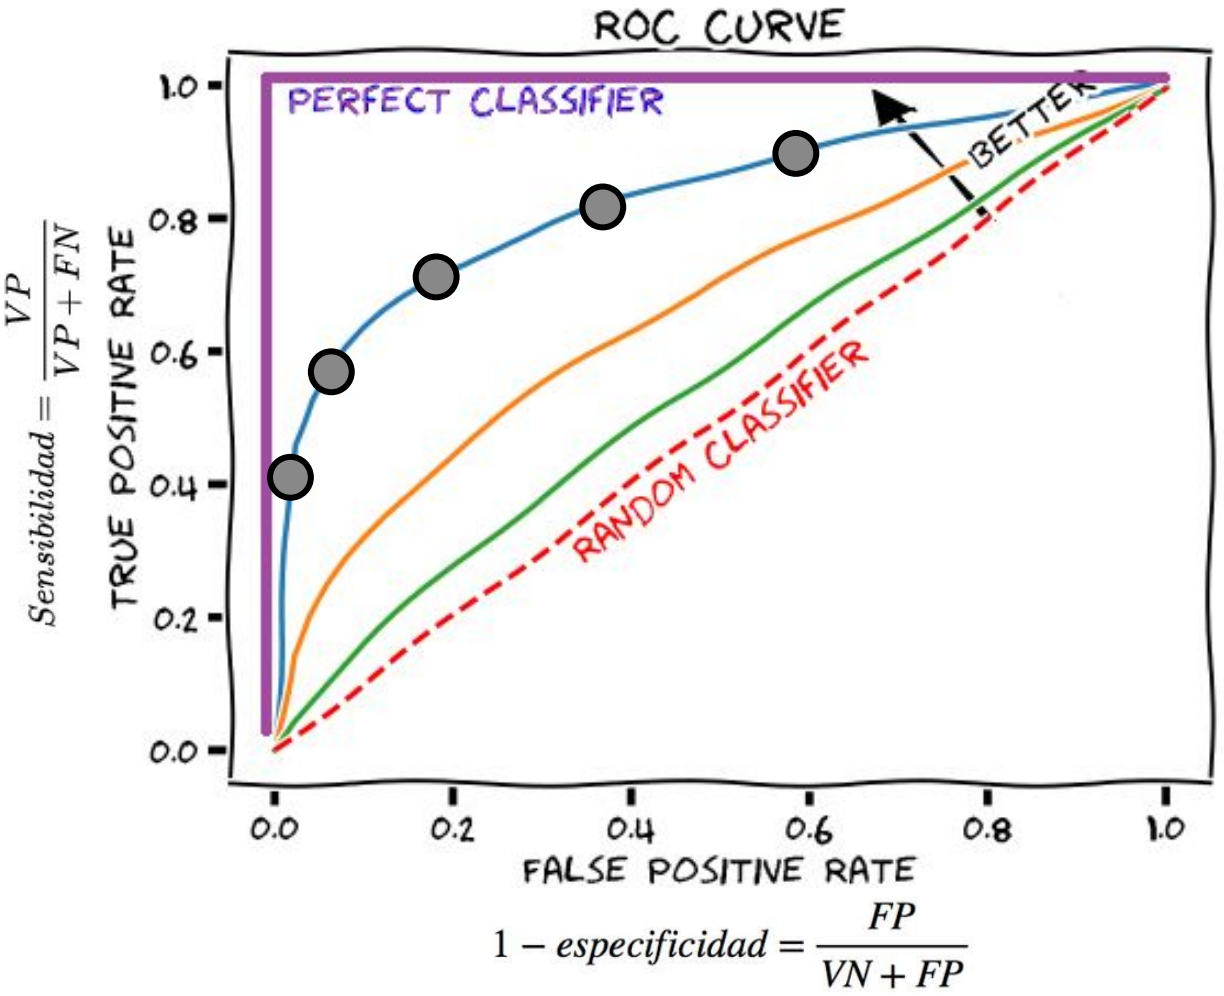
Clases



Random



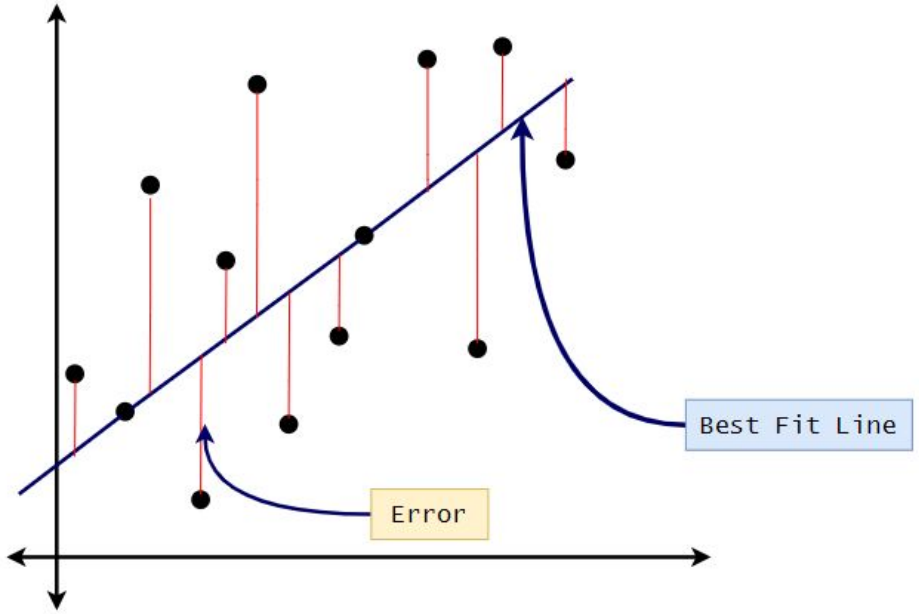
Curvas ROC



Área bajo la curva ROC (AUC) es una medida de desempeño

Medidas de performance

Caso regresión



Respuesta

Parámetros

Atributos

$$Y_i = \beta_0 + \beta_1 X_i$$

Hipótesis (estimación)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x$$

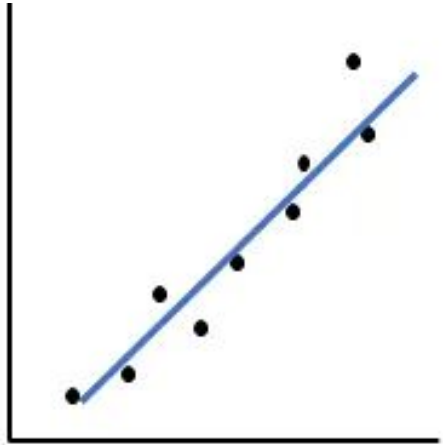
Predicción en datos nuevos

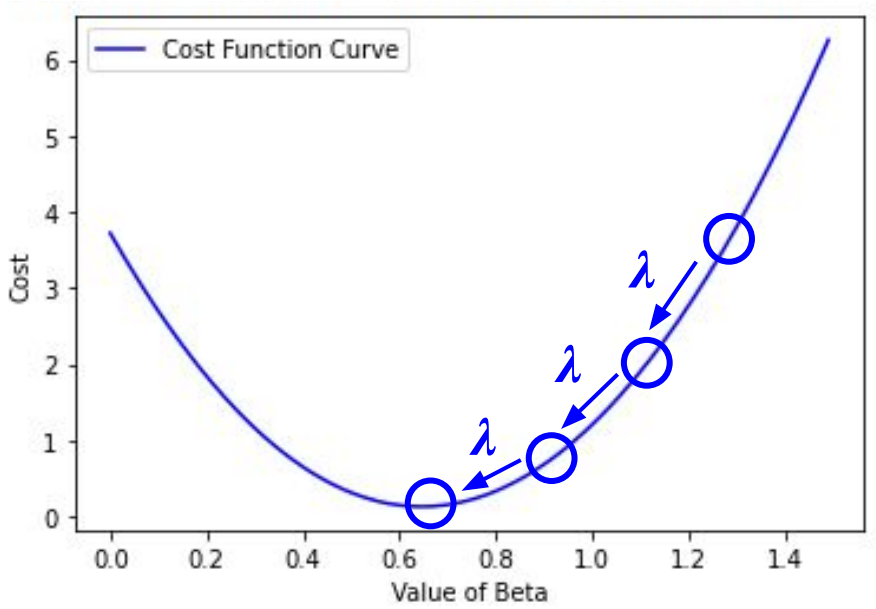
$$\text{MSE} = \frac{1}{n} \sum_{i=1}^{n} \left(\underbrace{y^{(i)} - \hat{y}^{(i)}}_{\text{error}} \right)^2$$

Error cuadrático medio

Función costo

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x$$





Error cuadrático medio

$$J(\hat{\beta}) = \frac{1}{n}\sum_{i=1}^{n}\left(\underbrace{y^{(i)} - \hat{y}^{(i)}}_{\text{error}}\right)^2$$

Función costo

Gradiente: $\dfrac{\partial J(\hat{\beta})}{\partial \hat{\beta}}$

Entrenar un modelo es básicamente resolver un problema de **optimización** que consiste en encontrar los **parámetros que minimizan una función costo**.

En los problemas de clasificación también se puede definir una función costo a minimizar (depende de modelo y algoritmo).

Uno de los métodos de minimización de la función costo, y el más usado, es el de **descenso por el gradiente**, con un paso llamado **learning rate** (lambda).

Curvas de aprendizaje



De manera general, el **aprendizaje** implica una **mejoría a partir de la experiencia**.

Esta mejoría no es infinita, sino que satura, lo que refleja una curva de aprendizaje.

El caso del aprendizaje automático es análogo. La mejoría se puede cuantificar con la **performance** (que va a maximizarse cuando minimizo la función costo), y la experiencia va a depender de la **cantidad de datos** que usé para el **entrenamiento**.

Cuantos más datos uso, mejora la performance de entrenamiento. Siempre? No, a veces no es suficiente aumentar la cantidad de datos. Puede ser que el modelo no sea el adecuado, que los datos no reflejen el concepto que quiero aprender, o que directamente no haya nada para aprender.

Take home message

1 - Nuestros ejemplos terminan definiendo la solución, OJO

2 - Antes de arrancar debemos definir claramente el problema y las herramientas adecuadas respondiendo:

- Tarea: Clasificación? Regresión?
- Experiencia: De qué son representativos mis datos?
- Performance: Cuál es la medida adecuada para mi problema?

3 - Qué es entrenar un modelo? Es en problema de optimización en el que se estiman los parámetros que mejor ajustan el modelo a los datos

A los Colabs…!!

