

Data Mining aplicado a Ciencia y Tecnología

A dark blue diagonal gradient bar that starts from the bottom left and extends towards the top right, covering the lower half of the slide.

Nosotros

IBioBA - MPSP

Instituto de Investigación en Biomedicina de Buenos Aires
- CONICET - Partner Institute of the Max Planck Society



Sebastián Romano (sebastian.romano@gmail.com).

Investigador CONICET. Lic. en Física (UBA) y PhD en Biofísica (UFRJ, Brasil)


Neurociencia. Procesamiento sensorial. Modelado estadístico. Aprendizaje.

Hernán Varela. Lic. en Sociología - UBA / Maestría Data Mining - UBA

Santiago Bezchinsky. Lic. en Sociología - UBA / Maestría Data Mining - UBA


Tomás Cicchini. Lic. en Ciencias Físicas - UBA / Doctorando en Ciencias Físicas - UBA

Revelando estructura en la actividad de redes neuronales (de forma no supervisada)



Romano *et al.* 2015
Romano *et al.* 2017


Data Mining aplicado a Ciencia y Tecnología 2026




Grafos

Estudiando los mecanismos evolutivos de la topología de grafos biológicos



Red de interacciones entre proteínas



Proceso evolutivo



Características topológicas



Sebastián Romano






Romano & Eguia 2004

Grafos

Flujos de empleo y transferencia de habilidades en Argentina (2014-2024) en base a redes complejas a partir de convenios colectivos


		t				
		A	B	C	D	E
t+1	A					
	B					
	C					
	D					
	E					

Heatmap de la matriz de adyacencia para el año 2024



Hernán Varela


LLMs y RAG aplicado a temáticas legales/impositivas



Análisis de tópicos y sentimiento en redes sociales




Santiago Bezchinsky




Visión por computadora para relevamiento de Barrios Populares



Robustez estructural y funcional TP



Redes de hospitales durante covid19



Tomás Cicchini

¿Ustedes?

Diversidad de formaciones de esta cohorte

Ingeniería Industrial (x10)

Economía (x8)

Biología (x7)

Informática / Sistemas de información (x6)

Sociología (x6)

Física (x3)

Ingeniería Química (x2)

Química (x2)

Administración (x2)

Psicología (x2)

Biotecnología (x2)

Ciencias de la Atmósfera (x2)

Computación (x2)

Medicina (x2)

Bioquímica

Actuario

Ingeniería Civil

Ingeniería Biomédica

Ingeniería Mecánica

Agronomía

Ingeniería Electrónica

Letras

Ciencias Política


Diseño Integrado

Gestión Deportiva

Comunicación

Estadística

Primer cuatrimestre: coordinación con otras materias




Contenidos de DMCyT a grandes rasgos

Técnicas de aprendizaje no supervisado para el análisis de datos complejos


- El aprendizaje no supervisado es un tipo de aprendizaje automático que aprende de datos “sin supervisión humana” (sin etiquetar).
- El modelo tiene que inferir sus propias reglas y estructurar la información en función de similitudes, diferencias y patrones sin instrucciones explícitas sobre cómo trabajar.
- Ayudan a identificar características útiles para categorizar y organizar los datos en tareas de procesamiento complejas.

Contenidos de DMCyT a grandes rasgos


Grafos



Clustering




Reducción de dimensionalidad




Contenidos de DMCyT a grandes rasgos


Grafos



Clustering



Reducción de dimensionalidad




Diferentes problemas pueden tratarse con técnicas similares, con algunas especificaciones propias de cada dominio.

Abordaje de la materia

Como Disciplina

Los científicos de datos son personas que utilizan su experiencia en estadística, programación y dominio de aplicación para transformar datos en conocimientos.




Abordaje de la materia

Como Disciplina

Los científicos de datos son personas que utilizan su experiencia en estadística, programación y dominio de aplicación para transformar datos en conocimientos.

Como Ciencia

El científico de datos es un **científico**: alguien que aplica el método científico para generar conocimiento a partir de datos en gran volumen



Abordaje de la materia


Como Disciplina

Los científicos de datos son personas que utilizan su experiencia en estadística, programación y dominio de aplicación para transformar datos en conocimientos.


Como Ciencia

El científico de datos es un **científico**: alguien que aplica el método científico para generar conocimiento a partir de datos en gran volumen


*Mientras que la ciencia busca “**entender el mundo**” y desarrollar herramientas y métodos para investigarlo, la ciencia de datos busca “**entender los datos**” y desarrollar herramientas y métodos para investigarlos. Es decir, la ciencia de datos concibe a los **datos como una fuente natural de información** y trabaja con métodos para extraer valor de estos datos*




El método científico es un proceso iterativo y cíclico, en el que las teorías y la información es continuamente revisada...




El método científico es un proceso iterativo y cíclico, en el que las teorías y la información es continuamente revisada...



El método científico es un proceso iterativo y cíclico, en el que las teorías y la información es continuamente revisada...



El método científico es un proceso iterativo y cíclico, en el que las teorías y la información es continuamente revisada...



Saber reportar resultados es parte del trabajo

El paper o artículo científico

¿Cuántos de uds leyeron alguna vez un artículo científico?

Saber reportar resultados es parte del trabajo

El paper o artículo científico

- Rigor metodológico
- Evaluación crítica de la evidencia
- Reporte completo, claro y neutro
- Integridad

Anatomy of a Scientific Paper

Are All Apples Red?

by
Ida Cortland

Abstract:

We examined several apples' color. Although most are red, some are not.

Introduction:

An age-old question is: are all apples red? MacIntosh (1993) thought so. G. Smith (1999) begs to differ. We hope to resolve this issue once and for all.

Methods:

We went to the local grocery store and bought one of every apple they had. We took them home and looked at them.

Results:

We found four red apples, one green apple, and two yellow apples.




Figure 1

Discussion:

Since we found one yellow apple and two green apples, it must be true that all apples are not red. We concur with G. Smith's findings.

References:

MacIntosh (1993) *Journal of Fruit Science*. 4(3): 121-135.

Smith, G. (1999) *Apple Technology Today*. 7(3):4-8.

Pomes and You, Volume 3, Issue 4 (2003) p. 8

Un poco de burocracia

Un poco de burocracia

- Virtualidad cuando sea estrictamente necesario: cámaras prendidas y con interacción. Que no sea para grabar clases únicamente.
- Material asincrónico opcional:

Colab de intro a python, numpy, pandas, matplotlib, seaborn, plotly.

Clase grabada de Sistemas de Información Geográfica (GIS)

Bibliografía adicional

- Discusión de papers
- Asistencia

Un poco de burocracia

- Evaluación: trabajos grupales y examen multiple choice individual.
- TP1 (grupal) de Grafos
- TP2 (grupal) de Clustering
- Examen multiple choice presencial (y recuperatorio multiple choice presencial)
- Nota final: promedio entre TP1, TP2 y examen.

Si se dio recuperatorio: promedio entre TP1, TP2 y (examen + recuperatorio)/2

- Conformación de grupos: de 4 integrantes, no más, y que **mezclen formaciones y conocimientos**

Anotarse junto con el grupo en la solapa "Grupos definitivos", numerando cada grupo de acuerdo se vayan agregando a la lista.

	A	B	C	D	E
1	Grupo #	Nombre y Apellido	mail	Comisión	Observaciones
2					
3					
4					
5					
6					
7					
8					
9					
10					
11					
12					
13					
14					
15					
16					
17					
18					
19					
20					
21					
22					
23					
24					
25					
26					
27					
28					
29					
30					
31					

+ ≡ Grupos definitivos ▾ Busco grupo ▾

Si no tuviesen grupo pueden anotarse en la solapa "Busco grupo" indicando su formación para que otrxs lxs contacten.

	A	B	C	D
1	Nombre y Apellido	mail	Comisión	Formación e info adicional
2				
3				
4				
5				
6				
7				
8				
9				
10				
11				
12				
13				
14				
15				
16				
17				
18				
19				
20				
21				
22				
23				
24				
25				
26				
27				
28				
29				
30				
31				

+ ≡ Grupos definitivos ▾ Busco grupo ▾

Anotarse junto con el grupo en la solapa "Grupos definitivos", numerando cada grupo de acuerdo se vayan agregando a la lista.

	A	B	C	D	E
1	Grupo #	Nombre y Apellido	mail	Comisión	Observaciones
2					
3					
4					
5					
6					
7					
8					

Si no tuviesen grupo pueden anotarse en la solapa "Busco grupo" indicando su formación para que otrxs lxs contacten.

	A	B	C	D
1	Nombre y Apellido	mail	Comisión	Formación e info adicional
2				
3				
4				
5				
6				
7				
8				

Fecha límite para armado de grupos: Miércoles 25 de marzo.
Antes de empezar los labos. Cuanto antes los armen, mejor.

21					
22					
23					
24					
25					
26					
27					
28					
29					
30					
31					

+ ≡ Grupos definitivos ▾ Busco grupo ▾

20					
21					
22					
23					
24					
25					
26					
27					
28					
29					
30					
31					

+ ≡ Grupos definitivos ▾ Busco grupo ▾

CRONOGRAMA - DATA MINING EN CIENCIA Y TECNOLOGÍA - 2026					
Entregas	Martes	TEMA	Jueves	TEMA	
	10/03	Presentación de la materia. Abordaje científico a data science. Análisis de grafos (parte 1). Sistemas complejos y Ciencia de Redes. Variedad de redes en la naturaleza, sociedad y tecnología. Grafos binarios y pesados. Binarización por umbral o densidad de enlaces. Grafos simples y multigrafos. Grafos dirigidos y no dirigidos. Grafos bipartitos. Árboles. Grado de un nodo y distribución de grado de una red.	12/03	Presentación de la materia. Abordaje científico a data science. Análisis de grafos (parte 1). Sistemas complejos y Ciencia de Redes. Variedad de redes en la naturaleza, sociedad y tecnología. Grafos binarios y pesados. Binarización por umbral o densidad de enlaces. Grafos simples y multigrafos. Grafos dirigidos y no dirigidos. Grafos bipartitos. Árboles. Grado de un nodo y distribución de grado de una red.	
	17/03	Análisis de grafos (parte 2). Recorridos y caminos. Longitudes y distancias. Eficiencia. Conectividad, componentes. Coef. de clustering. Asortatividad de redes. Prototipos de redes: Poisson, "Mundo Pequeño", Libres de Escala. Robustez de redes. Comparación con redes del mundo real.	19/03	Análisis de grafos (parte 2). Recorridos y caminos. Longitudes y distancias. Eficiencia. Conectividad, componentes. Coef. de clustering. Asortatividad de redes. Prototipos de redes: Poisson, "Mundo Pequeño", Libres de Escala. Robustez de redes. Comparación con redes del mundo real.	
	24/03	FERIADO	26/03	Laboratorio grafos	
	31/03	Laboratorio grafos	02/04	FERIADO	
	07/04	Análisis de grafos (parte 3). Medidas de centralidad: de grado, de intermediación, de cercanía y de autovector. Definición de modularidad y comunidades. Algoritmos de maximización de modularidad: Louvain	09/04	Análisis de grafos (parte 3). Medidas de centralidad: de grado, de intermediación, de cercanía y de autovector. Definición de modularidad y comunidades. Algoritmos de maximización de modularidad: Louvain	
	14/04	Tópicos de grafos. Stochastic Block Model. Discusión de papers. Aplicación: Graph Retrieval-Augmented Generation (GraphRAGs).	16/04	Tópicos de grafos. Stochastic Block Model. Discusión de papers. Aplicación: Graph Retrieval-Augmented Generation (GraphRAGs).	
	21/04	Laboratorio grafos.	23/04	Laboratorio grafos.	
	28/04	Herramientas de estadística para análisis de datos. Tests de hipótesis y p-Values. Crisis de replicabilidad en ciencia: p-hacking, etc. Buenas prácticas estadísticas. Pruebas estadísticas para comparaciones múltiples. Técnicas de remuestreo: Permutaciones y Bootstrapping, Cross-Validation.	30/04	Herramientas de estadística para análisis de datos. Tests de hipótesis y p-Values. Crisis de replicabilidad en ciencia: p-hacking, etc. Buenas prácticas estadísticas. Pruebas estadísticas para comparaciones múltiples. Técnicas de remuestreo: Permutaciones y Bootstrapping, Cross-Validation.	
	05/05	Consultas TP	07/05	Consultas TP	
	12/05	Reducción de la dimensionalidad y aprendizaje de variedades. "Maldición de la dimensionalidad". Métodos lineales y no lineales. PCA, SVD, MDS, ISOMAP, t-SNE, UMAP. Aplicaciones.	14/05	Reducción de la dimensionalidad y aprendizaje de variedades. "Maldición de la dimensionalidad". Métodos lineales y no lineales. PCA, SVD, MDS, ISOMAP, t-SNE, UMAP. Aplicaciones.	
Do 17/05	Entrega TP1.				
	19/05	Temas especiales de clustering (parte 1). Algoritmos: Clustering por prototipo (k-means / PAM o k-medoids), Clustering jerárquico, Clustering por densidad (DBSCAN), Clustering difuso	21/05	Temas especiales de clustering (parte 1). Algoritmos: Clustering por prototipo (k-means / PAM o k-medoids), Clustering jerárquico, Clustering por densidad (DBSCAN), Clustering difuso	
	26/05	Temas especiales de clustering (parte 2). Distancias y medidas de similitud: binarias, continuas, categóricas, mixtas. Tendencia al clustering. Validación interna y externa de clusters. Tutorial preTP	28/05	Temas especiales de clustering (parte 2). Distancias y medidas de similitud: binarias, continuas, categóricas, mixtas. Tendencia al clustering. Validación interna y externa de clusters. Tutorial preTP	
	02/06	Laboratorio clustering.	04/06	Laboratorio clustering.	
	09/06	Temas especiales de clustering (parte 3). Aplicaciones: agrupamiento de imágenes.	11/06	Temas especiales de clustering (parte 3). Aplicaciones: agrupamiento de imágenes.	Clase presencial en laboratorio
	16/06	Laboratorio clustering.	18/06	Laboratorio clustering.	Clase presencial en aula
	23/06	Clase integrativa de la materia. Consultas Examen	25/06	NO HAY CLASE	Clase virtual (zoom)
	30/06	NO HAY CLASE	02/07	Examen final. Multiple-choice	Entrega en Campus
	07/07	Consultas TP / Consultas Recuperatorio	09/07	FERIADO	
Do 12/07	Entrega TP2				
	14/07	Recuperatorio. Multiple Choice			

Contexto actual

Situación presupuestaria y salarial **crítica** en las universidades públicas nacionales.

Flexibilidad + Adaptabilidad