



Grafos (parte 3/3)

¿Cómo caracterizar una red?



¿Cómo caracterizar una red?




Una variedad de **medidas topológicas**...

Por ej.:


- Distribución de grado
- Distancias
- Coeficiente de clustering
- Robustez
- Asortatividad

¿Cómo caracterizar una red?




También hay **propiedades emergentes**...
Como por ejemplo, los “*mundos pequeños*”

Red de Facebook



Dos visiones del “mundo pequeño”



- El modelo de **Watts-Strogatz** sugiere que las redes son “pequeñas” porque incluyen tanto comunidades altamente interconectadas (con alto $\langle C \rangle$) como “enlaces débiles” (los recableados) que interconectan estas comunidades y permiten el flujo de información.



En sociología el concepto de “enlaces débiles” fue muy influyente: el artículo [“The strength of weak ties”](#) de Granovetter (1973) tiene más de 60 mil citas.

Dos visiones del “mundo pequeño”

- El modelo de **Watts-Strogatz** sugiere que las redes son “pequeñas” porque incluyen tanto comunidades altamente interconectadas (con alto $\langle C \rangle$) como “enlaces débiles” (los recableados) que interconectan estas comunidades y permiten el flujo de información.





- El modelo libre de escala de **Barabasi-Albert** sugiere que las redes son pequeñas porque incluyen nodos con de alto grado que funcionan como “hubs”.

En sociología el concepto de “enlaces débiles” fue muy influyente: el artículo [“The strength of weak ties”](#) de Granovetter (1973) tiene más de 60 mil citas.


Dos visiones del “mundo pequeño”

- Dependiendo de la organización topológica de una red, diferentes características de un nodo pueden ser más o menos importantes
- Noción de “flujo” y noción de “cohesividad”
- ¿Cómo cuantificar la importancia de un nodo?



Propiedades de los nodos. Medidas de centralidad

Definiciones



- ¿Qué tan relevante es un nodo en la red?
- De manera abstracta la **centralidad (C)** es una función que asigna un valor numérico a cada nodo de una red.
- El nodo i es más central que el nodo j si $C(i) > C(j)$.

Propiedades de los nodos. Medidas de centralidad

Definiciones



- Las medidas de centralidad sirven para caracterizar la conectividad de los nodos de una red (medidas locales o globales).
- Los valores de centralidad son relativos a una red: sólo son comparables dentro de una misma red.
- Algunas medidas de centralidad solo se pueden aplicar a redes conexas.

Propiedades de los nodos. Medidas de centralidad

Definiciones

→ ¿Qué tan relevante es un nodo en la red?

Noción de **flujo** sobre la red


Noción de **cohesividad** sobre la red

- a. Grado
- b. Intermediación
- c. Cercanía
- d. Autovalor



Propiedades de los nodos. Medidas de centralidad


Centralidad de grado



¿Cuántos vecinos tiene el nodo en cuestión?

Propiedades de los nodos. Medidas de centralidad

Centralidad de grado



Número de vecinos:
(grado del nodo)

$$C_i^D = k_i$$


Un "hub" tiene alta
centralidad de grado

Puede estar normalizado: $\overline{C_i^D} = \frac{k_i}{n - 1}$

Para grafos dirigidos se puede considerar en forma separada los grados de entrada y de salida, dando una centralidad de entrada y una de salida.

Propiedades de los nodos. Medidas de centralidad


Centralidad de grado



- Sólo utiliza información local (primeros vecinos)
- En términos de flujo:
 - caracteriza efectos de influencia inmediata (cercanía)
 - prob de recibir algo que está distribuido aleatoriamente por la red es proporcional al # de contactos.
- En términos de cohesividad:
 - Hubs proveen atajos entre pares de nodos
- Asume linealidad:
 - un nodo con el doble de vecinos que otro es dos veces más importante

Propiedades de los nodos. Medidas de centralidad

Centralidad de intermediación (betweenness)



¿Cuántos caminos mínimos dependen del nodo en cuestión?

Propiedades de los nodos. Medidas de centralidad

Centralidad de intermediación (betweenness)

Siendo $G=(V,E)$ un grafo no dirigido con i,s,t : nodos

$$C_{bet}(i) = \sum_{s \neq i} \sum_{t \neq i} \delta_{st}(i)$$


donde:

$$\delta_{st}(i) = \frac{\sigma_{st}(i)}{\sigma_{st}}$$

→ Fracción de caminos mínimos entre s y t que pasan por i

σ_{st} : número de **caminos mínimos** entre s y t .


$\sigma_{st}(i)$: número de **caminos mínimos** entre s y t que pasan por i



¡Puede haber más de uno!

Propiedades de los nodos. Medidas de centralidad

Centralidad de intermediación (betweenness)




Es una medida global

- En términos de flujo:
Mide la habilidad de un nodo de mediar las comunicaciones entre otros nodos
- En términos de cohesividad:
Quitar un nodo de alta intermediación no necesariamente rompe una red, pero hace el flujo más difícil

Propiedades de los nodos. Medidas de centralidad


Centralidad de cercanía (*closeness*)



¿Qué tan cerca está el nodo en cuestión del resto de los nodos?

Propiedades de los nodos. Medidas de centralidad

Centralidad de cercanía (*closeness*)




$$C_{\text{cer}}(i) = \frac{1}{N - 1} \sum_{i \neq j} \frac{1}{d_{ij}}$$

i, j : nodos

Es otra medida basada en la **distancia**.

Propiedades de los nodos. Medidas de centralidad

Centralidad de cercanía (*closeness*)




Es una medida global

- En términos de flujo:
 - Nodos que en promedio reciben rápidamente flujo transmitido por la red
 - Son posiciones “estratégicas” en la red

Propiedades de los nodos. Medidas de centralidad


Centralidad de autovector:



¿Qué tan centrales son los primeros vecinos del nodo en cuestión?

Propiedades de los nodos. Medidas de centralidad

Centralidad de autovector:



La importancia del nodo depende de la importancia que le proyectan sus vecinos (definición recursiva)

$$x_\nu = \frac{1}{\lambda} \sum_{t \in M(\nu)} x_t = \frac{1}{\lambda} \sum_{t \in G} a_{\nu,t} x_t$$

↑
primeros vecinos $t \rightarrow \nu$

↑
todo el grafo

Autovectores:
 $A x = \lambda x$

Siendo $G=(V,E)$ un grafo no dirigido con ν, t : nodos

$M(\nu)$: Conjunto de vecinos del nodo ν


$A = a_{\nu,t}$: Matriz de adyacencia

λ : Máximo autovalor de los autovectores de A

(sólo el autovector con máximo autovalor garantiza que $x_\nu \geq 0 \quad \forall \nu$)

Propiedades de los nodos. Medidas de centralidad

Centralidad de autovector:



La importancia del nodo depende de la importancia que le proyectan sus vecinos (definición recursiva)

$$x_\nu = \frac{1}{\lambda} \sum_{t \in M(\nu)} x_t = \frac{1}{\lambda} \sum_{t \in G} a_{\nu,t} x_t$$

↑
primeros vecinos $t \rightarrow \nu$

↑
todo el grafo

Autovectores:
 $Ax = \lambda x$

Siendo $G=(V,E)$ un grafo no dirigido con ν, t : nodos

$M(\nu)$: Conjunto de vecinos del nodo ν

$A = a_{\nu,t}$: Matriz de adyacencia

λ : Máximo autovalor de los autovalores

(sólo el autovector con máximo autovalor garantiza que $x_\nu \geq 0 \forall \nu$)

Para grafos no dirigidos A es simétrica y siempre se pueden encontrar los autovectores

Propiedades de los nodos. Medidas de centralidad

Centralidad de autovector:


¿Y qué pasa con las redes dirigidas?

Definición:

Dado un grafo dirigido $G(V,L)$ y una componente **fuertemente conexa** $S \subseteq V$:

Componente de entrada: el conjunto de nodos v que puede alcanzar cualquier nodo $\gamma \in S$ al seguir enlaces “hacia atrás” (el camino $v \rightarrow \dots \rightarrow \gamma$ existe). Es S más todos los nodos que le proyectan un enlace a S .

Componente de salida: el conjunto de nodos v alcanzable por cualquier nodo $\gamma \in S$ al seguir enlaces “hacia adelante” (el camino $\gamma \rightarrow \dots \rightarrow v$ existe). Es S más todos los nodos a los que se puede llegar desde S .



Hay un camino para llegar a cualquier nodo del componente


Propiedades de los nodos. Medidas de centralidad

Centralidad de autovector:

Problema en redes dirigidas:

- Por construcción, la centralidad de autovector está relacionada a los enlaces entrantes de un nodo.
- Solo nodos en la componente fuertemente conexa o en la componente de salida tienen una centralidad de autovector no nula (ya que todos los nodos reciben al menos un enlace de entrada).
- Nodos de la componente de entrada pueden tener centralidad de autovector nula (lo mismo ocurre para nodos que tienen enlaces entrantes provenientes de nodos con centralidad de autovector nula)

Solución de la **centralidad de Katz**: darle a todos los nodos “gratuitamente” una centralidad de autovector mínima no nula (que podrá “transferir” a otros nodos haciendo enlaces salientes hacia ellos).



Hay un camino para llegar a cualquier nodo del componente

Propiedades de los nodos. Medidas de centralidad

Correcciones a la centralidad de autovector para redes dirigidas:

Centralidad de Katz:

- Ningún nodo tendrá centralidad nula (vía β)
- Un nodo tendrá alta centralidad si sus vecinos son de alta centralidad o si recibe muchos enlaces

$$x_i = \alpha \sum_j A_{ij} x_j + \beta$$

En la práctica: $\beta = 1$; $0 < \alpha < 1/\lambda$

Propiedades de los nodos. Medidas de centralidad

Correcciones a la centralidad de autovector para redes dirigidas:

Centralidad de Katz:

- Ningún nodo tendrá centralidad nula (vía β)
- Un nodo tendrá alta centralidad si sus vecinos son de alta centralidad o si recibe muchos enlaces

$$x_i = \alpha \sum_j A_{ij} x_j + \beta$$

En la práctica: $\beta = 1$; $0 < \alpha < 1/\lambda$

Problema 2: un nodo de muy alta centralidad “contagia” un valor alto de centralidad a todos sus vecinos vía k^{out}

Propiedades de los nodos. Medidas de centralidad

Correcciones a la centralidad de autovector para redes dirigidas:

Centralidad de Katz:

- Ningún nodo tendrá centralidad nula (vía β)
- Un nodo tendrá alta centralidad si sus vecinos son de alta centralidad o si recibe muchos enlaces

$$x_i = \alpha \sum_j A_{ij} x_j + \beta$$

En la práctica: $\beta = 1$; $0 < \alpha < 1/\lambda$

Problema 2: un nodo de muy alta centralidad “contagia” un valor alto de centralidad a todos sus vecinos vía k^{out}

Centralidad de PageRank:

“Un nodo tendrá alta centralidad si **sus vecinos de alta centralidad lo conectan específicamente** o si recibe muchos enlaces”


$$x_i = \alpha \sum_j \frac{1}{k_j^{\text{out}}} A_{ij} x_j + \beta$$

Normaliza por la “promiscuidad” del nodo que lo enlaza


En la práctica: $\alpha = 0.85$

Propiedades de los nodos. Medidas de centralidad


Centralidad
de grado




Centralidad
de intermediación



Centralidad
de cercanía



Centralidad
de autovector



Para cada problema particular siempre hay que preguntarse: ¿Centralidad con respecto a qué?

Comunidades


- Clustering jerárquico:
 - Ravasz
 - Girvan/Newman betweenness
- Maximización de la modularidad
- Método de Louvain

Bibliografía adicional (optativa)

Capítulo 9 del libro online de Barabasi.

Perspectiva reciente y actualizada: “[20 years of network community detection](#)” de Fortunato & Newman, en Nature Physics, 2022

Review técnico: “[Community detection in networks: A user guide](#)” de Fortunato & Hric. en Physics Reports, 2016.




Comunidades


¿Qué es una comunidad?

Grafos



Comunidades sin superposición



Comunidades superpuestas




Matriz de adyacencia



Comunidades

¿Qué es una comunidad?


Disclaimer: comunidades superpuestas (*overlapping*) o “*soft clustering*”, un problema abierto...



Comunidades


¿Qué es una comunidad?

Visión “clásica”: Un subconjunto de nodos que están más conectados entre sí que con el resto de los nodos. Un subgrafo localmente denso en conectividad.



Comunidades


Muchas posibles definiciones de comunidades



- Poco realista
- Dentro de un clique todos los nodos son “iguales”. En comunidades reales, algunos nodos que las componen pueden ser más importantes que otros.


Comunidades

Muchas posibles definiciones de comunidades




Clique: Subgrafo completo.
Subgrafo con la máxima densidad de enlaces.

Muy restrictivo



Comunidad fuerte:

$$k_i^{\text{int}}(C) > k_i^{\text{ext}}(C) \\ \forall i \in C$$






Comunidad débil:

$$\sum_{i \in C} k_i^{\text{int}}(C) > \sum_{i \in C} k_i^{\text{ext}}(C)$$

Comunidades

Muchas posibles definiciones de comunidades



Y en función de densidades...

(definición de comunidad débil, ya que estoy viendo densidades y no nodo a nodo)

$$\left\{ \begin{array}{l} \rho_{\text{int}} > \rho \\ \rho > \rho_{\text{ext}} \end{array} \right\}$$



Detección de Comunidades

Agrupamiento jerárquico (Ravasz)

Hierarchical Organization of Modularity in Metabolic Networks

E. Ravasz,¹ A. L. Somera,² D. A. Mongru,² Z. N. Oltvai,^{2*}
A.-L. Barabási^{1*}


Identificar la topología modular
del metabolismo de la E. Coli



Science 2002


Breve tour de agrupamiento jerárquico

Ingrediente 1: matriz de similitudes




Breve tour de agrupamiento jerárquico

Ingrediente 1: matriz de similitudes



Ingrediente 2: “Linkage”

(¿cómo voy a medir distancias entre clusters?)




(a) MIN (single link.)

(b) MAX (complete link.)

(c) Group average.


Breve tour de agrupamiento jerárquico

Ingrediente 1: matriz de similitudes




Ingrediente 2: “Linkage”

(¿cómo voy a medir distancias entre clusters?)




Ingrediente 3: dendrograma
(árbol de jerarquía de similitudes)




Breve tour de agrupamiento jerárquico

Ingrediente 1: matriz de similaridades




Ingrediente 2: "Linkage"

(¿cómo voy a medir distancias entre clusters?)



Ingrediente 3: dendrograma (árbol de jerarquía de similaridades)



Detección de Comunidades

Receta agrupamiento jerárquico para detección de comunidades:

1. Se construye una matriz de similaridad de vértices a partir de la matriz de adyacencia
2. Estrategia aglomerativa: se adosan sucesivamente nodos y comunidades de alta similaridad
3. Agrupamiento jerárquico
4. El dendrograma describe el orden en el que nodos fueron agregados a comunidades. Es posible definir la partición en comunidades buscada a partir del dendrograma

Single linkage
Complete linkage
Average linkage

Similaridad en redes

Ravasz: Agrupamiento jerárquico aglomerativo de la “equivalencia estructural”

Similaridad superposición topológica (topological overlap)

¿Cuán similares son los vecinos de un par de nodos?

¿Qué proporción de vecinos en común tiene un par de nodos?


$$TO_{ij} = \frac{n_{ij} + \Theta(A_{ij})}{\min(k_i, k_j) + 1 - \Theta(A_{ij})}$$

$$\Theta(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 & \text{si } x > 0 \end{cases}$$

n_{ij} número de vecinos en común

binarización


- $TO_{ij}=1$ si i y j tienen un link entre ellos y los mismos vecinos.
- $TO_{ij}=0$ si i y j no tienen vecinos en común y tampoco link entre ellos.



Barabasi cap 9


Detección de Comunidades

Agrupamiento jerárquico aglomerativo (Ravasz)



$$TO_{ij} = \frac{n_{ij} + \Theta(A_{ij})}{\min(k_i, k_j) + 1 - \Theta(A_{ij})}$$

1. Define la matriz de similaridad (Topological overlap).
2. Decide similaridad de grupo




Science 2002

Detección de Comunidades



División jerárquica (Girvan-Newman)

Idea:
“Desagregar” comunidades
borrando iterativamente los
enlaces que las unen



Detección de Comunidades

División jerárquica (Girvan-Newman)



Define medida de centralidad de enlaces:

Link Betweenness Centrality (proporción de caminos mínimos entre los pares de nodos que atraviesen el enlace (i,j))


Va iterativamente borrando los enlaces de mayor Link Betweenness Centrality

(Obs: en cada iteración tiene que recalcular la centralidad de los enlaces... lento).

Barabasi cap 9

Detección de Comunidades

División jerárquica o Agrupamiento jerárquico
(Girvan-Newman) (Ravasz)




¿Dónde corto?

Solución:
Maximizar “modularidad”

Detección de Comunidades

Modularidad

Dada una partición en módulos (comunidades), medir el exceso de enlaces intra-modulares con respecto a un modelo nulo en la que los enlaces son aleatorizados



¿Pero cómo aleatorizamos los enlaces?

Detección de Comunidades

Modularidad de Girvan-Newman

Dada una partición en módulos (comunidades), medir el exceso de enlaces intra-modulares con respecto a un modelo nulo en la que los enlaces son aleatorizados, **manteniendo el grado original de cada nodo**

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{i,j} - \frac{k_i k_j}{2m} \right) \delta_{i,j}$$

m : número total de enlaces

A_{ij} : matriz de adyacencia

k : grado

$\delta_{i,j}$: 1 si i,j pertenecen al mismo comunidad, 0 si no.

Prob. que par de nodos de grado (k_i, k_j) tengan un enlace en el modelo nulo


Selecciona pares de nodos que pertenezcan a una misma comunidad

Barabasi cap 9


Detección de Comunidades

Modularidad de Girvan-Newman


a. OPTIMAL PARTITION
 $Q = 0.41$




b. SUBOPTIMAL PARTITION
 $Q = 0.22$



c. SINGLE COMMUNITY
 $Q = 0$



d. NEGATIVE MODULARITY
 $Q = -0.12$



$$Q = \frac{1}{2m} \sum_{i,j}^N \left(A_{i,j} - \frac{k_i k_j}{2m} \right) \delta_{i,j}$$

m : número total de enlaces

A_{ij} : matriz de adyacencia


k : grado

$\delta_{i,j}$: 1 si i,j pertenecen al mismo comunidad, 0 si no.


Q varía en el rango $[-0.5, 1]$

Detección de Comunidades

Ejemplo: cortando el dendrograma de Girvan-Newman por modularidad



También aplicable a Ravasz (dendrograma aglomerativo)



DetECCIÓN DE COMUNIDADES

Método de Louvain

Journal of Statistical Mechanics: Theory and Experiment
An IOP and SISSA journal

Fast unfolding of communities in large networks

Vincent D Blondel¹, Jean-Loup Guillaume^{1,2},
Renaud Lambiotte^{1,3} and Etienne Lefebvre¹

¹ Department of Mathematical Engineering, Université Catholique de Louvain,
4 avenue Georges Lemaitre, B-1348 Louvain-la-Neuve, Belgium

² LIP6, Université Pierre et Marie Curie, 4 place Jussieu, F-75005 Paris, France

³ Institute for Mathematical Sciences, Imperial College London,
53 Prince's Gate, South Kensington Campus, London SW7 2PG, UK
E-mail: vincent.blondel@uclouvain.be, jean-loup.guillaume@lip6.fr,
r.lambiotte@imperial.ac.uk and pixetus@hotmail.com

Received 18 April 2008

Accepted 3 September 2008

Published 9 October 2008

Método de optimización de la modularidad


Encuentra particiones de alta modularidad

Estructura jerárquica

Es muy rápido

Detección de Comunidades

Método Louvain



Paso inicial

Optimización de la modularidad


1.a Elegir un nodo al azar y calcular cambio en modularidad (ΔQ) que resultaría de juntarlo en una comunidad con cada uno de sus vecinos

1.b El nodo se junta al nodo vecino con mayor ΔQ

1.c Se repite el proceso para todos los nodos, hasta que no haya mejoría

Detección de Comunidades

Método Louvain



Paso inicial

Optimización de la modularidad

1.a Elegir un nodo al azar y calcular cambio en modularidad (ΔQ) que resultaría de juntarlo en una comunidad con cada uno de sus vecinos


1.b El nodo se junta al nodo vecino con mayor ΔQ

1.c Se repite el proceso para todos los nodos, hasta que no haya mejoría

Solo nos estamos fijando pares de nodos. ¡Es rápido!

Detección de Comunidades

Método Louvain



Segundo paso


Agregado de comunidades

2.a. Los nodos de una misma comunidad se unen en un “super” nodo que representa a la comunidad

2.b. Peso los enlaces sumando cantidad de enlaces intra- e inter-módulos

Detección de Comunidades

Método Louvain



Algoritmo

3. Repito hasta que no haya más cambios de modularidad.

Detección de Comunidades


Name	Nature	Comp.
Ravasz	Hierarchical Agglomerative	$O(N^2)$
Girvan-Newman	Hierarchical Divisive	$O(N^2)$
Greedy Modularity	Modularity Optimization	$O(N^2)$
Greedy Modularity (Optimized)	Modularity Optimization	$O(N \log^2 N)$
Louvain	Modularity Optimization	$O(L)$
Infomap	Flow Optimization	$O(N \log N)$
Clique Percolation (CFinder)	Overlapping Communities	$\text{Exp}(N)$
Link Clustering	Hierarchical Agglomerative; Overlapping Communities	$O(N^2)$

Barabasi cap 9

Detección de Comunidades

Problemas comunes a todos los métodos de Optimización de la Modularidad

- 1) Problema de “Resolución”: se tiende a agrupar pequeñas comunidades en módulos cada vez más grandes



“Solución”: repetir análisis para cada uno de los grandes módulos, y analizar subdivisiones

Detección de Comunidades

Problemas comunes a todos los métodos de Optimización de la Modularidad

- 1) Problema de “Resolución”: se tiende a agrupar pequeñas comunidades en módulos cada vez más grandes

Se puede demostrar que si unimos comunidades A y B, el cambio en la modularidad es:

$$\Delta Q_{AB} = m_{AB}/m - k_A k_B / 2m^2$$

m_{ij} : total de enlaces que unen comunidades i y j
 k_i : grado total en comunidad i

Si $k_A k_B / 2m < 1$ y tengo al menos un enlace entre comunidades A y B ($m_{AB} > 0$), entonces $\Delta Q_{AB} > 0$

Si $k_A \sim k_B = k$, entonces si $k \leq \sqrt{2m}$ las comunidades A y B siempre van a ser combinadas, incluso si son comunidades diferentes

Optimización de Modularidad siempre va a fusionar comunidades que estén bajo el umbral $k \leq \sqrt{2m}$

Detección de Comunidades

Problemas comunes a todos los métodos de Optimización de la Modularidad


- 1) Problema de “Resolución”: se tiende a agrupar pequeñas comunidades en módulos cada vez más grandes

Ejemplo “patológico”

Umbral de resolución:

$$k \leq \sqrt{2m}$$

$$m=112, k=12 \Rightarrow 12 \leq 14,97$$




Las comunidades encontradas (líneas punteadas) agrupan 2 subcomunidades (cliques de $k=12$)

Detección de Comunidades

Problemas comunes a todos los métodos de Optimización de la Modularidad

2) Problema de Modularidad Máxima

Se observa una “meseta en altura” más que un máximo único, por lo que hay muchas particiones con modularidades similares.



embedding de todas las particiones encontradas