

Tópicos de Grafos: GraphRAG

Grafos aplicados en el contexto de IA
generativa y LLMs


A large, dark blue, abstract shape that starts from the bottom left and extends diagonally upwards towards the right, covering the bottom half of the slide.

GraphRAG - “From Local to Global”

Aplicar conceptos y técnicas de **grafos** para **Retrieval-Augmented Generation (RAG)**

[Paper](#) y [Librería](#) de Microsoft Research

Es *una posible aplicación* de grafos para RAG/LLMs, **existen otras** (ej: modelado complejo como el ámbito legal, flujos de agentes, memoria)



Grandes Modelos de Lenguaje - LLMs

Modelos que generan texto de forma **autorregresiva** (más habitual)

Redes neuronales profundas basadas en alguna variación de la arquitectura de **Transformer** (Decoder)

Pre-entrenados en volúmenes masivos de texto (del orden de 10^{12} tokens)

Supervised Fine-Tuning y **Reinforcement Learning** para orientarlos a cierto tipo de tareas. Principalmente:

- Conversación
- Generación de código / salidas estructuradas
- Razonamiento y uso de herramientas

LLMs - Algunas limitaciones

Alucinaciones


Son muy buenos para predecir secuencias de texto

Sonar **VEROSÍMIL** $\neq$ Decir la verdad

Recuperación de datos puntuales

Dificultad para recuperar datos específicos o indicar su origen (citas)

Knowledge-cutoff - Son entrenados hasta cierto punto



¿Cómo hacemos si queremos citado de fuentes?

¿Y para trabajar con nuestros datos privados?

RAG: Generación Aumentada por Recuperación

1. Recuperación (Retrieval)


Busca información relevante en una base de conocimientos externa (documentos, bases de datos).

2. Aumentación (Augmented)

Combina la pregunta del usuario con los fragmentos de datos recuperados para crear un "prompt" enriquecido.

3. Generación (Generation)


El LLM genera una respuesta basada principalmente en el contexto proporcionado, reduciendo alucinaciones y permitiendo citas directas



Acá está el paso crítico

¿Cómo recuperamos?

Flujo básico de RAG




Etap 1:

Hay que indexar el contenido para que sea buscable
Pre-procesamiento

Etap 2:

Se recupera el contexto relevante y se envía al LLM junto con la consulta del usuario

RAG básico o “ingenuo” (Naive RAG)



Chunking



En la mayoría de los casos, necesito segmentar los documentos en fragmentos o **chunks**. Permite:

- Precisar la búsqueda
Embedding de un documento entero pierde especificidad semántica
- Acotar el contexto que se pasa al LLM
Si pregunto por algo particular, no necesito todo el documento

¿Por qué decimos que es ingenuo?

- **Similaridad semántica $\neq$ Relevancia**
- Top-K chunks por similaridad puede tener baja precisión/recall - **Mucho ruido**
- **Excesivamente local** - Los fragmentos están desconectados, no hay información global ni de contexto

¿Cómo lo resolvemos?

Hay múltiples caminos

GraphRAG - “From Local to Global”

Supuesto implícito de RAG “ingenuo”:

*Se supone que la respuesta esta contenida en unos pocos **pasajes locales** del corpus*

¿Qué ocurre si mi consulta es global?

Resumen, generalización, tendencias, etc.

¿Qué nombre elige Alonso Quijano para su caballo?

¿Cómo evoluciona la relación entre idealismo y realidad a lo largo de toda la novela?

GraphRAG - Ideas Principales

Puedo construir un **índice estructurado** con entidades, relaciones, comunidades y resúmenes a distintos niveles


Organizar el grafo en comunidades a distintos niveles me permite realizar una **síntesis jerárquica**

Utilizar capacidad de LLM no solo para generación, sino para **parsear** los documentos y **construir el grafo**

GraphRAG - Idea Central

Usar la modularidad del grafo para producir resúmenes que representen al corpus de forma más global que una muestra top-k.

Flujo operativo



Durante el preprocesamiento construyo el grafo, las comunidades y sus resúmenes

En la consulta genero respuestas parciales y unifico en una respuesta global

Chunk de texto

“NeoChip debutó en bolsa; antes había sido adquirida por Quantum Systems en 2016; se especializa en chips de bajo consumo para wearables e IoT.”



Entidades

- NeoChip
- Quantum Systems
- wearables
- IoT

Relaciones

- Quantum Systems → adquirió → NeoChip
- NeoChip → se especializa en → IoT/wearables

Claims / descripciones

Además del grafo, el paper considera descripciones cortas y claims factuales asociados a las entidades. Eso enriquece la representación que luego se resume a nivel comunidad.

Construcción del Grafo

Entidades detectadas se vuelven **Nodos**

Relaciones detectadas se vuelven **Enlaces**

Relaciones duplicadas pueden ser tomadas como **Peso** de los enlaces

Se extraen **descripciones y “claims”** (afirmaciones) que se agregan como metadatos, usados al momento de resumir la información

No importa solo qué documentos hablan de algo, sino qué entidades coaparecen y cómo se conectan.

Conceptos de Grafos aplicados - Detección de comunidades

Una vez extraído el grafo del corpus, se construyen **comunidades** de forma recursiva utilizando el algoritmo de Leiden, optimizando la **modularidad**

Se divide el grafo en comunidades. Para cada una de esas comunidades se vuelve a correr el algoritmo para detectar **sub-comunidades**. Esto se realiza de manera recursiva hasta que las comunidades ya no se puedan volver a dividir

Estrategia de divide-and-conquer

Leiden vs Louvain

El algoritmo de Leiden es una “versión mejorada” de Louvain, que aborda el problema de la topología interna de las comunidades

Después de una primera partición “provisoria”, Leiden no acepta esa comunidad tal como quedó. En cambio, entra dentro de cada comunidad y pregunta:

“¿Esta comunidad realmente tiene una estructura interna coherente, o en realidad es una mezcla de subgrupos pegados débilmente?”

Paso de Refinamiento

Leiden vs Louvain

Después del movimiento local, cada comunidad obtenida se refina **internamente**:


- se revisa si dentro de una comunidad hay subconjuntos que deberían separarse,
- se permite reagrupar partes de la comunidad de forma más consistente,
- se evita que una comunidad quede mal conectada o armada de forma “artificial”.

Este refinamiento hace que las comunidades resultantes sean **más sólidas**.

Leiden - Ciclo completo

1. Mover nodos localmente
2. Refinar comunidades
3. Agregar comunidades en un nuevo grafo
4. Repetir

hasta que ya no hay mejoras.



Más abajo = más
detalle.
Más arriba = más
cobertura.
La jerarquía permite
elegir el nivel.

Nivel 1 / global

Resumen más amplio del
corpus

Nivel 2

Resumen de comunidad

Nivel 2

Resumen de comunidad

Nivel 3

Subtema específico

Nivel 3

Subtema específico

Nivel 3

Subtema específico

Nivel 3

Subtema específico

Conceptos de Grafos aplicados - Centralidad de Grado

Nodos con **mayor cantidad de conexiones** suelen representar entidades más “prominentes” dentro del corpus.

Para generar resúmenes de comunidades en los niveles inferiores, se priorizan los enlaces cuyos nodos tengan **mayor centralidad de grado** (hasta que se alcanza el límite de tokens).

En los niveles superiores simplemente se resume de forma recursiva

Momento de Consulta

Puedo elegir distintos niveles de jerarquía para responder a la pregunta

Elección de **granularidad**



Momento de Consulta



Map

Cada resumen de comunidad produce una respuesta parcial a la consulta.

Score + filtro

El LLM además estima cuán útil fue cada respuesta parcial; las de score 0 se descartan.

Reduce

Las mejores respuestas parciales se combinan y se vuelven a resumir en una respuesta global.

Resultados de Experimentos (paper)

Podcast transcripts

	SS	TS	C0	C1	C2	C3
SS	50	17	28	25	22	21
TS	83	50	50	48	43	44
C0	72	50	50	53	50	49
C1	75	52	47	50	52	50
C2	78	57	50	48	50	52
C3	79	56	51	50	48	50

	SS	TS	C0	C1	C2	C3
SS	50	18	23	25	19	19
TS	82	50	50	50	43	46
C0	77	50	50	50	46	44
C1	75	50	50	50	44	45
C2	81	57	54	56	50	48
C3	81	54	56	55	52	50

	SS	TS	C0	C1	C2	C3
SS	50	42	57	52	49	51
TS	58	50	59	55	52	51
C0	43	41	50	49	47	48
C1	48	45	51	50	49	50
C2	51	48	53	51	50	51
C3	49	49	52	50	49	50

	SS	TS	C0	C1	C2	C3
SS	50	56	65	60	60	60
TS	44	50	55	52	51	52
C0	35	45	50	47	48	48
C1	40	48	53	50	50	50
C2	40	49	52	50	50	50
C3	40	48	52	50	50	50

Comprehensiveness

Diversity

Empowerment

Directness

News articles

	SS	TS	C0	C1	C2	C3
SS	50	20	28	25	21	21
TS	80	50	44	41	38	36
C0	72	56	50	52	54	52
C1	75	59	48	50	58	55
C2	79	62	46	42	50	59
C3	79	64	48	45	41	50

	SS	TS	C0	C1	C2	C3
SS	50	33	38	35	29	31
TS	67	50	53	45	44	40
C0	62	47	50	40	41	41
C1	65	55	60	50	50	50
C2	71	56	59	50	50	51
C3	69	60	59	50	49	50

	SS	TS	C0	C1	C2	C3
SS	50	47	57	49	50	50
TS	53	50	58	50	50	48
C0	43	42	50	42	45	44
C1	51	50	58	50	52	51
C2	50	50	55	48	50	50
C3	50	52	56	49	50	50

	SS	TS	C0	C1	C2	C3
SS	50	54	59	55	55	54
TS	46	50	55	53	52	52
C0	41	45	50	48	48	47
C1	45	47	52	50	49	49
C2	45	48	52	51	50	49
C3	46	48	53	51	51	50

Comprehensiveness

Diversity

Empowerment

Directness

Podcast Transcripts					
	C0	C1	C2	C3	TS
Units	34	367	969	1310	1669
Tokens	26657	225756	565720	746100	1014611
% Max	2.6	22.2	55.8	73.5	100

News Articles				
C0	C1	C2	C3	TS
55	555	1797	2142	3197
39770	352641	980898	1140266	1707694
2.3	20.7	57.4	66.8	100

Ventajas y Desventajas

Este enfoque pareciera mejorar la capacidad de **responder a preguntas globales** en detrimento del contexto local específico.

Permite reducir el **volumen de tokens** sobre el que se trabaja, pero con mayores costos de procesamiento (tanto en tiempo como en dinero)

Frente a un RAG vectorial mejora (*en las evaluaciones del paper) en **Comprensividad y Diversidad**, pero el vectorial suele ser un poco **más directo** (“directness”)

Limitaciones y Riesgos

- La calidad depende de la **extracción** de entidades, relaciones y claims.
- **Entity resolution** imperfecto puede duplicar nodos o fragmentar conceptos.
- Construir el índice **cuesta tiempo, tokens y dinero**.
- Puede **perder detalle local fino** si el resumen de comunidad lo abstrae demasiado.
- Como cualquier pipeline con LLM, sigue existiendo riesgo de **errores o alucinaciones**. Sigue sin ser determinístico

Limitaciones del Paper

La evaluación se concentra en dos corpora del orden del millón de tokens.
Trabaja con preguntas globales generadas por LLM.

Falta entender mejor la generalización a otros dominios y otros criterios.

¿Cuándo lo usaría?


Sí conviene

Corpus grande, heterogéneo y relativamente estable
Muchas preguntas globales sobre el mismo dataset
Importan cobertura, diversidad y estructura temática
Vale la pena pagar indexado más costoso

No necesariamente

Preguntas mayormente locales o factuales
Corpus chico o muy cambiante
Presupuesto ajustado de indexado
Se necesita máxima precisión sobre pasajes concretos

Otras formas de usar grafos para LLM



Survey Paper sobre GraphRAG y sus variantes: <https://arxiv.org/pdf/2501.00309>

LangGraph: orquestación de agentes con LLMs a bajo nivel. Permite definir flujos con Nodos y Enlaces que conectan ejecuciones de LLMs, gestionar estado, memoria y más

<https://docs.langchain.com/oss/python/langgraph/overview>



Base de datos orientada a Grafos, con aplicaciones para KG y Memoria basada en grafos

<https://neo4j.com/use-cases/ai-systems/>