


Grafos (parte 4/3)

Tópicos avanzado de grafos
Stochastic Block Model



¿Qué vimos hasta ahora?

- Sistemas complejos como grafos




¿Qué vimos hasta ahora?

- Sistemas complejos como grafos
- Topología y medidas de centralidad






¿Qué vimos hasta ahora?

- Sistemas complejos como grafos
- Topología y medidas de centralidad
- Modelos de redes



¿Qué vimos hasta ahora?

- Sistemas complejos como grafos
- Topología y medidas de centralidad
- Modelos de redes
- Comunidades



Stochastic Block Model

De heurísticas a modelos generativos


- ¿qué es una comunidad y cómo la modelamos?
- ¿heurísticas o modelos probabilísticos?
- ¿optimizar o tratar de entender la naturaleza de los datos?

Bibliografía:

- B. Karrer, M.E.J. Newman, *Phys. Rev. E* 2011, 83.
- M.E.J. Newman, *Phys. Rev. E* 2016, 94.
- T.P. Peixoto, *Phys. Rev. E* 2017, 95.
- T.P. Peixoto, 2023.

¿Qué es una comunidad?

- Grupo de nodos más conectados entre sí que con el resto
- Definición informal, una por cada algoritmo
- No hay una única noción universal





Enfoque clásico: maximizar modularidad

- Mide densidad intra vs inter comunidad
- Base de métodos como Louvain
- Problemas
 - Detección de comunidades en redes aleatorias
 - Límite de resolución
 - No explica la naturaleza de los datos

$$Q = \frac{1}{2m} \sum_{ij} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta_{b_i b_j}$$


De optimizar particiones a explicar los datos

- No buscamos la mejor partición
- Buscamos un modelo que explique la red
- El enfoque es de modelos generativos



Stochastic Block Model: lo básico

- Nodos pertenecen a bloques
- La probabilidad de conexión depende del bloque
- Es un modelo probabilístico del grafo





Stochastic Block Model: lo básico

- Nodos pertenecen a bloques
- La probabilidad de conexión depende del bloque
- Es un modelo probabilístico del grafo

inferir

$$P(A|k, e, b)$$
$$P(b|A)$$


grafo
grado
con. blo.
bloques




¿Cómo se genera una red?

Esquemáticamente, se puede pensar el problema como:

- Generación en etapas
- Variables latentes intermedias
- Problema factorizado




(a) Node partition, $P(\mathbf{b})$.



(b) Edge counts, $P(\mathbf{e}|\mathbf{b})$.



(c) Degrees, $P(\mathbf{k}|\mathbf{e}, \mathbf{b})$.



(d) Network, $P(\mathbf{A}|\mathbf{k}, \mathbf{e}, \mathbf{b})$.


¿Cómo se genera una red?

Esquemáticamente, se puede pensar el problema como:


- Generación en etapas
- Variables latentes intermedias
- Problema factorizado

inferir $\curvearrowright$

$$P(A|k, e, b) \overbrace{P(k|e, b)P(e|b)P(b)}^{\text{necesito}} \\ P(b|A)$$




(a) Node partition, $P(b)$.



(b) Edge counts, $P(e|b)$.






(c) Degrees, $P(k|e, b)$.



(d) Network, $P(A|k, e, b)$.

Paso 1: partición de los nodos

- Cada nodo, un bloque
- Conlleva definir cantidad de particiones y otras cuestiones




Paso 2: conexión entre bloques

- Conteo de enlaces entre bloques
- Define una estructura global
- Permite reducir la complejidad del algoritmo



(a) Node partition, $P(b)$.



(b) Edge counts, $P(e|b)$.




(c) Degrees, $P(k|e, b)$.



(d) Network, $P(A|k, e, b)$.


Paso 3: grados de los nodos

- Distribución de grado dentro de bloques
- Habilita heterogeneidad
- Establece la corrección por grado del SBM (análogamente al término de modularidad)




Paso 4: red observada

- Realización concreta del modelo
- Sometida a las restricciones previas
- Es la que nos permite escribir matemáticamente la red realmente observada




(a) Node partition, $P(b)$.



(b) Edge counts, $P(e|b)$.



(c) Degrees, $P(k|e, b)$.



(d) Network, $P(A|k, e, b)$.

De optimización a ciegas a inferir estadísticamente

- Con métodos como Louvain, Infomap y otros, optimizamos **funciones ad-hoc** (modularidad)
- Con el SBM, **inferimos variables** latentes del modelo
- El objetivo es encontrar **la partición más probable** dado el grafo observado

De optimización a ciegas a inferir estadísticamente

- Con métodos como Louvain, Infomap y otros, optimizamos **funciones ad-hoc** (modularidad)
- Con el SBM, **inferimos variables** latentes del modelo
- El objetivo es encontrar **la partición más probable** dado el grafo observado
- Observamos red **A**
- Buscamos partición **b**
- Maximizamos **$P(b|A)$**
- Equivalencia con maximizar verosimilitud penalizando por complejidad

Relación con modularidad

- Definiendo analíticamente $P(A|k, e, b)$

y tomando su logaritmo, se obtiene la expresión

$$\mathcal{L}(A|k, e, b) = \frac{1}{2} \sum_{ij} A_{ij} \log e_{b_i b_j} - \frac{k_i k_j}{2m} e_{b_i b_j}$$

Relación con modularidad

- Definiendo analíticamente $P(A|k, e, b)$

y tomando su logaritmo, se obtiene la expresión

$$\mathcal{L}(A|k, e, b) = \frac{1}{2} \sum_{ij} A_{ij} \log e_{b_i b_j} - \frac{k_i k_j}{2m} e_{b_i b_j}$$

- El planted partition model es un caso especial donde

$$e_{rs} = \begin{cases} e_{in} & \text{si } r=s \\ e_{out} & \text{si } r \neq s \end{cases}$$

e _{in}	e _{out}	e _{out}	e _{out}
e _{out}	e _{in}	e _{out}	e _{out}
e _{out}	e _{out}	e _{in}	e _{out}
e _{out}	e _{out}	e _{out}	e _{in}

Relación con modularidad

- Definiendo analíticamente $P(A|k, e, b)$

y tomando su logaritmo, se obtiene la expresión

$$\mathcal{L}(A|k, e, b) = \frac{1}{2} \sum_{ij} A_{ij} \log e_{b_i b_j} - \frac{k_i k_j}{2m} e_{b_i b_j}$$

- El planted partition model es un caso especial donde

$$e_{rs} = \begin{cases} e_{in} & \text{si } r=s \\ e_{out} & \text{si } r \neq s \end{cases} \quad \Rightarrow \quad \mathcal{L}(A|k, e, b) = B \frac{1}{2m} \sum_{ij} \left(A_{ij} - \gamma \frac{k_i k_j}{2m} \right) \delta_{b_i b_j} + C$$

e _{in}	e _{out}	e _{out}	e _{out}
e _{out}	e _{in}	e _{out}	e _{out}
e _{out}	e _{out}	e _{in}	e _{out}
e _{out}	e _{out}	e _{out}	e _{in}

$$\gamma = \frac{e_{in} - e_{out}}{\log e_{in} - \log e_{out}}$$

Relación con modularidad

- Definiendo analíticamente $P(A|k, e, b)$

y tomando su logaritmo, se obtiene la expresión

$$\mathcal{L}(A|k, e, b) = \frac{1}{2} \sum_{ij} A_{ij} \log e_{b_i b_j} - \frac{k_i k_j}{2m} e_{b_i b_j}$$

- El planted partition model es un caso especial donde

$$e_{rs} = \begin{cases} e_{in} & \text{si } r=s \\ e_{out} & \text{si } r \neq s \end{cases} \quad \Rightarrow$$

$$\mathcal{L}(A|k, e, b) = B \frac{1}{2m} \sum_{ij} \left(A_{ij} - \gamma \frac{k_i k_j}{2m} \right) \delta_{b_i b_j} + C$$

e _{in}	e _{out}	e _{out}	e _{out}
e _{out}	e _{in}	e _{out}	e _{out}
e _{out}	e _{out}	e _{in}	e _{out}
e _{out}	e _{out}	e _{out}	e _{in}

¡ES LA MODULARIDAD!

$$\gamma = \frac{e_{in} - e_{out}}{\log e_{in} - \log e_{out}}$$

Ejemplos – <https://shorturl.at/PSJyj>

Comunidades espurias en ER




Ejemplos – <https://shorturl.at/PSJyj>

Comunidades espurias en ER




Diferencias entre degree corrected (dc) y non dc



¿Qué llevarnos entonces del SBM?


- Detectar comunidades no es un problema de optimización arbitraria, por eso **modularidad puede fallar**
- El **SBM** permite modelar redes como **procesos generativos**, evitando sobreajustar el ruido
- La inferencia busca la **partición más probable dado los datos**, pero es importante el modelo que tengamos sobre los mismos
- A veces, modelar es más informativo que sólo optimizar

Description




A face


Explanation



A mountain



A network with 13 communities



A random network with a prescribed degree sequence, and no community structure.