

Reducción de dimensionalidad




¿Qué entendemos por dimensionalidad de un conjunto de datos?

¿Qué entendemos por dimensionalidad de un conjunto de datos?

3 muestras

6 atributos

	p ₁	p ₂	p ₃	p ₄	p ₅	p ₆
n ₁						
n ₂						
n ₃						




¿Qué entendemos por dimensionalidad de un conjunto de datos?

3 muestras

6 atributos

	p ₁	p ₂	p ₃	p ₄	p ₅	p ₆
n ₁						
n ₂						
n ₃						

Dimensionalidad = 6




Dimensionalidad = 3

La famosa “maldición de la dimensionalidad” (*curse of dimensionality*)

La famosa “maldición de la dimensionalidad” (*curse of dimensionality*)

Clasificando imágenes de gatitos y perritos: el efecto de la dimensionalidad de los atributos considerados

Exijamos que el tamaño de nuestra muestra abarque el **20%** del espacio total de atributos




Necesito cada vez más datos. Si no, a un tamaño de muestra fija, agregar atributos resulta en un muestreo cada vez más escaso (*sparse*)

La famosa “maldición de la dimensionalidad” (*curse of dimensionality*)

Además, la escasez es más pronunciada en el centro del espacio de atributos

Círculo inscrito en el cuadrado 2D de volumen 1



Empecemos en 2D:


Todos los puntos dentro de una distancia unitaria al centro del espacio de atributos están dentro de un **círculo unitario que inscribe el cuadrado unitario**.

(Observación: Los “atributos promedio” de una clase tenderán a estar cerca del centro del espacio, por lo que es una zona importante para la clasificación)

La famosa “maldición de la dimensionalidad” (*curse of dimensionality*)

Además, la escasez es más pronunciada en el centro del espacio de atributos




Volúmen de una hiperesfera de radio 1 en dimensión d



Observación: el cubo de lado 1 en dimensión d sigue teniendo volúmen 1 (volúmen= 1^d)

La famosa “maldición de la dimensionalidad” (*curse of dimensionality*)

Además, la escasez es más pronunciada en el centro del espacio de atributos



Hipercubo en 8D con $2^8=256$ esquinas

La famosa “maldición de la dimensionalidad” (*curse of dimensionality*)


Además, la escasez es más pronunciada en el centro del espacio de atributos

A medida que aumenta la dimensión, la mayoría de las muestras van a caer en las esquinas del espacio de atributos, fuera de la hiperesfera (para 8D será el 98% de las muestras)

Como resultado, las distancias al origen (dist) cumplen:

$$\lim_{d \rightarrow \infty} \frac{\text{dist}_{\max} - \text{dist}_{\min}}{\text{dist}_{\min}} \rightarrow 0$$

Las medidas comienzan a perder su efectividad para medir la disimilitud en espacios altamente dimensionales.



Hipercubo en 8D con $2^8=256$ esquinas


La famosa “maldición de la dimensionalidad” (*curse of dimensionality*)

Referencias: [Surprises in high dimensions](#)
[The Curse of Dimensionality in Classification](#)

La famosa “maldición de la dimensionalidad” (*curse of dimensionality*)

- Familia de fenómenos “problemáticos” en espacios de muy alta dimensionalidad.
- En un espacio de f atributos, el volumen en este espacio crece como potencia de f (orden O^f).
- Cuando la dimensionalidad aumenta, el volumen del espacio aumenta tan rápidamente que los datos representados quedan muy dispersos (*sparse*).
- La cantidad de datos necesarios para analizar estos espacios crece exponencialmente con la dimensionalidad.
- En espacios de alta dimensionalidad todos los puntos tienden a ser distantes (disímiles) entre sí, lo que dificulta encontrar organización o estructura en los datos.
- También aumenta la tendencia a la multicolinearidad (que algunos atributos sean correlacionados entre sí) dificultando regresiones.


Incluir más atributos no siempre mejora la performance



<https://www.visiondummy.com/>

¿Qué es la reducción de dimensionalidad?

- Técnica utilizada para reducir el número de atributos (*features*) en un conjunto de datos, manteniendo la mayor cantidad de información posible de los datos originales.
- Proceso para transformar datos de alta dimensionalidad hacia un espacio de menor dimensionalidad que preserva la “esencia” de los datos originales.



Ventajas

- Menos atributos se traduce en menor complejidad
- Reducción de “ruido” o redundancias, lo que reduce el *overfitting*
- Reducción de espacio de almacenamiento (data compression)
- Menores tiempos de cómputo
- La precisión de los modelos puede aumentar al eliminar datos irrelevantes/engañosos
- Mejora la visualización de los datos

Desventajas

- Podemos perder información, potencialmente afectando el análisis
- Puede requerir mucho poder de cómputo, dependiendo de la técnica
- La interpretación de atributos transformados puede ser compleja o imposible

Usos típicos

- Visualización, compresión y/o filtrado de datos
- Pre-visualización para justificar la “clusterabilidad” de un dato
- Post-visualización para evaluar la calidad de resultados de un clustering
- Entender la estructura “latente” de los datos (*manifold learning*)
- Regresión y clasificación de datos en espacio de menor dimensionalidad

Dos familias de técnicas de reducción de dimensionalidad



- Selección de atributos (*feature selection*): donde se selecciona un subconjunto de los atributos originales que resulten más relevantes para el problema a resolver. Una especie de “filtrado” que descarte atributos que no sean informativos.
- Extracción de atributos (*feature extraction*): donde se crea un conjunto de nuevos atributos mediante la combinación o transformación de atributos originales, siempre que este nuevo conjunto sea de menor dimensionalidad que el original.

Modelos lineales: la piedra fundamental de la reducción de dimensionalidad

Principal Component Analysis




Modelos lineales: la piedra fundamental de la reducción de dimensionalidad

Principal Component Analysis



Modelos lineales: la piedra fundamental de la reducción de dimensionalidad

Principal Component Analysis



$$D_3^2 = D_1^2 + D_2^2$$

initial variance = remaining variance + lost variance

Insight:

D_3 es constante así que, si maximizo D_1 , estoy minimizando D_2



Modelos lineales: la piedra fundamental de la reducción de dimensionalidad

Dos visiones de PCA:

a) Rotación ortogonal de los datos hacia nuevos atributos (PCs) de máxima varianza


b) Mejor aproximación posible a los datos (cuadrados mínimos) en un subespacio de menor dimensión obtenido mediante una rotación ortogonal

- No distorsiona los datos. Se puede ir y volver entre las diferentes representaciones (sin perder info si mantiene todos los autovectores)
- Se pueden computar los PCs usando Singular Value Decomposition (SVD) que es más rápido y estable numéricamente (ver colab).



Cuando los datos viven en variedades curvas las técnicas lineales fallan


Variedad: objeto geométrico que generaliza la noción intuitiva de “curva” (1-variedad) y de “superficie” (2-variedad) a cualquier dimensión. Una variedad de n dimensiones (n -variedad) se parece localmente a un espacio euclideo de n dimensiones.



Aprendizaje de variedades (*manifold learning*)


Intento de generalizar técnicas de reducción de dimensionalidad lineales para que sean sensibles a la estructura no lineal de los datos.

Típicamente es un problema no supervisado



Multidimensional Scaling (MDS)

- MDS busca una representación de menor dimensionalidad que respete la distancias originales **entre pares de puntos** de la mejor manera posible.
- Trabaja sobre una serie de datos de **distancias entre puntos** (opuesto a similaridad).
- Uno pre-establece la dimensión del espacio al que quiere llegar.
- Hay datos que sólo se pueden interpretar naturalmente como distancias. Por ejemplo similaridad entre palabras o distancias entre ciudades.



Multidimensional Scaling (MDS)


$$Stress(X) = \sum_{i < j \leq n} w_{ij} (d_{ij}(X) - \delta_{ij})^2$$

Donde δ_{ij} son las distancias en el espacio original, $d_{ij}(X)$ las distancias en el nuevo espacio en base a los punto X y w_{ij} un conjunto de pesos que sirven para penalizar información sobre pares de puntos.

- Dos grandes ramas: la métrica (respeta identidad, simetría, y desigualdad triangular; por ej. distancias entre ciudades) y la no métrica (por ej. “distancias afectivas”). En el caso métrico se trata de preservar las distancias originales, mientras que en la no métrica el orden (ranking) de estas distancias.
- Para el caso más básico llamado Classic Euclidean (Torgerson') MDS tenemos resultado analítico, ya que se resuelve vía PCA en matriz de disimilaridades.
- También hay soluciones iterativas que tratan de reducir el *stress*, y son generales para cualquier tipo de MDS. Es lo que usa scikitlearn.


Isomap

- Se basa en una representación de los datos en forma de grafos
- A cada punto se lo conecta con sus vecinos más próximos, y así se arma un grafo.
- Distancia entre dos puntos no se la define en el espacio original de datos, sino como la distancia mínima que conecta esos dos puntos en el grafo (la *geodésica*).



Isomap

- De esta manera recuperamos una información de la geometría de la variedad sobre la que yacen los puntos: Recorremos “caminos” sobre la variedad.
- El parámetro crítico es el número de vecinos: no debe permitir “saltos” en la variedad.




t-distributed Stochastic Neighbor Embedding (t-SNE)

- t-SNE busca crear una proyección a un espacio de dimensión menor tratando de **preservar la distribución de distancias en el espacio original**, manteniendo los agrupamientos locales.
- A diferencia de MDS que trabaja en distancia de pares, t-SNE trabaja con toda la distribución de distancias y preserva mejor la estructura global de los datos

Previene que se me solape todo en el centro, forzando que lo dissimilar se aleje

$$p_{j|i} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|\mathbf{x}_i - \mathbf{x}_k\|^2 / 2\sigma_i^2)},$$
$$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq i} (1 + \|\mathbf{y}_i - \mathbf{y}_k\|^2)^{-1}}$$



t-distributed Stochastic Neighbor Embedding (t-SNE)

Se hacen simétricas las distribuciones $p_{ij} = \frac{p_{j|i} + p_{i|j}}{2N}$ y se mide la divergencia KL

$$KL(P||Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

“ $KL(P || Q)$ es una medida de cuánto la distribución P es diferente de la distribución Q ”

Nos queda determinar el parámetro σ . Para ello, vamos a usar el parámetro clave de t-SNE, que es la *perplexity*:

t-distributed Stochastic Neighbor Embedding (t-SNE)

Se hacen simétricas las distribuciones $p_{ij} = \frac{p_{j|i} + p_{i|j}}{2N}$ y se mide la divergencia KL

$$KL(P||Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

“ $KL(P || Q)$ es una medida de cuánto la distribución P es diferente de la distribución Q ”

Nos queda determinar el parámetro σ , que fija el tamaño del vecindario local a tomar en cuenta. Para ello, vamos a usar el parámetro clave de t-SNE, que es la *perplexity*:


Uno de los parámetros libres de TSNE es la *perplexity* que mide en cierta forma la cantidad de vecinos que se consideran. Sirve para calcular para cada punto la desviación σ en base a la fórmula: $Perp(p_i) = 2^{-\sum_j p_{j|i} \log_2 p_{j|i}}$

Tira los puntos en baja dimensión con una inicialización determinada, y va moviendo de a un punto, viendo si KL disminuye y continúa esta iteración por descenso por gradiente.

Por lo tanto es lento, y escala mal con el número de datos.

t-distributed Stochastic Neighbor Embedding (t-SNE)

6000 dígitos de MNIST



t-SNE




Isomap

Van der Maaten & Hinton, 2008

t-distributed Stochastic Neighbor Embedding (t-SNE)

2 clusters, 50 puntos por cluster en 50 dimensiones reducidos a 2 dimensiones

<https://distill.pub/2016/misread-tsne>




Perplexity mide el balance entre la atención a lo local o a lo global, es proporcional al número de vecinos que tiene un punto

t-distributed Stochastic Neighbor Embedding (t-SNE)

2 clusters gaussianos, uno 10x más compacto que el otro

<https://distill.pub/2016/misread-tsne>




Ecualización de densidad de puntos: en t-SNE la noción de distancia se adapta a la densidad de puntos local. Tiende a homogeneizar tamaño de clusters.

El tamaño del cluster en t-SNE no significa nada

t-distributed Stochastic Neighbor Embedding (t-SNE)

3 clusters gaussianos, uno más lejos que los otros

<https://distill.pub/2016/misread-tsne>




¿será por acá?

t-distributed Stochastic Neighbor Embedding (t-SNE)

<https://distill.pub/2016/misread-tsne>

Aumentamos de 50 a 200 puntos por cluster → tenemos que aumentar perplexity




Mala noticia: la geometría global requiere un “calibrado fino” de la perplexity. Además, perplexity es un único parámetro global: los datos del mundo real probablemente tendrían múltiples grupos con diferentes números de elementos. Puede que no haya un valor de perplexity que capture las distancias entre todos los grupos, lo que llevaría a una distorsión de la geometría de los datos

t-distributed Stochastic Neighbor Embedding (t-SNE)

<https://distill.pub/2016/misread-tsne>

500 puntos en 100 dimensiones describiendo una gaussiana



Original



Perplexity: 2
Step: 5,000



Perplexity: 5
Step: 5,000



Perplexity: 30
Step: 5,000



Perplexity: 50
Step: 5,000



Perplexity: 100
Step: 5,000

Puede “alucinar estructura” que no existe. Cuidado con las granulosidades.

Uniform Manifold Approximation and Projection (UMAP)


- UMAP es similar a t-SNE pero **más eficiente** computacionalmente, y puede resolver mejor **geometrías globales**.
- Construye un grafo de los datos en alta dimensión, y luego optimiza una representación en baja dimensión cuyo grafo sea lo más similar posible al de alta dimensión.
- En vez de usar perplexity para controlar la extensión de la vecindad **fijamos el número de vecinos de antemano**
- El grafo en alta dimensión es un **grafo pesado**, donde el peso del vértice representa la probabilidad de que dos puntos estén conectados
- Para establecer la conectividad, de cada punto hace crecer una esfera, y conecta puntos cuando sus esferas se tocan. El radio de esta esfera está determinado por el número de primeros vecinos que voy a elegir. De esta forma, el radio se define localmente.
- El peso del vértice disminuye a medida que necesito una esfera más grande.
- Cada punto tiene aunque sea un primer vecino, lo que **fuerza conexión global de la red**.

<https://pair-code.github.io/understanding-umap/>

Uniform Manifold Approximation and Projection (UMAP)

- Luego construye un **grafo de baja dimensión** de una manera similar a t-SNE, pero con trucos que lo hacen **más rápido**.
- La parte importante es entender el primer grafo de alta dimensión.
- El **parámetro clave es el número de primeros vecinos** que fijamos. Controla el balance entre local y global.
- El otro parámetro es `min_dist`, que es la distancia mínima de los puntos en baja dimensionalidad. Controla cuán solapadas quedan las representaciones de baja dimensión.
- A pesar de ser estocástico es **más confiable** (resultados se reproducen más que con t-SNE) por el énfasis en lo global.
- Como en t-SNE, el tamaño de los clusters puede no significar nada.

Uniform Manifold Approximation and Projection (UMAP)



Uniform Manifold Approximation and Projection (UMAP)

