

Clustering (parte 2/3)

Medidas de Distancias y Similaridades

Medidas de Proximidad, Disimilaridad, Similitud, Distancias

([http://www.iiisci.org/journal/CV\\$/sci/pdfs/GS315JG.pdf](http://www.iiisci.org/journal/CV$/sci/pdfs/GS315JG.pdf))

- Distancias para atributos continuos:
 - métricas de Minkowski: Manhattan (L1), Euclídea (L2), ...
 - distancia Canberra
 - distancia de Mahalanobis
- Similitudes para atributos continuos:
 - similaridad coseno
 - Correlación de Pearson
- Similitudes/Distancias para atributos categóricos binarios:
 - Coeficiente de coincidencias
 - Coeficiente de Jaccard
- Atributos multiestado (categóricas de varios estados, ordinales o no)
- Mixtos
- ...

Atributos o Variables

	p ₁	p ₂	p ₃	p ₄	p ₅	p ₆
n ₁						
n ₂						
n ₃						

Muestras

Consideraciones generales sobre disimilaridades y similitudes

A dark blue diagonal gradient bar that starts from the bottom left and extends towards the top right, covering the lower half of the slide.

Matrices de Disimilaridad

Representan relaciones entre los N elementos del conjunto, entonces son matrices de $N \times N$.

Las matrices de disimilaridad (**D**) deben cumplir con varias propiedades:


- Las disimilaridades solo pueden ser mayores o iguales que cero, $d(a,b) \geq 0$.
- La disimilaridad de dos objetos idénticos (un objeto consigo mismo) es cero, $d(a,a) = 0$.
- Los objetos pueden ser distinguibles o no.
 - Si $a \neq b$ entonces $d(a,b) > 0$. (Distinguibles)
 - Si $a = b \Leftrightarrow d(a,b) = 0$. (No distinguibles)
- Las medidas de disimilaridad son simétricas: $d(a, b) = d(b, a)$.

Matrices de Disimilaridad

Representan relaciones entre los N elementos del conjunto, entonces son matrices de N x N.

- Para que la desigualdad sea **métrica**, además debe cumplir la **desigualdad triangular**:

$$d(a,b) \leq d(a,c) + d(c,b) \quad \text{“El camino más corto entre a y b es un camino recto”}$$




Matrices de Disimilitud

Representan relaciones entre los N elementos del conjunto, entonces son matrices de N x N.


- Para que la desigualdad sea **métrica**, además debe cumplir la **desigualdad triangular**:

$$d(a,b) \leq d(a,c) + d(c,b) \quad \text{“El camino más corto entre a y b es un camino recto”}$$



Principio de arquímedes

“Un camino recto largo lo puedo dividir en pasos rectos más cortos”



Colapso el triángulo


Matrices de Disimilaridad

Representan relaciones entre los N elementos del conjunto, entonces son matrices de N x N.

- Cuando la medida de disimilitud no cumple con la desigualdad triangular, pero satisface la **desigualdad triangular fuerte**:

$$d(a, b) \leq \max\{d(a, c), d(c, b)\}$$

entonces tenemos una **matriz de disimilaridad ultramétrica**.




Matrices de Disimilaridad

Representan relaciones entre los N elementos del conjunto, entonces son matrices de N x N.

- Cuando la medida de disimilitud no cumple con la desigualdad triangular, pero satisface la **desigualdad triangular fuerte**:

$$d(a, b) \leq \max\{d(a, c), d(c, b)\}$$

entonces tenemos una **matriz de disimilaridad ultramétrica**.




No es válido el principio de Arquímedes

Matrices de Disimilaridad

Desigualdad triangular fuerte

$$d(a, b) \leq \max\{d(a, c), d(c, b)\}$$


Un árbol que se bifurca es ultramétrico



$$d(a, b) = d(a, c)$$

Dendrograma

(árbol de jerarquía de similitudes)



Las disimilaridades en un dendrograma son ultramétricas

Matrices de Disimilaridad


Desigualdad triangular fuerte

$$d(a, b) \leq \max\{d(a, c), d(c, b)\}$$

Linkages:

- Los métodos “Single” (min), “Complete” (max), y “Average” requieren que las distancias sean no negativas y simétricas.
- Los métodos “Ward” y “Centroid” necesitan distancias euclídeas para producir resultados que sean significativos y consistentes.

Dendrograma (árbol de jerarquía de similitudes)



Las disimilaridades en un dendrograma son ultramétricas

Métrico vs No Métrico en la práctica del Clustering

- En la práctica las propiedades métricas de una distancia no son necesarias para hacer clustering.
- Por ej., cuando trabajamos con datos reales no podemos exigir $d(a,b)=0 \Rightarrow a=b$ (que tengan distancia nula no implica que sean la misma observación).
- Sin embargo, algunos resultados teóricos de optimalidad para algunos algoritmos de clustering si dependen de trabajar con distancias métricas. Por ej., la velocidad de convergencia.
- Algoritmos que funcionan con distancias no métricas: k-medoids, jerárquico (excepto Ward's linkage) y en alguna medida DBSCAN (puede ser engañoso porque la medida de vecindades en espacios no métricos puede fallar).
- K-means, c-means y jerárquico con Ward's linkage dependen de distancias euclidianas y no están recomendados para distancias no métricas.
- Las violaciones de simetría en las distancias ($d(a, b) = d(b, a)$) son mucho más difíciles de manejar para algoritmos de clustering (De los que vimos, DBSCAN es el único que puede trabajar con asimetrías). Consejo en estos casos: simetrizar distancias.

Matrices de Similitud

Una **matriz de similitud** S es aquella donde $s(a,a) = 1$. Se puede transformar una matriz de similitud S en una de disimilitud D :

- Si el dominio de la similitud es $[0, 1]$:

$$d(a, b) = 1 - s(a, b)$$

- Si el dominio de S es $[-1, 1]$ y $s = -1$ se corresponde con la mayor distancia normalizada:

$$d(a, b) = 1 - (s(a, b) + 1)/2$$



por ej. correlación de Pearson

Definiendo una disimilitud (distancia), puedo inferir una similitud
(Observación: aunque S sea métrica, no puedo *garantizar* que la D resultante sea métrica)

Matrices de Proximidad, Similaridad, Disimilaridad y Distancia y Afinidad ...


¡Ojo! ¡La diferencia entre estos términos depende muchas veces del dominio!

En general,

una **matriz de disimilaridad métrica** ~ una **matriz de distancia**

una **matriz de afinidad** ~ una **matriz de similaridad**, con la particularidad de que

afinidad(a,b) ~ $\exp(-d(a,b)^2)$ $\Rightarrow$ si $d(a,b) = 0$, $\text{afinidad}(a,b) = 1$
si $d(a,b) \gg 1$, $\text{afinidad}(a,b) \sim 0$



Matrices de Similitud y Disimilitud para atributos BINARIOS

A dark blue diagonal gradient bar that starts from the bottom-left corner and extends towards the top-right corner, covering the lower half of the slide.

Matrices de Similitud y Disimilitud para atributos BINARIOS

Supongamos que tenemos dos objetos para los cuales se registran los valores que toman **p** diferentes **atributos binarios** (Verdadero/Falso, 0/1, +/-, etc.):

	var.0	var.1	var.2	var.3	var.4	var.5	var.6	var.7
item.x	1	1	1	1	0	0	0	1
item.y	1	1	0	0	1	0	0	0

Podemos definir estas cantidades:

a: cantidad de variables con **1** tanto para **x** como para **y**

b: cantidad de variables con **1** para **x** y **0** para **y**

c: cantidad de variables con **0** para **x** y **1** para **y**

d: cantidad de variables con **0** tanto para **x** como para **y**

$$p = a + b + c + d$$

Matrices de Similitud y Disimilitud para atributos BINARIOS

Supongamos que tenemos dos objetos para los cuales se registran los valores que toman **p** diferentes **atributos binarios** (Verdadero/Falso, 0/1, +/-, etc.):

	var.0	var.1	var.2	var.3	var.4	var.5	var.6	var.7
item.x	1	1	1	1	0	0	0	1
item.y	1	1	0	0	1	0	0	0

Podemos definir estas cantidades:

a: cantidad de variables con **1** tanto para **x** como para **y** → **a = 2**

b: cantidad de variables con **1** para **x** y **0** para **y** → **b = 3**

c: cantidad de variables con **0** para **x** y **1** para **y** → **c = 1**

d: cantidad de variables con **0** tanto para **x** como para **y** → **d = 2**

p = a + b + c + d → **p = 8**

Matrices de Similitud y Disimilitud para atributos BINARIOS

	var.0	var.1	var.2	var.3	var.4	var.5	var.6	var.7
item.x	1	1	1	1	0	0	0	1
item.y	1	1	0	0	1	0	0	0

Para calcular la (di)similitud entre **x** e **y** hay diferentes opciones.
Dos de las más conocidas son:

→ **Coeficiente de coincidencias** (Simple Matching Coeff.)

(similitud) $s(x,y) = (a + d)/p$

(disimilitud) $d(x,y) = (b + c)/p$

→ **Coeficiente de Jaccard**

(similitud) $s(x,y) = a / (a + b + c)$

(disimilitud) $d(x,y) = (b + c) / (a + b + c)$

Todos están acotados en $[0,1]$

Ambas disimilitudes son distancias métricas

Podemos definir estas cantidades:

a: $x = 1 \ \& \ y = 1 \rightarrow a = 2$

b: $x = 1 \ \& \ y = 0 \rightarrow b = 3$

c: $x = 0 \ \& \ y = 1 \rightarrow c = 1$

d: $x = 0 \ \& \ y = 0 \rightarrow d = 2$

p = $a + b + c + d \rightarrow p = 8$

Coincidencias le asigna importancia a pares de valores **1-1 (V-V)** y a **0-0 (F-F)**

Jaccard mide la proporción de “hits” tipo **1-1 (V-V)**, con respecto a todas las entradas con al menos un **1 (V)**

Dependiendo del problema, una medida puede ser más adecuada que la otra.

Matrices de Similitud y Disimilitud para atributos BINARIOS

¡Existe un gran número de medidas de (di)similitud desarrolladas para variables binarias! Por ejemplo, Choi, S. S., Cha, S. H., & Tappert, C. C. (2010). *A survey of binary similarity and distance measures*. *Journal of Systemics, Cybernetics and Informatics*, 8(1), 43-48.

[http://www.iiisci.org/journal/CV\\$/sci/pdfs/GS315JG.pdf](http://www.iiisci.org/journal/CV$/sci/pdfs/GS315JG.pdf)

IMPORTANTE: k-means o c-means NO son recomendables para atributos binarios en general, ya que estos algoritmos trabajan sobre el espacio original de atributos (no se les puede pasar una matriz de distancia precomputada) y se basan en definir prototipos promedio (para variables binarias, el promedio va a ser un valor decimal no representativo de los atributos binarios). También es difícil definir densidades en espacios binarios, por lo que DBSCAN tampoco se recomienda.

Medidas para atributos CONTINUOS

A dark blue, abstract shape that starts as a thin line on the left and curves upwards and to the right, filling the bottom half of the slide.

Medidas para atributos cuantitativos (continuos)

Métricas de Minkowski:

$$d(x, y) = \left(\sum_{k=1}^p w_k^\lambda |x_k - y_k|^\lambda \right)^{1/\lambda}$$


Distancia Euclídea ($\lambda=2$):

$$d(x, y) = \sqrt{\sum_{k=1}^p |x_k - y_k|^2}$$

Distancia Manhattan ($\lambda=1$):

$$d(x, y) = \sum_{k=1}^p |x_k - y_k|$$

Supongamos que tenemos dos objetos para los cuales se registran los valores que toman **p diferentes variables continuas**




Los w_k son pesos para cada una de las p dimensiones que suelen aplicarse para “estandarizar” las variables (por ej., normalizarlas por la desviación estándar de la dimensión) o acotarlas en $[0, 1]$.

Otras distancias son la de [Canberra](#) (una versión pesada de la distancia de Manhattan) o la de [Mahalanobis](#) (una distancia cuadrática estandarizada por la matriz de covarianza, eliminando correlación entre atributos).

Similitud de coseno: Medida “geométrica” basada en comparaciones angulares

A veces las magnitudes que toman las variables no son tan importantes en cuanto a cómo concebimos a las distancias entre objetos. El interés, en cambio, se enfoca en la comparación de las direcciones de los vectores que definen a cada objeto en el espacio multidimensional de las variables.

La similitud coseno es una medida de similitud que sirve para comparar la separación angular entre objetos.



Similitud de coseno: Medida “geométrica” basada en comparaciones angulares

Similitud coseno:

Similitud entre dos muestras de vectores de p atributos, que pueden venir de una misma distribución o de diferentes distribuciones. Dado las muestras $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$, $\mathbf{x} = \{x_1, x_2, \dots, x_p\}$, $\mathbf{y} = \{y_1, y_2, \dots, y_p\}$




$$S(\mathbf{x}, \mathbf{y}) \equiv \cos(\theta) = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} = \frac{\sum_{i=1}^p x_i y_i}{\sqrt{\sum_{i=1}^p x_i^2} \sqrt{\sum_{i=1}^p y_i^2}}$$

De naturaleza **geométrica**. Es una medida en el intervalo $[-1, 1]$ de la proporcionalidad entre $\mathbf{x}$ e $\mathbf{y}$: importa la dirección de ambos vectores, no sus magnitudes

Distancia de coseno:

$$D_{\cos} = 1 - \cos(\theta)$$

(no es métrica, ya que viola la desigualdad triangular)



Correlación de Pearson: Medida basada en comparación estadística de muchas muestras


Correlación de Pearson:

Computa la **correlación entre 2 variables aleatorias provenientes de una misma distribución conjunta**

Obtenemos n muestras de una distribución bivariada (X, Y) que consiste de 2 atributos, $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$

$$S(\mathbf{x}, \mathbf{y}) \equiv \rho(\mathbf{x}, \mathbf{y}) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

De naturaleza **estadística**. El coeficiente está acotado en el intervalo $[-1, 1]$ y está centrado, es decir que es invariante a desplazamientos de $\mathbf{x}$ o $\mathbf{y}$. Es una medida de la colinealidad entre $\mathbf{x}$ e $\mathbf{y}$



Si $\mathbf{x}$ e $\mathbf{y}$ están centrados, y los interpretamos como vectores en un espacio de n atributos (o sea, $p=n$), la correlación de Pearson es numéricamente igual a la similaridad de coseno. ¡Pero en general son dos medidas de diferente naturaleza!

Distancia de correlación:

$$D_\rho = 1 - (\rho+1)/2$$

(no es métrica)

IMPORTANTE: Ni podemos intentar usar distancias de coseno o de correlación con k-means o c-means, ya que estos algoritmos trabajan sobre el espacio original de atributos con distancias euclideanas (no se les puede pasar una matriz de distancia precomputada de otra manera). DBSCAN también puede fallar porque la noción de densidad no está bien definida en estas distancias no métricas.

Medidas para atributos MULTIESTADO

Medidas para atributos categóricos multiestado (ordinales o no)

Consideramos variables categóricas multiestado a aquellas que presentan dos o más estados o categorías (más que binarias). Si estas categorías presentan algún tipo de ordenamiento, la variable es categórica ordinal, o simplemente ordinal.

Ejemplo de variable categórica no ordinal: ocupación laboral de un sujeto (albañil, docente, etc...)

Ejemplo de variable categórica: grado de estudio de un sujeto (primario, secundario, universitario, etc...)

Atributos categóricos multiestado no ordinales

Una solución sencilla es separar la variable multiestado original en varias variables binarias, una para cada categoría (one-hot encoding) [problema: muchos estados=muchas variables!!].

Human-Readable

Pet
Cat
Dog
Turtle
Fish
Cat

Machine-Readable

Cat	Dog	Turtle	Fish
1	0	0	0
0	1	0	0
0	0	1	0
0	0	0	1
1	0	0	0

Atributos categóricos multiestado no ordinales

Tipo de mascota	Color
Gato	Negro
Perro	Negro
Tortuga	Verde
Pez	Azul
Gato	Blanco



Gato	Perro	Tortuga	Pez	Negro	Verde	Azul	Blanco
1	0	0	0	1	0	0	0
0	1	0	0	1	0	0	0
0	0	1	0	0	1	0	0
0	0	0	1	0	0	1	0
1	0	0	0	0	0	0	1

- Criterio de coincidencias:

$$S(x, y) = \frac{1}{r} \sum_{l=1}^r S_{xyl}$$

(Proporción de “matches” en one-hot-encoding)

Donde la similaridad entre las observaciones **x** e **y** de r atributos (el número de **columnas**) se calcula:

$$\text{Para } l = 1, \dots, r : \quad \begin{array}{ll} S_{xyl} = 0 & \text{si } x_l \neq y_l \\ S_{xyl} = w & \text{si } x_l = y_l \end{array}$$

w es típicamente 1, pero se puede usar un peso

Atributos categóricos multiestado no ordinales

Algoritmos de clustering recomendados para usar con criterio de coincidencias pre-computados: k-medoids, jerárquico (excepto ward's linkage), y DBSCAN. Pero ojo con la alta dimensionalidad de one-hot encoding....

- Criterio de coincidencias:

$$S(x, y) = \frac{1}{r} \sum_{l=1}^r S_{xyl}$$

(Proporción de “matches” en one-hot-encoding)

Donde la similaridad entre las observaciones **x** e **y** de r atributos (el número de **columnas**) se calcula:

$$\text{Para } l = 1, \dots, r : \quad \begin{array}{ll} S_{xyl} = 0 & \text{si } x_l \neq y_l \\ S_{xyl} = w & \text{si } x_l = y_l \end{array}$$

w es típicamente 1, pero se puede usar un peso

Atributos categóricos multiestado ORDINALES

La disimilaridad será proporcional a la cantidad de “saltos” entre los estados ordenados.

Por ejemplo, suponiendo que se tienen 3 estados: $A < B < C$, y que la distancia entre dos estados cualquiera es 1 $\Rightarrow$ podemos decir que $A=0$, $B=1$, $C=2$. La distancia entre dos estados x e y es:

$$d(x, y) = |x - y|^r$$

donde típicamente $r=1$. Así $d(A, B) = d(B, C) = 1$ y $d(A, C) = 2$. Luego, estas medidas suelen ser normalizadas al rango $[0, 1]$, en este caso:

$$d(x, y) = \frac{|x - y|^r}{2}$$

Para p atributos categóricos ordinales, esta medida puede generalizarse a:

$$d(x, y) = \frac{\sum_{k=1}^p d_k(x, y)}{p}$$

Atributos categóricos multiestado ORDINALES

Algoritmos de clustering recomendados para usar con estas distancias en espacios multiestado ordinales: k-medoids, jerárquico (excepto ward's linkage). DBSCAN puede fallar al buscar densidades en espacios de variables discretas.

Para p atributos categóricos ordinales, esta medida puede generalizarse a:

$$d(x, y) = \frac{\sum_{k=1}^p d_k(x, y)}{p}$$

Medidas para atributos MIXTOS



Medidas para comparar variables de tipos mixtos

Es común tener que calcular matrices de distancia a partir de un conjunto de variables con variables de diferentes tipos, binarias, categóricas, continuas. Una forma simple de combinarlas es el *coeficiente de similaridad de Gower*:

$$S(x, y) = \frac{\sum_{k=1}^p S_{xyk} \delta_{xyk}}{\sum_{k=1}^p \delta_{xyk}}$$

donde S_{xyk} es la similaridad entre x e y para la variable k (en la métrica que corresponda) que siempre se normaliza al rango $[0,1]$; δ_{xyk} toma valores 0 o 1 según esta comparación esté presente o no.

- El coeficiente de disimilaridad se toma como $d(x,y)=1-S(x,y)$,
- A veces la noción de distancia se extiende a $d(x,y)^2=1-S(x,y)$ (ya que si hay variables ordinales, $d(x,y)=1-S(x,y)$ no es métrica y $d(x,y)^2=1-S(x,y)$ si es métrica, pero no euclídeana)

Esta distancia en el fondo representa el promedio entre las distancias de todas las variables calculadas en cada caso como corresponda.

Medidas para comparar variables de tipos mixtos

En común tener que calcular matrices de distancia a partir de un conjunto de variables con variables de diferentes tipos, binarias, categóricas, continuas. Una forma simple de combinarlas es el *coeficiente de similitud de Gower*:

$$S(x, y) = \frac{\sum_{k=1}^p S_{xyk} \delta_{xyk}}{\sum_{k=1}^p \delta_{xyk}}$$

donde S_{xyk} es la similitud entre x e y para la variable k (en la métrica que corresponda) que siempre se normaliza al rango $[0,1]$; δ_{xyk} toma valores 0 o 1 según esta comparación esté presente o no.

Típicamente,

S_{xyk} (continua)	→ Manhattan
S_{xyk} (binaria)	→ Jaccard ($a / (a + b + c)$)
S_{xyk} (multiestado)	→ Dice ($2a / (2a + b + c)$)
S_{xyk} (ordinales)	→ Ordena y luego Manhattan

Medidas para comparar variables de tipos mixtos

En común tener que calcular matrices de distancia a partir de un conjunto de variables con variables de diferentes tipos, binarias, categóricas, continuas. Una forma simple de combinarlas es el *coeficiente de similitud de Gower*:

$$\Delta^p = \frac{1}{p} \sum_{k=1}^p \delta_{xyk}$$

Algoritmos de clustering recomendados para usar con distancia de Gower: k-medoids, jerárquico (excepto ward's linkage). DBSCAN puede nuevamente fallar al buscar densidades en espacios mixtos.

normaliza al rango [0,1]; δ_{xyk} toma valores 0 o 1 según esta comparación este presente o no.

Típicamente,

S_{xyk} (continua)	→ Manhattan
S_{xyk} (binaria)	→ Jaccard ($a / (a + b + c)$)
S_{xyk} (multiestado)	→ Dice ($2a / (2a + b + c)$)
S_{xyk} (ordinales)	→ Ordena y luego Manhattan

Librerías

Python

sklearn: Todas métricas sobre datos continuos

<https://scikit-learn.org/stable/modules/metrics.html#metrics>

<https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.DistanceMetric.html>

scipy: También tiene sobre binarios como Jaccard

<https://docs.scipy.org/doc/scipy/reference/generated/scipy.spatial.distance.pdist.html#scipy.spatial.distance.pdist>

gower: En ninguno de los dos hay una implementación para datos mixtos o categóricos como Gower.

<https://pypi.org/project/gower/>