

Clustering (parte 2/3)


Técnicas de Validación

Métodos de validación: ¿Por qué es importante la validación?



- Antes de empezar a buscar es importante verificar si existe una **tendencia al clustering**.
- Siempre vamos a encontrar grupos PERO ¿Son buenos grupos?
- Determinar el mejor número de clusters (k).
- Comparar métodos de Clustering (sobre los mismos datos).





¿Cuántos clusters?




¿Seis?



¿Dos?




¿Cuatro?



Validación Externa vs Validación Interna: con etiquetas o a partir de los datos no etiquetados

- Determinar cuán buenos son los grupos (**externa**/**interna**).
- Determinar cuán buena es la separación entre ellos (**externa**/**interna**).
- Constatar el número de clusters con las etiquetas *a priori* (si existen) (**externa**).



Existen diferentes medidas de validación y no existe un criterio único para determinar cuál es la mejor.


No hay una medida única que se pueda usar para todos los métodos de clustering.

Validación interna de DBSCAN: *eliminar siempre los puntos catalogados como “ruido” antes de validar. Por otro lado, los clusters de formas arbitrarias que logra identificar pueden ser difíciles de validar. Se aconseja visualizar los resultados previamente.*

Validación interna de c-means: *al ser un algoritmo de agrupamiento difuso (“fuzzy clustering”), para aplicar los índices de validación que vamos a ver se recomienda adoptar un criterio sobre los pesos de pertenencia w_{ij} para traducir los resultados a un clustering exclusivo y luego realizar la validación. Existen índices de validación específicos para agrupamientos difusos pero no los vamos a ver.*

Tendencia al Clustering

Estadístico (coeficiente) de Hopkins



● *elementos del dataset*


Tendencia al Clustering

Estadístico (coeficiente) de Hopkins

$$H = \frac{\sum_{i=1}^p w_i}{\sum_{i=1}^p u_i + \sum_{i=1}^p w_i}$$

w_i = distancia del elemento i del dataset al vecino del dataset más cercano

u_i = distancia del punto i agregado al azar al vecino del dataset más cercano



- elementos del dataset
- elementos agregados al azar

- Si hay clusters las distancias w son menores que las u
- Si no hay clusters ambas distancias son comparables

$H \sim 0$: ¡Hay clusters!

$H \sim 0.5$ (por ej., >0.3): El dataset tiende a la homogeneidad

```
>>> from pyclustertend import hopkins
```

Validación Externa (a.k.a. Supervisada)

A dark blue diagonal gradient bar that starts from the bottom left and extends towards the top right, covering the lower half of the slide.

Validación externa

1. Matriz de confusión

		Clusters				
		0	1	2	3	4
Labels	a	1	25	1	0	13
	b	7	7	2	0	24
	c	34	0	2	0	4
	d	0	0	39	0	1
	e	0	0	0	40	0

Importante: El número de clusters que obtengo no tiene por qué ser igual al de etiquetas externas *a priori*

Las etiquetas no tienen por qué ser una “verdad revelada”

Referencia Diferentes Técnicas de Validación Externa aplicado a K-Means
[Wu, J., Xiong, H., & Chen, J. \(2009, June\). Adapting the right measures for k-means clustering. In Proceedings of the 15th ACM SIGKDD international conference on Knowledge discovery and data mining \(pp. 877-886\).](#)

Validación externa

2. Medida Normalizada de van Dongen: Medida mejorada de la “pureza” (que mide cuánto se aleja de tener sólo una entrada no nula por fila/columna)

Labels	Clusters					
	0	1	2	3	4	
	a	1	25	1	0	13
	b	7	7	2	0	24
	c	34	0	2	0	4
	d	0	0	39	0	1
e	0	0	0	40	0	

Para n muestras y una matriz de confusión con entradas n_{ij}

$$VD_n = \frac{(2n - \sum_i \max_j n_{ij} - \sum_j \max_i n_{ij})}{(2n - \max_i n_{i.} - \max_j n_{.j})}$$

Validación externa

2. Medida Normalizada de van Dongen: Medida mejorada de la “pureza” (que mide cuánto se aleja de tener sólo una entrada no nula por fila/columna)

	Clusters					
	0	1	2	3	4	
Labels	a	1	25	1	0	13
	b	7	7	2	0	24
	c	34	0	2	0	4
	d	0	0	39	0	1
	e	0	0	0	40	0

Interpretación: (mejor) $0 \leq VD_n \leq 1$ (peor)

$$2*200 - (25 + 24 + 34 + 39 + 40) - (34 + 25 + 39 + 40 + 24)$$

$$VD_n = \frac{(2n - \sum_i \max_j n_{ij} - \sum_j \max_i n_{ij})}{(2n - \max_i n_{i.} - \max_j n_{.j})} \sim 0.24$$

$$2*200 - 40 - 40$$

Observación: acá las sumatorias dan el mismo valor porque todos los clusters tienen igual número de elementos (están balanceados), pero en general no tiene por qué ser así

No está implementada en sklearn, hay que crearla a mano


Validación externa

3. Índice Rand :

Interpretación: (peor) $0 \leq R \leq 1$ (mejor)

$$R = \frac{a + b}{a + b + c + d} = \frac{a + b}{\binom{n}{2}}$$

Todos los pares
posibles



Etiquetas: ● ●

Clusters: ○ ○

Bien

a = número de pares de elementos que aparecen juntos en un clúster y además pertenecen a la misma clase.

b = número de pares de elementos que pertenecen a clases diferentes y además están en clústeres diferentes.

Mal

c = número de pares de elementos que comparten la clase, pero se ubican en diferentes clústeres.

d = número de elementos que pertenecen a clases diferentes, sin embargo se agrupan en el mismo clúster.

n = número total de elementos.

Validación externa

3. Índice Rand :

$$R = \frac{a + b}{a + b + c + d} = \frac{a + b}{\binom{n}{2}}$$

$$a = 6 + 10 + 3 + 15 = 34$$

$$b = 30 + 12 = 42$$

$$n = 18$$

$$R = 76 / 153 \sim 0.5$$



Validación externa

3. Índice Rand :


$$R = \frac{a + b}{a + b + c + d} = \frac{a + b}{\binom{n}{2}}$$

$$a = 28 + 28 = 56$$

$$b = 64 + 1 = 65$$

$$n = 18$$

$$R = 111 / 153 \sim 0.73$$



Problemas con índice de Rand:

- Tiende a ser “optimista”, asignando valores altos a particiones al azar
- Depende mucho del tamaño de los clusters

Validación externa

4. Índice Rand Ajustado o Normalizado (Adjusted Rand Index, ARI):

$$R = \frac{a + b}{a + b + c + d} = \frac{a + b}{\binom{n}{2}}$$

$$ARI = (R - E(R)) / (\max(R) - E(R))$$

$E(R)$ = valor esperado de R si se distribuyen al azar.

$\max(R)$ = valor máximo posible de R para los datos.

Si $R = E(R) \rightarrow ARI = 0$
Si $R = \max(R) \rightarrow ARI = 1$

```
>>> from sklearn.metrics.cluster import adjusted_rand_score
```

Validación externa

4. Índice Rand Ajustado o Normalizado (Adjusted Rand Index, ARI):

$$R = \frac{a + b}{a + b + c + d} = \frac{a + b}{\binom{n}{2}}$$

$$ARI = (R - E(R)) / (\max(R) - E(R))$$

$E(R)$ = valor esperado de R si se distribuyen al azar.

$\max(R)$ = valor máximo posible de R para los datos.

Observación: $E(R)$ no se obtiene por medio de una aleatorización estocástica, sino analíticamente vía la [distribución hipergeométrica](#) (que nos indica el número esperado de pares superpuestos entre dos particiones, suponiendo que los tamaños de los clústeres y los tamaños de las clases son fijos y que los objetos se asignan aleatoriamente).

Si $R = E(R) \rightarrow ARI = 0$
Si $R = \max(R) \rightarrow ARI = 1$

```
>>> from sklearn.metrics.cluster import adjusted_rand_score
```

Validación Interna (a.k.a. No Supervisada)

Criterios generales: Cohesión y Separación

- **Cohesión:** es una medida de las proximidad de los miembros de un clúster entre sí (o con respecto al prototipo para acelerar los cálculos).
- **Separación:** es la proximidad entre miembros de diferentes clústeres (o entre prototipos de grupos y el prototipo general).

**Suma de los Errores al Cuadrado
(dentro de un cluster) (SSE)**

$$SSE = \sum_{i=1}^K \sum_{x \in C_i} \text{dist}(c_i, x)^2$$

**Suma de Cuadrados de Separación
(SSB)**

$$SSB = \frac{1}{2K} \sum_{i=1}^K \sum_{j=1}^K \frac{m}{K} \text{dist}(c_i, c_j)^2$$

¡Tienen un sesgo hacia clusters globulares!

m puntos en K clusters
 c_i = centroide o medoide (prototipo) i

Validación Interna


1. Criterio de “codo”: buscar un número de clusters que me minimice la dispersión (SSE) o maximice la separación (SSB). Muchas veces se observa un pico o un “codo” donde satura la optimización

Una heurística simple, pero sin fundamentos teóricos. ¡Puede ser engañoso!

Bibliografía: [Stop using the elbow criterion for k-means](#)

Válido para k-means y c-means (o incluso k-medoids) que tienen centroides (medoides) bien definidos.

SSE penaliza clusters de forma irregular que pueden encontrar por agrupamiento jerárquico o DBSCAN (este criterio no se recomendada para validar resultados de estos algoritmos)



Validación Interna

2. Coeficiente de Silhoutte:

$$s_i = \frac{(b_i - a_i)}{\max(a_i, b_i)}$$

$s_i \rightarrow 1$: excelente clusterización del punto
 $s_i \sim 0$: el punto está cerca del límite entre dos clusters
 $s_i < 0$: el punto podría pertenecer a otro cluster superpuesto al suyo

1. Distancias intra-cluster: Para cada elemento i se calcula su distancia promedio a todos los otros elemento de su clúster (a_i).
2. Distancias inter-cluster: Para el elemento i y todos los otros clústeres que no lo contienen, se calcula las distancias promedio a todos los elementos de cada clúster. Se obtiene el mínimo (la “peor”) de esas distancias (b_i).
3. Se calcula el coeficiente Silhouette (s_i) del elemento i . **Para cada punto obtengo un valor.**
4. Luego se puede calcular el promedio para cada cluster o el promedio global.

Validación Interna

2. Coeficiente de Silhoutte:

$$s_i = \frac{(b_i - a_i)}{\max(a_i, b_i)}$$

También penaliza clusters irregulares,
pero menos que SSE.

$s_i \rightarrow 1$: excelente clusterización del punto

$s_i \sim 0$: el punto está cerca del límite entre dos clusters

$s_i < 0$: el punto podría pertenecer a otro cluster superpuesto al suyo


1. Distancias intra-cluster: Para cada elemento i se calcula su distancia promedio a todos los otros elemento de su clúster (a_i).
2. Distancias inter-cluster: Para el elemento i y todos los otros clústeres que no lo contienen, se calcula las distancias promedio a todos los elementos de cada clúster. Se obtiene el mínimo (la “peor”) de esas distancias (b_i).
3. Se calcula el coeficiente Silhouette (s_i) del elemento i . **Para cada punto obtengo un valor.**
4. Luego se puede calcular el promedio para cada cluster o el promedio global.

Validación Interna

2. Coeficiente de Silhoutte:

Consejo general:

- Evitar la presencia de clusters con valores de silhouette por debajo del puntaje promedio de silhouette (el “average silhouette width”, línea punteada roja)
- Evitar clusters con variaciones muy altas de puntaje de silhouette (por ej, con picos positivos y negativos)




Validación Interna

2. Coeficiente de Silhoutte:

Consejo general:


- Evitar la presencia de clusters con valores de silhouette por debajo del puntaje promedio de silhouette (el “average silhouette width”, línea punteada roja)
- Evitar clusters con variaciones muy altas de puntaje de silhouette (por ej, con picos positivos y negativos)



Validación Interna

2. Coeficiente de Silhouette:


- ¡Ojo! Es deseable tener un *average silhouette width* (línea punteada roja) alto, pero no es un indicador válido e infalible por sí solo. Hay que ver toda la distribución del gráfico de silhouette



Validación Interna

2. Coeficiente de Silhoutte:


Puede ocurrir que algunos clusters tengan peor coeficiente o algunos elementos negativos dentro del cluster. Pero en general esto parece un buen clustering



Validación Interna


2. Coeficiente de Silhoutte:

Esto es un mal clustering, hay que cambiar los parámetros del algoritmo usado.





Validación Interna

3. (Jerárquico) Aplicar criterio de corte en el dendrograma (por distancia o por número de clusters) y luego se pueden aplicar las medidas de validación interna o externa igual que otros métodos.




Validación Interna

4. (*Jerárquico*) **Coeficiente de Correlación Cofenético (CoPhenetic Correlation Coefficient, CPCC)**: Mide la correlación entre la matriz de distancia que dio origen al agrupamiento y los distancias extraídas del árbol (Altura del nodo que une por primera vez dos elementos).



Validación Interna

5. Bootstrapping: Para evaluar la estabilidad de los clusters obtenidos. Se realizan “simulaciones” por remuestreo de los datos y se los clusteriza, esperando obtener resultados similares a los obtenidos con los datos reales. Se puede usar con cualquier algoritmo de clustering.





[Animación](#)

- 1) Se hace un bootstrapping del conjunto de datos (varias rondas de remuestreo con reposición)
- 2) Se hace clustering sobre esas cada una de esas simulaciones
- 3) Se computa una estadística de similaridad (por ej. Índice de van Dongen, ARI, etc...) entre todas las particiones simuladas y la obtenida con el dato real
- 4) Se espera obtener una similaridad alta.

Validación Interna

5. Bootstrapping: Para evaluar la estabilidad de los clusters obtenidos. Se realizan “simulaciones” por remuestreo de los datos y se los clusteriza, esperando obtener resultados similares a los obtenidos con los datos reales. Se puede usar con cualquier algoritmo de clustering.

Con bootstrapping también se puede dar un intervalo de confianza a cualquier estadística calculada sobre los datos clusterizados



Cada boxplot es el agregado de todas las simulaciones por bootstrap

Validación Interna

6. Cross-validation: *Para evaluar la capacidad de “predicción” de los clusters obtenidos.*

1. Dividir la muestra total en un conjunto de entrenamiento y otro de test (usando k-folds).
2. Clusterizar el conjunto de entrenamiento con algún algoritmo.
3. Clusters en conjunto test: Clusterizar de la misma forma el conjunto de test.
4. “Predicción”: Usar los resultados del paso 2 para asignar cada observación del conjunto test a un cluster del conjunto de entrenamiento (por ej., en k-means asignar la observación al centroide más cercano del conjunto de entrenamiento).
5. Evaluar “calidad de la predicción”: calcular algún índice de validación externa que compare los clusters “predichos” y los del conjunto test (punto 3). Por ej. via Índice de Rand, o ARI.
6. Repetir para todos los folds, y evaluar si el conjunto de predicciones fueron de buena calidad.