

Clustering - Clase 3/3

Aplicaciones

Clasificación de galaxias

El problema

Translation Invariance



Rotation/Viewpoint Invariance



Size Invariance



Illumination Invariance




Matt Krause
mattkrause


Clasificación de galaxias

Representaciones

Basada en los pixels
(representación de bajo nivel)



Basada en atributos latentes
(representación de alto nivel)



Motivación:

Agrupamiento de imágenes astronómicas



Clasificación de galaxias

- Fundamental dentro de la cosmología observacional.
- La morfología codifica estados dinámicos de la galaxia.



Relación con el color, la formación estelar, el entorno, etc.






Clasificación morfológica de galaxias





Galaxias de secuencia Hubble



Clasificación morfológica de galaxias



Clasificación morfológica de galaxias




Clasificación morfológica de galaxias





Modelo:

** Quitar
información
irrelevante*

** Features que
sean invariantes
de escala,
rotaciones,
orientación*



Feature Extraction



Un modelo no supervisado para este problema específico


An automatic taxonomy of galaxy morphology using unsupervised machine learning

Alex Hocking,¹★ James E. Geach,² Yi Sun¹ and Neil Davey¹

¹Centre for Computer Science and Informatics Research, University of Hertfordshire, Hatfield AL10 9AB, UK

²Centre for Astrophysics Research, School of Physics, Astronomy & Mathematics, University of Hertfordshire, Hatfield AL10 9AB, UK

Accepted 2017 September 8. Received 2017 September 5; in original form 2015 July 3



[Hocking, A., Geach, J. E., Sun, Y., & Davey, N. \(2018\). An automatic taxonomy of galaxy morphology using unsupervised machine learning. *Monthly Notices of the Royal Astronomical Society*, 473\(1\), 1108–1129.](#)




Feature extraction

A dark blue diagonal gradient bar that starts from the bottom-left corner and extends towards the top-right corner, covering the lower half of the slide.






Algunas posibilidades (supervisadas y no supervisadas)

- Principal Component Analysis (PCA)
- t-Distributed Stochastic Neighbor Embedding (t-SNE)
- Autoencoders
- Convolutional Neural Networks (CNNs)
- Transfer Learning
- Y muchas más...

Redes neuronales artificiales: conceptos y terminología




Redes neuronales artificiales: conceptos y terminología



Autoencoders

Método no supervisado (o *self-supervised*) para feature extraction



Ingredientes:

- Red de codificación
- Red de decodificación
- Algún función objetivo para comparar el input y el output


Comprimir los datos en una representación de menor dimensionalidad, a partir de la cual se produce un output que reconstruye de la mejor manera posible el dato original.

No necesita etiquetas. Aprende “la esencia” del dato necesaria para poder regenerarlo.


Problema: tienden a ser un poco “domain specific”, y la generalización no siempre funciona.

Convolutional Neural Networks

- Ideal para el procesamiento de datos estructurados espacialmente (por ej., imágenes)
- Entrenadas en conjuntos de datos etiquetados muy grandes



VGG16 es una CNN muy exitosa



- Entrada: Imágenes RGB de tamaño 224 x 224
- El kernel de convolución es de 3x3 (¡muy pequeño!)
- Luego de convolución y pooling, tenemos 3 capas de neuronas totalmente conectadas: Las dos primeras están compuestas por 4096 neuronas ("features") y una última capa "softmax" de 1000 para clasificar.
- Tiene 16 capas con 138 millones de parámetros.
- Entrenada en el dataset ImageNet (14 millones de imágenes etiquetadas en más de 1000 clases) con accuracy >92%

Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*.
<https://arxiv.org/pdf/1409.1556.pdf%E3%80%82> ; https://www.robots.ox.ac.uk/~vgg/research/very_deep/ ; <http://www.cs.toronto.edu/~frossard/post/vgg16/>

¿Cómo podemos adaptar estos modelos para nuevos problemas?

- Usar un modelo previamente entrenado como punto de partida para una nueva tarea o dominio.
- La idea es aprovechar el conocimiento adquirido por el modelo previamente entrenado en un conjunto de datos grande y aplicarlo a una tarea relacionada con un conjunto de datos más pequeño.
- Al hacerlo, podemos beneficiarnos de las características y patrones generales aprendidos por el modelo previamente entrenado


Transfer Learning: extrapolando el conocimiento adquirido

Dos pasos principales:

Feature extraction: Utilizamos el modelo previamente entrenado como un extractor “fijo” de características. Eliminamos las capas finales de clasificación y las reemplazamos con nuevas capas específicas para nuestra tarea. Los pesos del modelo previamente entrenado se “congelan” y solo los pesos de las nuevas capas de clasificación se entrenan en el conjunto de datos más pequeño.

Fine-tuning: Se lleva el proceso un paso más allá al descongelar algunas de las capas del modelo previamente entrenado y permitir que se actualicen con el nuevo conjunto de datos. Este paso permite que el modelo se adapte y aprenda características más específicas relacionadas con la nueva tarea o dominio.

Figure 1. Transfer learning from ImageNet.




Transfer Learning: extrapolando el conocimiento adquirido

En el TP2 harán una versión de “transfer learning”:

- Usarán la VGG16 ya entrenada, y para cada imagen van a extraer los features de la capa de 4096 neuronas post-convolución.
- Luego aplicarán métodos de clustering para clasificar las imágenes del dataset.

Figure 1. Transfer learning from ImageNet.




Transfer Learning: extrapolando el conocimiento adquirido

Limitaciones:

Si los datos de origen no representan adecuadamente el dominio de destino, los modelos podrían tener dificultades para adaptarse con precisión.

En última instancia, la performance de un modelo depende de la representatividad de los datos en los cuales fueron entrenados. Típico problema: sesgos


Figure 1. Transfer learning from ImageNet.




Mitigando sesgos en la clasificación



El problema de los datasets sesgados



Classifier with balanced class



Classifier with imbalanced class

Algoritmos de clasificación de género



Sistema automático -> reconoce género por características faciales

- * Video de vigilancia
- * Demografía
- * Publicidad online
- * Interacción humana con la computadora
- * Registros policiales



Sesgos en la clasificación de género

Mujeres de color menor precisión en detección



TYPE I TYPE II TYPE III TYPE IV TYPE V TYPE VI

(Microsoft) error rates:



1.7%	1.1%	3.3%	0%	23.2%	25.0%
------	------	------	----	-------	-------

(IBM) error rates:



5.1%	7.4%	8.2%	8.3%	33.3%	46.8%
------	------	------	------	-------	--------------

Gender Classification and Bias Mitigation in Facial Images

Wenying Wu

wwu1@alumni.harvard.edu

Senior Software Engineer @ Visa Inc.

Zheng Yang

zhengyang@alumni.harvard.edu

Data Scientist @ FM: Systems

Pavlos Protopapas

pavlos@seas.harvard.edu

Scientific Program Director @ Harvard John A. Paulson

School Of Engineering And Applied Sciences

Panagiotis Michalatos

pan.michalatos@gmail.com

Senior Principal Research Engineer @ Autodesk

ABSTRACT


Gender classification algorithms have important applications in many domains today such as demographic research, law enforcement, as well as human-computer interaction. Recent research showed that algorithms trained on biased benchmark databases could result in algorithmic bias. However, to date, little research has been carried out on gender classification algorithms' bias towards gender minorities subgroups, such as the LGBTQ and the non-binary population, who have distinct characteristics in gender expression. In this paper, we began by conducting surveys on existing benchmark databases for facial recognition and gender classification tasks. We discovered that the current benchmark databases lack representation of gender minority subgroups. We worked on extending the current binary gender classifier to include a non-binary gender class. We did that by assembling two new facial image databases: 1) a racially balanced inclusive database with a subset of LGBTQ population 2) an inclusive-gender database that consists of people with non-binary gender. We worked to increase classification accuracy and mitigate algorithmic biases on our baseline model trained on the augmented benchmark database. Our ensemble model has achieved an overall accuracy score of 90.39%, which is a 38.72% increase from the baseline binary gender classifier trained on Adience. While this is an initial attempt towards mitigating bias in gender classification, more work is needed in modeling gender as a continuum by assembling more inclusive databases.

[Link paper](#)

Minorías subrepresentadas en dataset.

Sesgo proviene del dataset.



Algoritmo presenta tasa de precisión óptima para muestras más representadas




Métodos

Toman una base de datos sesgada (Adience, 18k fotos) y la “amplían” para mitigar sesgos

Dataset original casi no tiene personas de piel oscura




Data augmentation: ImageDataGenerator (KERAS).




Métodos

Toman una base de datos sesgada (Adience, 18k fotos) y la “amplían” para mitigar sesgos

Reentrenan en el dataset ampliado



Data augmentation: ImageDataGenerator (KERAS).



Métodos

Base de datos no binaria: 2000 imágenes, 67 personas



Figure 2: Adore De-
lano: non-binary



Figure 3: Aja: gen-
derfluid




Figure 4: Courtney
Act: genderqueer

Gender Identity	Counts	Percentage
Non-binary	24	35.82%
Genderfluid	16	23.88%
Genderqueer	11	17.91%
Gender non-conforming	5	7.46%
Agender	4	5.97%
Gender neutral	3	4.48%
Genderless	2	3.00%
Third gender	1	1.50%
Queer	1	1.50%

Table 2: Non-binary Gender Benchmark Database Gender
Identity Distribution

Métodos


Transfer learning del modelo entrenado en la base de datos Adience ampliada, para mejorar la clasificación en la base de datos no binaria (2000 imágenes, 67 personas)



Modelo de redes neuronales convolucionales. Congelan coeficientes del Augmented Adience y reentrenan con red inclusiva y no binaria.

Métodos

Transfer learning del modelo entrenado en la base de datos Adience ampliada, para mejorar la clasificación en la base de datos no binaria (2000 imágenes, 67 personas)



Prueban varias cosas:

1. Baseline feature extraction
2. Baseline Fine-tuning model
3. VGG16 Feature extraction model
4. Logistic Regression Ensemble.
5. Adaboost ensemble.

RESULTADOS

Model	Wrong Images	Accuracy Rate				Selection Rate
		Overall	Male	Female	Non-binary	
Baseline	609	51.67%	87.87%	85.75%	0%	0%
Baseline Feature Extraction	150	88.10%	89.76%	85.49%	88.82%	95.24%
Baseline Fine-tuned	149	88.17%	84.10%	88.39%	90.98%	92.44%
VGG16 Feature Extraction	185	85.32%	85.71%	83.38%	86.47%	96.43%
Logistic Regression Ensemble	121	90.39%	90.02%	88.65%	91.97%	96.40%
Adaboost Ensemble	123	90.24%	91.11%	89.71%	90.00%	98.46%

Table 3: Model Accuracy Rates and Selection Rates