


Minería de Datos


¿Qué es la Ciencia de Datos?




Ciencia de Datos: Orígenes



A close-up photograph of a document with mathematical formulas. The visible text includes:
$$= P\left(\frac{18.4 - 20}{5} < Z < \right)$$
$$= P(-0.32 < Z < 1.20)$$
$$= P(Z < 1.20) - P(Z < -0.32)$$
$$= 0.8849 - 0.3745$$
$$= 0.5104$$



Método científico “tradicional”



Método científico actual




¿Qué es la Ciencia de Datos?


“**Proceso** no trivial de identificar **patrones** en los datos que sean **válidos, novedosos, potencialmente útiles y entendibles**”

“Un patrón es una regularidad en el mundo,
algo que se repite”

Proceso de Ciencia de Datos



Proceso de Ciencia de Datos



Entender el dominio

- ¿Dónde quiero aplicar el proceso de ciencia de datos?
- ¿Cuál es el problema a resolver?
- ¿Cuáles son los objetivos?
- ¿Con qué datos cuento?

Datos: Seleccionar el conjunto de datos

- Con qué datos disponemos
- Obtener datos adicionales de ser necesario
- Integrar todos los datos

Datos: Preprocesamiento y limpieza

- Mejorar la fiabilidad de los datos
- Limpieza de datos: manejo de los **datos faltantes** y la **eliminación de ruido** o **valores atípicos**
- Cuidado: no todo es anomalía, no todo es ruido. Hay que entender el dominio del problema

Datos: Transformación

- Reducción de dimensionalidad
- Agregación y generalización
- Normalización, estandarización
- Construcción de nuevos atributos

Modelos: Selección

- Modelos de aprendizaje supervisado
 - Relación entre un conjunto de atributos y un atributo especial
 - Clasificación o regresión
- Modelos de aprendizaje no supervisado
 - Relación entre las observaciones
 - Análisis de agrupamientos, reglas de asociación

Aprendizaje supervisado: Ejemplos




- ¿Un correo electrónico es spam o no?
- ¿De qué temas habla una noticia?
- ¿Cuál es la próxima palabra que quiere escribir un usuario?
- ¿Qué quiso decir el usuario con “desime el saldo de mi kuenta”?
- ¿Qué alumno va a abandonar la universidad en primer año?

Aprendizaje no supervisado: Ejemplos

- ¿Cuáles son mis alumnos parecidos según su forma de aprender?
- ¿Puedo agrupar recetas según sus ingredientes para caracterizar cocinas del mundo?
- ¿Qué libros leen juntos los usuarios de una biblioteca?

Modelos: Selección

- ¿Qué algoritmo de aprendizaje automático vamos a utilizar?
- ¿Qué requisitos tiene cada algoritmo para los datos?
- ¿Permite que los patrones encontrados sean explicados?



Modelos: Entrenamiento

- Se ajustan los parámetros del algoritmo a los datos
- Pensar en regresión lineal
- Proceso computacional

Modelos: Evaluación

- ¿Qué tan buenos son los resultados conseguidos por el modelo?
- ¿Qué medidas para evaluar modelos uso?
- Este paso se centra en la comprensibilidad y la utilidad del modelo inducido.

Utilizar el conocimiento

- Desafío: superar las **condiciones de laboratorio**. Pasar de los datos seleccionados para ajustar el modelo al mundo real.
- Se deben verificar potenciales conflictos con conocimiento previos.
- El conocimiento puede ser incorporado en un sistema para dar soporte al proceso de toma de decisiones.

El problema de las predicciones

Problema: predicción

Tengo todos estos datos...

Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,22	0,89	4	ventas	alto	...	???
0,4	0,57	2	ventas	bajo	...	???
0,72	0,87	4	contabilidad	medio	...	???
...	...	...	...	...	...	...

y quiero predecir
“se fue” ...

Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,54	0,52	3	contabilidad	bajo	...	no
0,94	0,85	4	ventas	medio	...	no
0,79	0,71	4	RRHH	medio	...	si
0,88	0,66	4	marketing	bajo	...	no
0,92	0,77	4	ImásD	medio	...	no
0,72	0,87	5	ventas	bajo	...	si
0,44	0,46	2	técnica	bajo	...	si
0,54	0,71	5	RRHH	bajo	...	no
0,89	0,55	5	marketing	medio	...	no
...	...	...	...	...	...	...

en base a
los datos que conozco
(incluido “se fue”)

Entrada: muchos datos

Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,22	0,89	4	ventas	alto	...	???
0,4	0,57	2	ventas	bajo	...	???
0,72	0,87	4	contabilidad	medio	...	???
...	...	...	...	...	...	...

Conjunto de datos
que quiero predecir



Tienen que ser parecidos en
atributos y en distribución




Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,54	0,52	3	contabilidad	bajo	...	no
0,94	0,85	4	ventas	medio	...	no
0,79	0,71	4	RRHH	medio	...	si
0,88	0,66	4	marketing	bajo	...	no
0,92	0,77	4	ImásD	medio	...	no
0,72	0,87	5	ventas	bajo	...	si
0,44	0,46	2	técnica	bajo	...	si
0,54	0,71	5	RRHH	bajo	...	no
0,89	0,55	5	marketing	medio	...	no
...	...	...	...	...	...	...

Conjunto de datos
que conozco

Creación de un modelo

Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,54	0,52	3	contabilidad	bajo	...	no
0,94	0,85	4	ventas	medio	...	no
0,79	0,71	4	RRHH	medio	...	si
0,88	0,66	4	marketing	bajo	...	no
0,92	0,77	4	ImásD	medio	...	no
0,72	0,87	5	ventas	bajo	...	si
0,44	0,46	2	técnica	bajo	...	si
0,54	0,71	5	RRHH	bajo	...	no
0,89	0,55	5	marketing	medio	...	no
...	...	...	...	...	...	...

inducción



Modelo
(matemático
o computacional)

Tipos de modelos

Matemáticos:

$$\text{se_fue} = (\text{área} = \text{“ventas”}) * 1.1 + (\text{salario} = \text{“bajo”}) * 0.8 + 2.2$$


Computacionales:

si (área = “ventas”) y (salario = “bajo”)
entonces se fue = “si”

Salida: Predicción

Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,54	0,52	3	contabilidad	bajo	...	no
0,94	0,85	4	ventas	medio	...	no
0,79	0,71	4	RRHH	medio	...	si
0,88	0,66	4	marketing	bajo	...	no
0,92	0,77	4	ImásD	medio	...	no
0,72	0,87	5	ventas	bajo	...	si
0,44	0,46	2	técnica	bajo	...	si
0,54	0,71	5	RRHH	bajo	...	no
0,89	0,55	5	marketing	medio	...	no
...	...	...	...	...	...	...


1. Creamos el modelo



2. Ingresamos los datos a predecir al modelo



3. Usamos del modelo para predecir



Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,22	0,89	4	ventas	alto	...	???
0,4	0,57	2	ventas	bajo	...	???
0,72	0,87	4	contabilidad	medio	...	???
...	...	...	...	...	...	...

Se fue
si
no
si
...

Credibilidad del modelo

- El modelo es tan bueno como sus predicciones
- Para ver qué tan buenas son las predicciones las comparo contra la “realidad”
- Problema: no tengo la “realidad” en el momento de crear el modelo

Simulación

Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,54	0,52	3	contabilidad	bajo	...	no
0,94	0,85	4	ventas	medio	...	no
0,79	0,71	4	RRHH	medio	...	si
0,88	0,66	4	marketing	bajo	...	no
0,92	0,77	4	ImásD	medio	...	no
0,72	0,87	5	ventas	bajo	...	si
0,44	0,46	2	técnica	bajo	...	si
0,54	0,71	5	RRHH	bajo	...	no
0,89	0,55	5	marketing	medio	...	no



Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,54	0,52	3	contabilidad	bajo	...	no
0,94	0,85	4	ventas	medio	...	no
0,79	0,71	4	RRHH	medio	...	si
0,88	0,66	4	marketing	bajo	...	no
0,92	0,77	4	ImásD	medio	...	no

Conjunto de datos de entrenamiento

Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,72	0,87	5	ventas	bajo	...	si
0,44	0,46	2	técnica	bajo	...	si
0,54	0,71	5	RRHH	bajo26	...	no
0,89	0,55	5	marketing	medio	...	no

Conjunto de datos de validación

Credibilidad del modelo: Evaluación


Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...	Se fue
0,54	0,52	3	contabilidad	bajo	...	no
0,94	0,85	4	ventas	medio	...	no
0,79	0,71	4	RRHH	medio	...	si
0,88	0,66	4	marketing	bajo	...	no
0,92	0,77	4	ImásD	medio	...	no

Conjunto de datos de entrenamiento


Nivel de Satisfacción	Última Evaluación	Cantidad de Proyectos	Área	Salario	...
0,72	0,87	5	ventas	bajo	...
0,44	0,46	2	técnica	bajo	...
0,54	0,71	5	RRHH	bajo	...
0,89	0,55	5	marketing	medio	...

Conjunto de datos de validación

1. Creamos el modelo



2. Ingresamos los datos a predecir al modelo



3. Usamos del modelo para predecir



Se fue
si
si
no
no



4. Evaluamos la predicción

Predicción
si
si
no
si



Validación cruzada





Vamos a programar




Árboles de decisión



Árboles de decisión (2)




Ensambles




Bagging

- Crear m conjuntos de entrenamiento
 - En base a muestras de n registros
 - Las muestras son con reemplazo
- Entrenar m modelos base
- Ensamble agregando las predicciones de los m modelos base




Random Forests

- Crea un conjunto de árboles de decisión
- Toma muestras de registros (como *bagging*)
- Toma subconjuntos de atributos
- Paralelizable



Boosting

- Crear un modelo y verificar qué tan bien predice
- Asignar pesos a los registros de entrenamiento, más peso a los difíciles de peor predicción
- Usar los pesos para hacer una muestra con reemplazo (los difíciles van a estar repetidos)
- Crear otro modelo...



Gradient Boosting Trees

