

Minería de Datos

Preprocesamiento de datos



Datos y atributos


- Datos: Colección de entidades o hechos
- Atributos: propiedad o característica de un dato

Marca	Modelo	Año	Km	...	Precio
Ford	Focus	2010	84000	...	192000
Chevrolet	S-10	2013	67000	...	409000
Volkswagen	Bora 2.0	2011	50300	...	196500
Ford	Focus II	2012	75000	...	225000
Peugeot	308	2012	82000	...	270000
Audi	A3	2001	190000	...	135000
...	...	...	...		...

Objetos (o instancias,
ejemplos, registros, filas)

Atributos (o características, columnas, campos)

Atributos: Tipos



Atributos: Tipos

- Atributos nominales: no tienen un orden
 - Ejemplos: color, provincia, género
 - Sólo se pueden comparar por = y !=
 - Cuidado: Pueden ser números → código postal
- Atributos ordinales: tienen un orden
 - Ejemplos: altura, talle (XS, S, ...), nivel educativo
 - Se pueden comparar por =, !=, < y >

Preprocesamiento

- Datos crudos incompletos y con ruido
- Valores no consistentes
- Campos obsoletos o redundantes
- Valores faltantes
- Valores atípicos
- Formato inadecuado para modelos de minería de datos

Limpieza de datos

- Los datos en el mundo real están sucios por error del instrumento, humano, de transmisión...
- Incompleto: Atributo no tiene valor (datos faltantes)
 - Ocupación = ""
- Ruidoso: Contiene ruido, errores o valores atípicos
 - Salario = "-10", Edad = "1200"
- Inconsistente: contiene discrepancias
 - Edad = "42", fecha_de_nacimiento = "03/07/2010"
 - Mes = ["Julio", "Agosto", "8", "Sep"]
- Intencional (por ejemplo, datos faltantes disfrazados)
 - Todos nacieron el 1 de enero

Limpieza de datos: Discretización

- Transformar datos cuantitativos en cualitativos (necesario para algunos algoritmos de aprendizaje automático)
- Ejemplos:
 - Edad en $[0-12]$ → niño, $(12-21]$ → joven, $[21-65]$ → adulto y >65 → adulto mayor.
 - Calificación en $[4,10]$ → aprobado y $[0,4)$ → desaprobado
- Dividir los números en un número fijo de intervalos. El ancho del intervalo se calcula:
 - Dividiendo el rango en partes iguales
 - Dividiendo la cantidad de ejemplos en partes iguales (igual frecuencia)
 - Indicando los límites de cada intervalo en forma manual

Limpieza de datos: Numerización

- Convertir atributos cualitativos en cuantitativos (proceso contrario a la discretización)
- Algunos algoritmos de aprendizaje automático sólo operan con atributos cuantitativos
- Atributos:
 - Nominales a binarios
 - {rojo, amarillo, azul} $\rightarrow$ {(1,0,0), (0,1,0), (0,0,1)}
 - Ordinales a enteros
 - XS $\rightarrow$ 1, S $\rightarrow$ 2, M $\rightarrow$ 3 ...
 - primaria $\rightarrow$ 1, secundaria $\rightarrow$ 2,

Limpieza de datos: Datos faltantes

- Los datos no siempre están disponibles o no es posible conseguirlo
 - Ingresos de un cliente
- Pueden deberse a:
 - Mal funcionamiento de un equipo de medición
 - Datos considerados no importantes en el momento de la entrada
- Estrategias:
 - Imputar valores (ponerles un valor)
 - Eliminar registros (en lo posible no)
 - No hacer nada (!)

Integración de datos

- Combinar datos de múltiples fuentes en un único conjunto coherente
- Problema de identificación de entidades a partir de múltiples fuentes de datos.
 - Por ejemplo, Bill Clinton = William Clinton
- Detectar y resolver conflictos de valores de datos:
 - Para la misma entidad del mundo real, los valores de los atributos de diferentes fuentes son diferentes
- Posibles razones: diferentes representaciones, diferentes escalas, por ejemplo, unidades métricas vs. británicas

Redundancia

- De atributos

- Ocurren a menudo cuando se integran múltiples bases de datos
- Mismo atributo con diferentes nombres en diferentes conjuntos de datos
- Cómo detectarlos
 - análisis de correlación
 - análisis de covarianza



Lo van a ver en AID o EEA

- De observaciones

- Registros duplicados o cuasi-duplicados
- Pueden deberse a que faltan atributos para distinguirlos

Vamos a programar

