

Minería de datos

Análisis de valores atípicos

Análisis de valores atípicos (*outliers*)



“Un *valor atípico* es una observación que se desvía tanto de las otras observaciones como para despertar sospechas que fue generado por un mecanismo diferente”

D. Hawkins. Identification of Outliers

Análisis

Univariado

- Valores **atípicos** que podemos encontrar en una única variable.
- Problema: son buenos para detección de extremos pero no en otros casos


Multivariado

- Se pueden encontrar en un espacio n-dimensional.
- Para detectarlos es necesario ajustar un modelo

Métodos

Métodos Univariados

BoxPlot Petal.Length por Species



- ❑ IQR: Analizar los valores que están por fuera del IQR
- ❑ Z-score y Z-score Modificado
- ❑ Identificar valores extremos a partir de 1, 2 o 3 desvíos de la media.

Métodos Multivariados


- ❑ Análisis globales: Clustering.
 - ❑ Utilizando medidas de distancia como Mahalanobis.
- ❑ *Local Outlier Factor* (LOF)
 - ❑ Método basado en distancias
 - ❑ Calcula un *score* de *outlier* a partir de una distancia que se normaliza por densidad.
- ❑ IsolationForest
 - ❑ Métodos basados en árboles de búsqueda

Métodos univariados: Box-Plot

Los Box-Plots permiten visualizar valores extremos univariados.


Las estadísticas de una distribución univariada se resumen en términos de cinco cantidades:

- Mínimo/máximo (bigotes)
- Primer y tercer cuartil (caja)
- Mediana (línea media de la caja)
- $IQR = Q3 - Q1$
- Generalmente la regla de decisión es $\pm 1.5 \cdot IQR$




Métodos univariados: Limitaciones

Ejemplo: Outliers



Box-Plot de la variable Y




Métodos multivariados

Una forma de tratar con tales valores es sacar los valores más altos y más bajos de una variable.

Esto puede funcionar bastante bien, pero no tiene en cuenta las **combinaciones de variables**.

¿Qué ocurre con los casos ● ?



Distancia de Mahalanobis

Mide la distancia de un punto y una distribución

Es una medida de distancia entre un punto $\vec{x} = (x_1, x_2, x_3, \dots, x_N)^T$,

el vector de medias $\vec{\mu} = (\mu_1, \mu_2, \mu_3, \dots, \mu_N)^T$

y la matriz de covarianza S.


$$D_M(\vec{x}) = \sqrt{(\vec{x} - \vec{\mu})^T S^{-1} (\vec{x} - \vec{\mu})}.$$

Matriz de distancias con
respecto a la media


Inversa de la matriz de
covarianzas

Distancia de Mahalanobis


Mahalanobis (Top@5)



Mahalanobis (Top@10)



Mahalanobis (Top@15)




Local Outlier Factor (LOF)

El Local Outlier Factor (LOF) se basa en el concepto de **densidad local**, donde la localidad viene dada por k vecinos más cercanos, cuya distancia se utiliza para estimar la densidad.

Se compara la densidad local de cada punto con las densidades locales de sus vecinos

- Conjuntos de densidad similar
- Puntos que tienen una densidad sustancialmente menor que sus vecinos → valores atípicos



LOF: Componentes del cálculo

La k-distancia de una observación $\mathbf{o}$, $\mathbf{dist}_k(\mathbf{o})$: Es la distancia entre $\mathbf{o}$ y su k -ésimo vecino más cercano (kNN)

La vecindad de $\mathbf{o}$ se define como $N_k(\mathbf{o}) = \{\mathbf{o}' \mid \mathbf{dist}(\mathbf{o}, \mathbf{o}') \leq \mathbf{dist}_k(\mathbf{o})\}$

La distancia de vecindad son todas las distancias dentro del radio de $\mathbf{dist}_k(\mathbf{o})$

La distancia esperada de $\mathbf{o}'$ a $\mathbf{o}$ se define como $\mathbf{reachdist}_k(\mathbf{o}' \leftarrow \mathbf{o}) = \max(\mathbf{dist}_k(\mathbf{o}), \mathbf{dist}(\mathbf{o}, \mathbf{o}'))$, esto es la distancia real de $\mathbf{o}$ a $\mathbf{o}'$ o al menos $\mathbf{dist}_k(\mathbf{o})$. Los datos que están en $N_k(\mathbf{o})$ se consideran con distancia igual.

La Densidad de Accesibilidad Local (Local Reachability Density) es la distancia en que $\mathbf{o}$ puede ser “accedida” desde sus vecinos se define como:


$$lrd_k(o) = \frac{\|N_k(o)\|}{\sum_{o' \in N_k(o)} reachdist_k(o' \leftarrow o)}$$

$$LOF_k(o) = \frac{\sum_{o' \in N_k(o)} \frac{lrd_k(o')}{lrd_k(o)}}{\|N_k(o)\|}$$

LOF: Ejemplo

Dado el siguiente conjunto de datos:

	x	y
a	0	0
b	0	1
c	1	1
d	3	0



Paso 1: Calcular la matriz de distancias.


	a	b	c
b	1		
c	2	1	
d	3	4	3

Para el ejemplo utilizamos distancia de Manhattan:

$$d_1(\mathbf{p}, \mathbf{q}) = \|\mathbf{p} - \mathbf{q}\|_1 = \sum_{i=1}^n |p_i - q_i|$$

LOF: Ejemplo

Paso 2: Calculamos las distancias al k-ésimo vecino más cercano. Para este ejemplo **k=2**



La distancia del k=2 vecino más cercano es la distancia de $a \rightarrow c$

$$\text{Dist}_2(a) = \text{dist}(a, c) = 2$$

Recordemos la matriz de distancias para a:

El 2do NN es **c**

	a	b	c
b	1		
c	2	1	
d	3	4	3

$$\text{Dist}_2(b) = \text{dist}(b, a) = 1$$


$$\text{Dist}_2(c) = \text{dist}(c, a) = 2$$

$$\text{Dist}_2(d) = \text{dist}(d, a) = 3$$


LOF: Ejemplo

Paso 3: Calculamos todas las distancias de la vecindad: $N_k(o)$

$$N_k(o) = \{o' \mid o' \text{ in } D, \text{dist}(o, o') \leq \text{dist}_k(o)\}$$




$$N_2(a) = \{b, c\}$$



$$N_2(b) = \{a, c\}$$


LOF: Ejemplo

$N_k(c)$: Vecinos de c
 $k=2$



$$N_2(c) = \{b, a\}$$

$N_k(d)$: Vecinos de d
 $k=2$



$$N_2(d) = \{a, c\}$$

LOF: Ejemplo

Paso 4: Calculamos todos los $LDR_k(o)$

$$LDR_2(a) = \frac{\|N_2(a)\|}{reachdist_2(b \leftarrow a) + reachdist_2(c \leftarrow a)} = \frac{2}{1+2} = 0.667$$

$$LDR_2(b) = \frac{\|N_2(b)\|}{reachdist_2(a \leftarrow b) + reachdist_2(c \leftarrow b)} = \frac{2}{2+2} = 0.5$$

$$LDR_2(c) = \frac{\|N_2(c)\|}{reachdist_2(a \leftarrow c) + reachdist_2(b \leftarrow c)} = \frac{2}{1+2} = 0.667$$

$$LDR_2(d) = \frac{\|N_2(d)\|}{reachdist_2(a \leftarrow d) + reachdist_2(c \leftarrow d)} = \frac{2}{3+3} = 0.33$$

LOF: Ejemplo

Paso 5: Calcular $LOF_k(o)$

$$LOF_2(a) = (lrd_2(b) + lrd_2(c)) * (reachdist_2(b \leftarrow a) + reachdist_2(c \leftarrow a)) = (0.5 + 0.667) * (1 + 2) = 3.501$$

$$LOF_2(b) = (lrd_2(a) + lrd_2(c)) * (reachdist_2(a \leftarrow b) + reachdist_2(c \leftarrow b)) = (0.667 + 0.667) * (2 + 2) = 5.336$$

$$LOF_2(c) = (lrd_2(b) + lrd_2(a)) * (reachdist_2(b \leftarrow c) + reachdist_2(a \leftarrow c)) = (0.5 + 0.667) * (1 + 2) = 3.501$$

$$LOF_2(d) = (lrd_2(a) + lrd_2(c)) * (reachdist_2(a \leftarrow d) + reachdist_2(c \leftarrow d)) = (0.667 + 0.667) * (3 + 3) = 8.004$$

LOF: Ejemplo

Paso 6: Ordenamos todos los valores de $\text{LOF}_k(o)$

$$\text{LOF}_2(d) = \mathbf{8.004} \leftarrow$$


Una vez que ordenamos tenemos que definir un umbral de corte.

$$\text{LOF}_2(b) = 5.336$$

$$\text{LOF}_2(a) = 3.501$$

$$\text{LOF}_2(c) = 3.501$$

En este caso el punto **d** es un claro valor atípico.



Ventajas y desventajas

- Ventajas



- Un punto se considerará un valor atípico si está a una distancia pequeña del clúster extremadamente denso.
 - El enfoque global podría no considerar ese punto como un valor atípico.
 - LOF puede identificar eficazmente los valores atípicos locales.

- Desventajas

- Como el LOF es un ratio, es difícil de interpretar.
- No existe un valor umbral específico por encima del cual un punto se define como un valor atípico.
- La identificación de un valor atípico depende del problema y del usuario.
- Es un método con problemas de escalabilidad

Métodos multivariados: Isolation Forest

Idea Principal: las anomalías se pueden aislar de los datos normales mediante la partición recursiva del conjunto de datos, ya que requieren menos particiones para separarlas



Isolation Forest: Algoritmo

Pasos del algoritmo

Generar n árboles haciendo:

1. Obtener una muestra del conjunto de datos
2. Seleccionar un atributo del conjunto de datos
3. Seleccionar un valor de partición en ese atributo (un valor p entre el min / max)
4. Repetir los paso 2 y 3 en todas las particiones (hasta que no pueda dividir)

Calcular el *score* para cada punto y todos los árboles generados

- a. Si es cercano a 1 $\rightarrow$ anomalía
- b. Si es cercano a 0.5 $\rightarrow$ normal

Isolation Forest: Score

$$score = 2^{-\frac{E(h(x))}{c(n)}}$$

Donde:

- $h(x)$ es la longitud del camino a x
- $E(h(x))$ es la media de las alturas de x en todos los árboles
- $c(n)$ es una constante de normalización puede ser calculado como:

$$c(n) = 2H(n-1) - (2(n-1)/n),$$

$H(i)$ es el número armónico $H(i) = \ln(i) + 0.5772156649$ (constante de Euler)

Isolation Forest: Propiedades

- Construye un árbol de manera **no supervisada**
- Utiliza la **altura del árbol** en lugar de las medidas de distancia o densidad
- **Puede escalar** para manejar datos de gran dimensión

Bibliografía

- ❑ Jiawei Han, Micheline Kamber, Jian Pei. 2012. Tercera edición. Data Mining: Concepts and Techniques. Cap. 12
- ❑ Breunig, M. M., Kriegel, H. P., Ng, R. T., & Sander, J. (2000, May). LOF: identifying density-based local outliers. In Proceedings of the 2000 ACM SIGMOD international conference on Management of data (pp. 93-104). [[pdf](#)]
- ❑ Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008, December). Isolation forest. In 2008 eighth iee international conference on data mining (pp. 413-422). IEEE. [[pdf](#)]

Bibliografía complementaria

- ❑ Salgado, C. M., Azevedo, C., Proença, H., & Vieira, S. M. (2016). Noise versus outliers. In Secondary Analysis of Electronic Health Records (pp. 163-183). Springer, Cham. [[html](#)]
- ❑ Iglewicz, B., & Hoaglin, D. C. (1993). How to detect and handle outliers (Vol. 16). Asq Press. [[pdf](#)]

Para saber más...

- PyOD: <https://pyod.readthedocs.io/en/latest/>
- TODS - Automated Time-series Outlier Detection System:
<https://github.com/datamllab/tods>
- Outliers Detection Datasets: <http://odds.cs.stonybrook.edu/>