

Minería de Datos

Datos Faltantes

Datos faltantes

- ❑ El problema de los ***datos faltantes*** está presente en el análisis de datos desde los **orígenes del almacenamiento**
- ❑ Al incrementarse los volúmenes de datos analizados sube la probabilidad de inconsistencias y faltantes

Razones de la inconsistencia

- ❑ **Factores propios del procedimiento**
Formularios mal diseñados, errores de programación, errores de medición...
- ❑ **Negativa a responder**
Cuestiones relacionadas con la edad, sueldo, afiliación política, religión...
- ❑ **Respuestas inaplicables**
¿Cuánto gastó en juguetes para sus hijos el último año?...
→ no tiene hijos

Datos faltantes: Tipos

- ***Missing completely at random (MCAR)***

- Ocurre cuando los eventos que llevaron a tener un dato faltante son independientes de las variables observadas y las no observadas
- La falta de datos no está relacionada a ninguna variable en estudio
- Los participantes que no tienen datos faltantes son una muestra al azar de la totalidad de los participantes

- ***Missing At Random (MAR)***

- El patrón de los datos faltantes se puede predecir a partir de otras variables del conjunto de datos
- No hay forma estadística de comprobar este patrón.
- Ejemplo: El peso es MAR si es más probable que los adolescentes digan su peso que las personas entre 50 y 60 años

Datos faltantes: Tipos

- ***Missing not at random (MNAR)***

- Los datos no son MAR ni MCAR, esto es, el valor de la variable que falta está relacionado con la razón por la que falta
- Ejemplo: una persona no llena una encuesta sobre depresión por su depresión

- **Valores atípicos como datos faltantes**

- Si se conocen los límites de las variables del conjunto de datos, los datos que caen fuera del rango esperado pueden ser tratados como datos faltantes

`edad == 120`

`horas_de_clase == -12`

Métodos para tratar con datos faltantes

- ❑ **Utilizar solo registros completos:** Esto va a depender de cómo es el origen del faltante.
 - ❑ Recomendado sólo en casos MCAR
- ❑ **Borrar casos seleccionados o variables:** La eliminación de registros ante la presencia de faltantes puede utilizarse cuando hay un **patrón no aleatorio de datos faltantes**.
 - ❑ Si la eliminación de un subconjunto disminuye significativamente la utilidad de los datos, la eliminación del caso puede no ser efectiva.
- ❑ **Imputación de datos:** Métodos de relleno de faltantes.
- ❑ Aproximaciones basadas en modelos: Múltiples imputaciones

Imputación de datos

- ❑ Métodos de relleno de datos ante la presencia de datos faltantes
- ❑ Proceso de estimar datos faltantes de una observación a partir de valores válidos de otras variables.
- ❑ Cuidado: pueden generar sesgos importantes entre los datos reales y los imputados

Imputación por sustitución


- ❑ **Sustitución de casos.** Se reemplaza con valores no observados. Debería ser realizado por un experto en esos datos.
- ❑ **Sustitución de medias.** Se reemplaza utilizando el promedio calculado de los valores presentes. Debe verificarse que los datos se ajusten a una distribución normal, si los datos están sesgados es mejor utilizar la mediana.

Desventajas:

- ❑ La varianza estimada de la nueva variable no es válida porque estará atenuada por los valores repetidos
- ❑ Se distorsiona la distribución
- ❑ Las correlaciones que se observen estarán deprimidas debido a la repetición de un solo valor constante.

Imputación: Cold Deck

- ❑ Selecciona valores o usar relaciones obtenidas de fuentes distintas de la base de datos actual.
- ❑ Se **sustituye un valor constante** derivado de fuentes externas o de investigaciones previas.
- ❑ Mismas desventajas de aplicar la media.



Imputación: Hot Deck

Se reemplazan los faltantes con valores obtenidos de registros que son los más similares.

Ventajas de hot deck:

- ❑ Conceptualmente simple
- ❑ Conserva los niveles de medición adecuados para las variables
- ❑ Finaliza el proceso de imputación con un conjunto completo de datos.

Desventajas:

- ❑ Dificultad para definir similitud

Table I

Illustration of hot deck imputation: incomplete data set

Case	Item 1	Item 2	Item 3	Item 4
1	10	2	3	5
2	13	10	3	13
3	5	10	3	???
4	2	5	10	2

Table II

Illustration of hot deck imputation: imputed data set

Case	Item 1	Item 2	Item 3	Item 4
1	10	2	3	5
2	13	10	3	13
3	5	10	3	13
4	2	5	10	2

Imputación utilizando regresiones

- ❑ Se utiliza el análisis de regresión para predecir valores faltantes a partir de variables relacionadas en el conjunto de datos.
- ❑ Se pueden utilizar regresiones simples o múltiples.
- ❑ Se identifican las variables independientes y dependientes.

	caso	income	age	years_of_college
1	1	45251.25	26	4
2	2	62498.27	45	6
3	3	49350.32	28	5
4	4	46424.92	28	4
5	5	56077.27	46	4
6	6	51776.24	38	4
7	7	51410.97	35	4
8	8	64102.33	50	6
9	9	45953.96	45	3
10	10	50818.87	52	5
11	11	49078.98	30	0
12	12	61657.42	50	6
13	13	54479.90	46	6
14	14	64035.71	48	6
15	15	51651.50	50	6
16	16	46326.93	31	3
17	17	53742.71	50	4
18	18	59786.8	55	6
19	19	50660.4	35	4
20	20	53418.2	39	5

Imputaciones múltiples y usando modelos

MICE

Multivariate imputation by chained equations (MICE).

MICE opera bajo el supuesto de que el origen de los faltantes es Missing At Random (MAR).




La probabilidad de que falte un valor depende solo de los valores observados y no de los valores no observados.

Cuidado: La aplicación de MICE a datos que no son MAR puede generar resultados sesgados.

MICE : Pasos

El proceso de *Chained Equation* se puede dividir en cuatro pasos generales:



Una vez que se procesan todas las variables con faltantes se cumple un **ciclo o iteración**.

Estos ciclos pueden repetirse varias veces, según la bibliografía 10 veces es suficiente.

MICE: Ejemplo

Conjunto inicial con datos faltantes

Age	Income	Gender
33	N.A.	F
18	12,000	N.A.
N.A.	13,542	M

Paso 2: Pasamos a faltante uno de los casos imputados en 1

Age	Income	Gender
33	12,771	F
18	12,000	F
N.A.	13,542	M

Paso 1: Imputación puntual

Age	Income	Gender
33	12,771	F
18	12,000	F
25.5	13,542	M

Paso 3: Ajustamos un modelo con los casos completos

Age	Income	Gender
33	12,771	F
18	12,000	F
N.A.	13,542	M

Paso 4: Imputamos con el valor que surja de aplicar el modelo

Age	Income	Gender
33	12,771	F
18	12,000	F
35.3	13,542	M

MICE: Ejemplo

Paso 2: Pasamos a faltante uno de los casos imputados en 1

Age	Income	Gender
33	N.A	F
18	12,000	F
35.3	13,542	M

Paso 3: Ajustamos un modelo con los casos completos

Age	Income	Gender
33	N.A	F
18	12,000	F
35.3	13,542	M

Paso 4: Imputamos con el valor que surja de aplicar el modelo

Age	Income	Gender
33	13,103	F
18	12,000	F
35.3	13,542	M

Age	Income	Gender
33	13,103	F
18	12,000	M
35.3	13,542	M

Por último se modela Gender y se completa la primera iteración.

Con los valores imputados en este 1er ciclo y utilizando la máscara de faltantes se vuelve a iterar.

Imputación usando modelos

- ❑ Se suele usar KNN (k-vecinos más cercanos)
- ❑ Se usa una métrica de distancia euclidiana que admite valores perdidos para encontrar los vecinos más cercanos.
- ❑ Cada característica faltante se imputa usando valores de los vecinos más cercanos que tienen un valor para dicha característica.
- ❑ Las características de los vecinos se promedian uniformemente o se ponderan por la distancia a cada vecino.

Marcar los valores imputados

- ❑ Cuando se utiliza la imputación, conservar la información sobre los valores que faltan puede ser informativo.
- ❑ Se utiliza una marca binaria que dice si un valor fue imputado o no, para aquellas características con valores faltantes

Bibliografía

- ❑ Brown, M. L., & Kros, J. F. (2003). Data mining and the impact of missing data. *Industrial Management & Data Systems*, 103(8), 611-621. [[pdf](#)]
- ❑ Kwak, S. K., & Kim, J. H. (2017). Statistical data preparation: management of missing values and outliers. *Korean journal of anesthesiology*, 70(4), 407-411. [[pdf](#)]
- ❑ Andridge, R. R., & Little, R. J. (2010). A review of hot deck imputation for survey non-response. *International statistical review*, 78(1), 40-64. [[pdf](#)]
- ❑ Azur, M. J., Stuart, E. A., Frangakis, C., & Leaf, P. J. (2011). Multiple imputation by chained equations: what is it and how does it work?. *International journal of methods in psychiatric research*, 20(1), 40-49. [[pdf](#)]
- ❑ Olga Troyanskaya, Michael Cantor, Gavin Sherlock, Pat Brown, Trevor Hastie, Robert Tibshirani, David Botstein and Russ B. Altman, Missing value estimation methods for DNA microarrays, *BIOINFORMATICS* Vol. 17 no. 6, 2001 Pages 520-525.