

Minería de Datos

Ingeniería de atributos

Agenda

- ❑ Ingeniería de atributos
- ❑ Normalización
- ❑ Discretización
- ❑ Sesgos y transformaciones

Ingeniería de atributos

- ❑ Transformación de datos
 - ❑ en formatos adecuados para los modelos de aprendizaje automático
 - ❑ y para mejorar la interpretación de los datos

Normalización

- ❑ Escalar atributos numéricos para mapearlos a un rango más pequeño.
 - ❑ Ejemplo: edad $\rightarrow [0, 1]$ ó temperatura $\rightarrow [-1, 1]$.
- ❑ Utilizada cuando las unidades de medidas dificultan la comparación de atributos (distancias en agrupamiento)
- ❑ Ayuda a evitar que atributos con mayores magnitudes tengan mayor peso que los rangos pequeños.
- ❑ Métodos más utilizados: Min-Max, Z-Score y Decimal Scaling

Normalización Min-Max

$$X_{mm}^* = \frac{X - \min(X)}{\text{range}(X)} = \frac{X - \min(X)}{\max(X) - \min(X)}$$

- ❑ Valores normalizados van de 0 a 1.
- ❑ Dominada por los valores atípicos

Sepal.Length

Min.	4.300
1st Qu.	5.100
Median	5.800
Mean	5.843
3rd Qu.	6.400
Max.	7.900


$$X_{mm} = \frac{X - 4.3}{7.9 - 4.3}$$

Para los valores extremos es 0 y 1

Normalización Z-Score (estandarización)

$$Z\text{-score} = \frac{X - \text{mean}(X)}{sd(X)}$$

Útil cuando...

- ❑ el verdadero mínimo y máximo son desconocidos
- ❑ hay valores atípicos que dominan la normalización min-max. Acá se puede usar la mediana

Sepal.Length

Min.	4.300
1st Qu.	5.100
Median	5.800
Mean	5.843
3rd Qu.	6.400
Max.	7.900


$$Z\text{-score} = \frac{4.3 - 5.843}{0.828} = -1,863$$


$$Z\text{-score} = \frac{7.9 - 5.843}{0.828} = 2,484$$

Normalización: No centrar datos dispersos

- ❑ Normalización y estandarización restan una cantidad al valor de la característica original (mínimo y media)
- ❑ En atributos con datos dispersos (la mayoría 0), esta resta convierte todos los ceros en un número, **pasa de disperso a denso**.
- ❑ Sube el costo computacional
- ❑ Atributos de minería de texto suelen ser dispersos

Normalización Decimal Scaling


Decimal Scaling asegura que cada valor normalizado se encuentra entre - 1 y 1.

$$X_{decimal} = \frac{X}{10^d}$$

donde **d** es el número de dígitos en los valores de la variable con el valor absoluto más grande.

Sepal.Length		
Min.	4.300	$X_{decimal} = \frac{4.3}{10^1}$
1st Qu.	5.100	
Median	5.800	
Mean	5.843	
3rd Qu.	6.400	$X_{decimal} = \frac{7.9}{10^1}$
Max.	7.900	

Comparación de métodos



Transformaciones

- ❑ La transformación es el reemplazo de una variable por una función de esa variable
 - ❑ Ejemplo, reemplazar una variable x por la raíz cuadrada de x ó el logaritmo de x
- ❑ En un sentido más fuerte, una transformación es un reemplazo que cambia la forma de una distribución
- ❑ Se usa para reducir los sesgos en los datos o tener dispersiones similares



Transformaciones

Logaritmo (base 10 o natural)









- ❑ No se puede aplicar a valores ≤ 0
- ❑ Usada en *power functions*

Raíz cuadrada

- ❑ Se puede aplicar a 0
- ❑ Se puede usar cúbica





Ejemplo: Spotify liveness, instrumentality



Discretización

- ❑ Divide el rango de una variable continua en intervalos.
- ❑ Valores continuos → número reducido de etiquetas.



Discretización: Características

La discretización puede ser caracterizada según cómo se realiza:

- ❑ Si utiliza la clase como información
 - ❑ Si la utiliza será **supervisada**
 - ❑ Si no la utiliza será **no supervisada**
- ❑ Según la orientación en la que realice las particiones recursivas:
 - ❑ **Top-down**: Parte de algunos pocos puntos de *splitting* y trata de separar todo el rango
 - ❑ **Bottom-up**: Considera a todos los puntos como posibles separadores del rango

Discretización no supervisada: Binning

- ❑ Se separan los datos en un número definido de **bins**
- ❑ Criterios de agrupamiento:
 - ❑ Igual frecuencia: Misma cantidad de observaciones en cada bin.
 - ❑ Igual ancho: Definimos rangos o intervalos de clases para cada bin.
 - ❑ K-means: Agrupa según distancia
- ❑ En cada bin se puede reemplazar los valores por la **media** o **mediana** o por una etiqueta (valor entero)
- ❑ No se utiliza la información de la clase → no supervisado.

Binning: Ejemplos

Vamos a discretizar **X** en 3 categorías.


$X = \{1, 1, 1, 1, 1, 2, 2, 11, 11, 12, 12, 44\}$

Igual ancho




Bajo: $0 \leq X < 15$
Medio: $15 \leq X < 30$
Alto: $30 \leq X < 45$

Igual frecuencia



$n = 12$
 $\text{bins} = 3$
 $n/\text{bins} = 4$

K-means



$k = 3$

Discretización no supervisada: rank

- ❑ **Rank:** El ranking de un número **es su tamaño relativo a otros valores**
 - ❑ Ordenamos la lista de valores
 - ❑ Asignamos la posición de un valor como su rango
- ❑ Valores con decimales → redondear a entero
- ❑ Cuidado: los valores pueden tener rangos diferentes en diferentes listas

Ejemplo:

$X = \{1, 1, 1, 1, 1, 2, 2, 11, 11, 12, 12, 44\}$

$\text{Rank}_x = \{1, 1, 1, 1, 1, 2, 2, 3, 3, 4, 4, 5\}$

Discretización supervisada: basada en Entropía

- ❑ Usa distribución de información en la clase para el cálculo y determinación del **split-point**
- ❑ Para un dataset $D \rightarrow \{A_1, \dots, A_N\}$ el método para discretizar A es:
 1. Cada **valor de A** se considera como un posible **split-point** para hacer una discretización **binaria**
 2. Se calcula la **entropía** para la clase $E(S) = \sum -p_i \ln p_i$
 3. Se calcula la **entropía** para la clase y el **split-point** a evaluar $E(S, A) = \sum \frac{|S_v|}{|S|} E(S_v)$
 4. Se calcula la **Ganancia de información** para esa partición, como:
$$InformationGain = E(S) - E(S, A)$$

Discretización basada en Entropía: Ejemplo

Discretizar la variable de temperatura usando el algoritmo basado en entropía.

Paso 1: Calcular la entropía de la clase

$$E(\text{Failure}) = E(7, 17) = -0.29 * \log_2(0.29) - 0.71 * \log_2(0.71) = 0.871$$

Paso 2: Calcular la entropía para la variable objetivo dado un bin (=60)

$$\begin{aligned} E(\text{Failure}, \text{Temperature}) &= P(\leq 60) * E(3, 0) + P(> 60) * E(4, 17) = \\ &= \frac{3}{24} * 0 + \frac{21}{24} * 0.7 = 0.615 \end{aligned}$$

O-Ring Failure	
Y	N
7	17

Paso 3: Calcular la ganancia de Información (GI) dado un bin

$$GI = E(S) - E(S, A)$$

$$GI(\text{Failure}, \text{Temperature}) = 0.256$$

		O-Ring Failure	
		Y	N
Temperature	≤ 60	3	0
	> 60	4	17

Discretización supervisada: Peso de la evidencia

- ❑ El peso de la evidencia (WoE, *weight of evidence*) indica el poder predictivo de una variable independiente en relación con la variable dependiente
- ❑ Dado que evolucionó del mundo de la calificación crediticia, generalmente se describe como una medida de la separación de buenos y malos clientes.
- ❑ Se define como el logaritmo natural de la proporción de eventos positivos contra eventos negativos

$$WOE = \ln\left(\frac{\text{Event}\%}{\text{Non Event}\%}\right)$$

Peso de la evidencia: Cálculo

1. Para una variable continua, dividir los datos en 10 partes (o menos dependiendo de la distribución). Para una variable categórica, no hacer nada.
2. Calcular el % de eventos y el % no eventos en cada grupo (bin)
3. Calcular el WoE tomando el logaritmo natural de la división del % de no eventos y el % de eventos
4. Reemplazar los valores de la variable por los valores WoE

Range	Bins	Non events	Events	% of Non-Events	% of Events	WOE
0-50	1	197	20	5.4%	5.9%	-0.0952
51-100	2	450	34	12.3%	10.1%	0.2002
101-150	3	492	39	13.4%	11.5%	0.1522
151-200	4	597	51	16.3%	15.1%	0.0774
201-250	5	609	54	16.6%	16.0%	0.0401
251-300	6	582	55	15.9%	16.3%	-0.0236
301-350	7	386	41	10.5%	12.1%	-0.1405
351-400	8	165	23	4.5%	6.8%	-0.4123
>401	9	184	21	5.0%	6.2%	-0.2123
	Total	3662	338			

Peso de la evidencia: Reglas

- ❑ Cada categoría (bin) debe tener al menos el 5% de las observaciones.
- ❑ La cantidad de eventos y no eventos en cada categoría (bin) debe ser distinta a cero
- ❑ El WoE debe ser distinto para cada categoría. Se deben agregar grupos similares.
- ❑ Los valores faltantes se agrupan por separado.
- ❑ Idea: se puede usar para reagrupar valores categóricos

Bibliografía

- ❑ Jiawei Han, Micheline Kamber, Jian Pei. 2012. Tercera edición. Data Mining: Concepts and Techniques. Cap. 2 y Cap. 3
- ❑ Daniel T. Larose. 2014. Segunda edición. Discovering Knowledge in Data: An Introduction to Data Mining.
- ❑ Should I normalize/standardize/rescale the data? [[link](#)]
- ❑ Zheng, A., & Casari, A. (2018). Feature engineering for machine learning: principles and techniques for data scientists. " O'Reilly Media, Inc.".
- ❑ Zuur, A. F., Ieno, E. N., & Elphick, C. S. (2010). A protocol for data exploration to avoid common statistical problems. *Methods in Ecology and Evolution*, 1(1), 3–14. [[pdf](#)]
- ❑ Nargesian, F., Samulowitz, H., Khurana, U., Khalil, E. B., & Turaga, D. (2017). Learning feature engineering for classification. *IJCAI International Joint Conference on Artificial Intelligence*, 2529–2535. [[pdf](#)]