


# Minería de Datos

Reducción de dimensionalidad

# Problema




# Estrategias de reducción

Estrategias de reducción de datos:

- ❑ **Reducción de dimensionalidad:** Remover atributos que no son importantes.
  - ❑ Componentes Principales (PCA), Pares correlacionados, VarImp, Escalado multidimensional, etc.
  
- ❑ **Reducción de datos**
  - ❑ Representar los datos a partir de modelos.
  - ❑ Histogramas, agrupamiento, muestreo, agregación, discretización, etc

# Reducción de dimensionalidad

- ❑ **Maldición de dimensionalidad**
  - ❑ Cuando aumenta la dimensionalidad, **los datos se vuelven cada vez más malos.**
  - ❑ La densidad y la distancia entre los puntos, se vuelve menos significativa.



# Reducción de dimensionalidad

- ❑ Evitar la maldición de la dimensionalidad
- ❑ Ayudar a eliminar características irrelevantes y reduce el ruido
- ❑ Reducir el tiempo y el espacio necesarios en la extracción de datos
- ❑ Facilitar la interpretación visual. Permitir una visualización más simple de los datos.

# Eliminar columnas con datos faltantes

- ❑ Si bien podemos trabajar en imputación de datos faltantes, a veces no es posible rellenar
- ❑ **Criterio de eliminación:** Predominio de datos faltantes.
  - ❑ Por ejemplo, Atributos con menos del 5% o 10% de valores.
- ❑ Se calcula la proporción de faltantes y se busca un valor de corte que sea óptimo.
  - ❑ En un problema de clasificación podemos buscar el % de eliminación que maximiza la precisión.
- ❑ Este método aplica tanto a variables numéricas como categóricas.

# Eliminar columnas con baja varianza

- ❑ Una forma de medir cuánta información tiene una columna de datos es medir su varianza.
  - Caso límite: valor constante → **varianza es 0** y la columna no sería de ayuda en la discriminación de diferentes grupos de datos.
- ❑ Se calcula la varianza para cada uno de los atributos y remueve aquellos que están por debajo de un umbral.

- ❑ Los rangos de columna de datos deben **normalizarse** para que los valores de varianza sean independientes del rango del dominio de la columna.

# Reducción utilizando prueba de ji-cuadrado

- ❑ La prueba de ji-cuadrado mide la dependencia entre dos atributos
- ❑ Se eliminan aquellos atributos con valores más altos para el estadístico de la prueba  $X^2$  entre la clase y dicho atributo
  - ❑ Se aplica a atributos categóricos y no negativos
- ❑ Se quitan las variables con mayor probabilidad de ser independientes de la clase y, por lo tanto, irrelevantes para la clasificación.



# Eliminación de atributos con alta correlación

- ❑ Los atributos correlacionados introducen **redundancia** en el conjunto de datos
- ❑ No agregan información y tornan complejo el modelado.
- ❑ Se puede eliminar uno de los dos atributos sin disminuir drásticamente la cantidad de información disponible.
- ❑ El método puede ser utilizado con variables continuas o discretas con **Coeficiente de correlación de Pearson** y **Prueba  $\chi^2$  de Pearson**.

# Eliminación de atributos con alta correlación


Se eliminan pares de columnas correlacionadas a partir de la matriz de correlaciones.

1. Se define un umbral de correlación
2. Seleccionamos pares con valores mayores al umbral
3. El criterio es conservar la variable que en el resto de las correlaciones sea en promedio menor

Ejemplo:

Umbral = 0.7

Displacement vs Cylinders




# Eliminación recursiva de atributos

- ❑ Se usa un modelo que puede asignar pesos a las características
  - Por ejemplo, coeficientes de un modelo lineal o importancia de atributos de *random forests*
- ❑ Procedimiento:
  - Se entrena el modelo en el conjunto de características
  - Se obtiene la importancia de cada característica
  - Se eliminan las características menos importantes
- ❑ Se repite el procedimiento hasta que se alcanza el número deseado de características para seleccionar


# Eliminación secuencial de atributos: forward

- ❑ Se entrena un modelo usando cada atributo por separado ( $\{a\}$ ,  $\{b\}$  ...) y se mide su rendimiento
- ❑ Se selecciona el atributo con más rendimiento, por ejemplo  $e$
- ❑ Se entrena un modelo usando  $e$  junto con cada atributo ( $\{a, e\}$ ,  $\{b, e\}$  ...) y se mide su rendimiento
- ❑ Se selecciona el conjunto de atributos que más aumenta el rendimiento con respecto a  $\{e\}$
- ❑ Se repite este proceso hasta que no se observe una mejora significativa en el rendimiento del modelo o se queda sin atributos




# Eliminación secuencial de atributos: backward

- ❑ Se entrena un modelo de aprendizaje automático con todas las características y se calcula su rendimiento
- ❑ Para cada característica: se la descarta y se entrena un modelo con las características restantes
- ❑ Se elimina aquella característica cuyo descarte produjo el cambio más pequeño en el rendimiento del modelo
- ❑ Se repite este proceso hasta que no se puede eliminar ninguna característica más



# Componentes Principales (PCA)

- ❑ Encuentra una proyección que captura la mayor cantidad de variación en los datos.
- ❑ Los **datos originales se proyectan en un espacio mucho más pequeño**, lo que resulta en la reducción de dimensionalidad.
- ❑ Buscamos los autovectores de la matriz de covarianza, y estos autovectores definen el nuevo espacio.
  - ❑ Los autovalores varianza capturada por el CP



# Bibliografía

- ❑ Jiawei Han, Micheline Kamber, Jian Pei. 2012. Tercera edición. Data Mining: Concepts and Techniques. Cap. 3
- ❑ Rosaria Silipo. Seven Techniques for Data Dimensionality Reduction. [ [web](#) ]