

Minería de Datos

Datos no estructurados

Datos estructurados y no estructurados

❑ Datos estructurados

- Poseen un **modelo de datos** que organiza los datos y estandariza cómo se relacionan entre sí y con las propiedades de las entidades del mundo real
- Ejemplo: cliente: id, nombre, apellido, edad, ...

❑ Datos no estructurados

- No tienen un modelo de datos predefinido o no están organizados de una manera predefinida
- Imágenes, texto, sonido...

❑ Datos semi estructurados


- Tienen una parte estructurada y otra no estructurada
- Noticia: fecha de publicación, autor, sección + texto

Datos No Estructurados

- ❑ Se deben estructurar los datos extrayendo atributos. Se puede hacer en forma manual o automática
- ❑ **Más del 95%** de todos los datos generados **no están estructurados**

Person p Loc l Org o Event e Date d Other z

Barack Hussein Obama II * (born August 4, 1961 *) is an American * attorney and politician who served as the 44th President of the United States * from January 20, 2009 *, to January 20, 2017 *. A member of the Democratic Party *, he was the first African American * to serve as president. He was previously a United States Senator * from Illinois * and a member of the Illinois State Senate *.



Estructurar Texto

Modelo

- ❑ Bolsa de palabras

Técnicas

- ❑ Tokenizar
- ❑ Pasar a minúsculas, normalizar y quitar ruido
- ❑ Eliminar *stopwords*
- ❑ Detectar entidades
- ❑ Aplicar *stemming* y lematización

Modelo: Bolsa de palabras

- ❑ No importa el orden de las palabras
- ❑ Modelo simple pero con buenos resultados
- ❑ ¿Cuál es la probabilidad de sacar la palabra "tango" de la bolsa?
- ❑ Problema: la cantidad de palabras en la bolsa está relacionada con la dimensionalidad de los datos



Matriz de Término/Documento


- ❑ Forma de representar las palabras en el texto como una tabla (o matriz) de números
- ❑ Filas → documentos, columnas → términos, valores → 0/1, frecuencia, ...
- ❑ Representación de **alta dimensión**, **dispersa** y **no negativa**.

	El	popular	01	placentero	baile	Gardel	Escuchar	fue	tango	sueños	liquido	un	del	Tango	gran	valor	el	vendido	los	es	Con
El tango es un baile popular	1	1			1				1			1	1							1	
Escuchar tango es placentero				1			1		1											1	
Gardel es un gran valor del tango						1			1			1			1	1				1	
Con el Tango liquido los sueños										1	1			1			1		1		1
El Tango 01 fue vendido	1		1					1						1				1			

Bolsa de palabras

El tango revolucionó el baile popular introduciendo una danza sensual con pareja abrazada que propone una profunda relación emocional de cada persona con su propio cuerpo y de los cuerpos de los bailarines entre sí. Refiriéndose a esa relación, Enrique Santos Discépolo, uno de sus máximos poetas, definió al tango como «un pensamiento triste que se baila»


57 palabras
2 oraciones



Términos	Frecuencia
de	4 /57
tango	2
los	2
que	2
una	2
con	2
el	1
Santos	1
sí.	1
danza	1
relación	1
al	1
cada	1
pensamiento	1
sensual	1
Refiriéndose	1
baile	1
baila	1
máximos	1
relación	1
sus	1
esa	1
Discépolo	1
persona	1
abrazada	1
triste	1
propone	1
pareja	1
cuerpo	1

Tokenización

El tango es un género musical y una danza, característica de la región del Río de la Plata y su zona de influencia



Proceso de Tokenización

el, tango, es, un, género, musical, y,
una, danza, característica, de, la,
región, del, río, de, la, plata, y, su,
zona, de, influencia

tango, género, musical, danza,
característica, region, rio, plata,
zona, influencia

tango, género, musical, danza,
característica, región, **[Río de la
Plata]**, zona, influencia

Cada variante modifica el espacio de características



Pasar a minúsculas, normalizar y quitar ruido

❑ Minúsculas

- ❑ Pasar todo el texto a minúsculas para disminuir el tamaño de la bolsa de palabras
- ❑ Cuidado: “Carlos es de La Pampa” → “carlos es de la pampa”, USA → usa

❑ Normalizar

- ❑ Reemplazar palabras por su forma canónica
- ❑ “Bieeeeeen” → “Bien”, {“:-)”, “:-)” } → sonrisa, “BTW” → “por cierto”


❑ Quitar ruido

- ❑ Quitar caracteres o partes del texto que pueden interferir con el análisis
- ❑ “La casa es...” → “La casa es...”
- ❑ “La compra<, de...” → “La compra, de...”

Remove *stopwords*

- ❑ Remove palabras muy frecuentes (***stopwords***) porque no ayudan
- ❑ Podemos utilizar listas de ***stopwords*** ya curadas para cada idioma.

*un una unas unos uno sobre todo también tras otro algún
alguno alguna algunos algunas ser es soy eres somos sois
estoy esta estamos estais estan como en para atrás porque
por qué estado estaba ante antes siendo ambos pero por
poder puede puedo podemos podéis pueden fui fue fuimos
fueron hacer hago hace hacemos hacéis hacen cada....*



¿Qué tan útiles son estas palabras para entender la semántica?

Detectar de entidades

- ❑ Subtarea de Extracción de Información cuyo objetivo es identificar y clasificar expresiones de un texto que hacen referencia a personas, organizaciones, lugares, marcas comerciales e incluso fechas, horas, medidas...
- ❑ “Carlos López, presidente del Banco Central, llegó este martes a las 19:00 a San Luis”
 - {“Carlos López”, “presidente”, “del”, “Banco Central”, “llegó”, “este”, “martes”, “a”, “las”, “19:00”, “a”, “San Luis”}
 - {<Carlos López, persona>, “presidente”, “del”, <Banco Central de la República Argentina, entidad>, “llegó”, “este”, “<martes, 2 de mayo de 2022>”, “a”, “las”, “<19:00, hora, GMT-3>”, “a”, “<Provincia de San Luis, Argentina, lugar>”}

Stemming y lematización


- ❑ Extraer la raíz morfológica de una palabra
- ❑ En *stemming* se usan heurísticas (quitar prefijos y sufijos automáticamente)

Form	Suffix	Stem
studie s	-es	studi
study ing	-ing	study
niñ as	-as	niñ
niñ ez	-ez	niñ

- ❑ La lematización se busca la raíz de la palabra
 - ❑ ido → ir
 - ❑ yendo → ir
 - ❑ ...

Otras tareas del Procesamiento del Lenguaje Natural

Part-of-speech tagging: averiguar qué son sustantivos, verbos, adjetivos, etc.



The screenshot shows a web-based interface for a Maximum Entropy Part of Speech Tagger. It has a title bar with a dropdown arrow, the text "Maximum Entropy Part of Speech Tagger", and standard window controls. The main area is divided into two sections. The top section, titled "Type a sentence to tag:", contains a text input field with the following text: "El tango es un baile popular", "Escuchar tango es placentero", "Gardel es un gran valor del tango", "Con el Tango liquido los sueldos", and "El Tango 01 fue vendido". Below the input field is a button labeled "Tag sentence!". The bottom section, titled "Tagged sentence:", displays the output of the tagging process, where each word is followed by its assigned part-of-speech tag in a smaller font.

Maximum Entropy Part of Speech Tagger

Type a sentence to tag:

El tango es un baile popular
Escuchar tango es placentero
Gardel es un gran valor del tango
Con el Tango liquido los sueldos
El Tango 01 fue vendido

Tag sentence!

Tagged sentence:

El_NNP tango_NNP es_VBZ un_JJ baile_NN pupular_JJ Escuchar_NN tango_NN es_VBZ placentero_NN Gardel_NNP es_VBZ un_JJ gran_JJ valor_NN del_DT tango_NN Con_NN el_NN Tango_NNP liquido_NNP los_VBZ sueldos_NNS El_NNP Tango_NNP 01_CD fue_NN vendido_NN

El_NNP tango_NNP es_VBZ un_JJ baile_NN
pupular_JJ Escuchar_NN tango_NN es_VBZ
placentero_NN Gardel_NNP es_VBZ un_JJ
gran_JJ valor_NN del_DT tango_NN Con_NN
el_NN Tango_NNP liquido_NNP los_VBZ
sueldos_NNS El_NNP Tango_NNP 01_CD
fue_NN vendido_NN

Bibliografía

- ❑ Vijayarani, S., Ilamathi, M. J., & Nithya, M. (2015). Preprocessing techniques for text mining-an overview. International Journal of Computer Science & Communication Networks, 5(1), 7-16. [[pdf](#)]
- ❑ Zheng, A., & Casari, A. (2018). Feature engineering for machine learning: principles and techniques for data scientists. " O'Reilly Media, Inc.". **Capítulo 3**
- ❑ Hickman, L., Thapa, S., Tay, L., Cao, M., & Srinivasan, P. (2020). Text preprocessing for text mining in organizational research: Review and recommendations. Organizational Research Methods. [[pdf](#)]
- ❑ 95-865: Unstructured Data Analytics (Spring 2018 Mini 4) Clase 1 [[Slides](#)]